

**Compilation:** logiciel qui traduit un programme écrit dans un langage de haut niveau en instructions exécutables

### Différence entre un compilateur et un interpréteur

- \* le compilateur lit le code source fournit le fichier résultat, contenant le code machine (appelé aussi fichier cible), est exécutable une fois pour toutes.

ex: C, C++, Fortran...

- \* L'interpréteur ne crée pas de fichier cible. Il interprète et exécute au fur et à mesure les instructions du programme source

ex: PHP, Python, sh, bash

### Analyse lexicale

C'est l'unique module du compilateur qui lit le fichier contenant le code source. Il le lit caractère par caractère.

Il reconnaît les unités lexicales (ou tokens) qui sont les mots du langage et les présente à l'analyseur syntaxique.

Il supprime les espaces, les fins de ligne, les tabulations, les commentaires, affiche les erreurs (idf mal formé, caractère inconnu...)



Il code les unités lexicales avec des entiers (+ efficace, + simple à manipuler)

C'est un automate

### But de l'analyse sémantique

Vérifier que la phrase en entrée est bien formée, c'est-à-dire conforme à la syntaxe du langage, définie par une grammaire

Reconnaître les unités syntaxiques décrites par une grammaire (déclaration, affectation, instruction, variables...)

Détecter les erreurs syntaxiques : afficher des messages clairs et précis contenant le numéro de ligne de l'erreur, corriger l'erreur si possible,

et poursuivre l'analyse syntaxique pour détecter d'autres erreurs

L'analyse d'un programme correct ne doit pas être ralentie

### Analyse descendante

Le code source est lu unité lexicale par unité lexicale

L'arbre syntaxique est construit à partir de l'axiome, en accrochant les parties droites des productions sous la racine (suite d'expansion)

Le texte est lu de gauche à droite

LL(k) : left to right scanning, left most derivation

Une grammaire LL(k) n'utilise les k unités lexicales suivantes pour décider de la production à appliquer lors d'une expansion

### Algorithme : Analyse syntaxique descendante par fct récursives

A chaque non-terminal on associe une fct qui vérifie que le texte correspond à la syntaxe décrite par les  $\neq$  alternatives

Pour choisir entre ces  $\neq$  alternatives, les fct disposent d'une unité lexicale d'avance



## Analyse ascendante

L'analyse syntaxique ascendante ne fonctionne que par telle d'analyse déterministe

On part du moyen à analyser

On remplace itérativement des fragments du mot courant qui correspondent à des parties droites de règles de production par le membre gauche de cette règles.

L'analyse est OK si le mot courant final est l'axiome de  $G$

LR(k): left to right scanning, Right most derivation

## Item

Un item d'une grammaire  $G$  est une product° de  $G$  avec un marqueur (noté  $\cdot$ ) repérant une position de sa partie droite.

## Fermeture

Soit  $I$  un ensemble d'items de  $G$

Fermeture( $I$ ) est un ensemble d'items construits à partir de  $I$  tq:

- placer chaque item de  $I$  dans fermeture( $I$ )
- si  $A \rightarrow \alpha \cdot B \beta \in \text{Fermeture}(I)$  et si  $B \rightarrow \gamma$  alors ajouter  $B \rightarrow \cdot \gamma$  à Fermeture( $I$ ) (sauf si déjà dedans)
- itérer jusqu'à ne plus trouver d'item à ajouter à Fermeture( $I$ )

## État de l'automate LR(0)

Les états de l'automate LR(0) sont les ensembles  $I$  d'items obtenus par fermeture

L'état initial  $I_0$  est obtenu par fermeture de  $S' \rightarrow \cdot S$

## Transition de l'automate LR(0)

Soit  $I$  un ensemble d'items,  $X$  un symbole de  $G$  ( $X \in \text{INUT}$ )

On définit transition( $I, X$ ) comme étant la fermeture de l'ensemble des items  $A \rightarrow \alpha \cdot X \cdot \beta$  tq  $A \rightarrow \alpha \cdot X \beta \in I$



Toute grammaire  $SLR(1)$  est non ambiguë  
Toute grammaire  $LR(0)$  sans conflit est  $SLR(1)$

$k$  dans  $LR(k)$  représente le nb d'unités lexicales dont on a besoin pour prendre la décision de réduction

### Analyse sémantique


vérifie que le programme satisfait un ensemble de règles sémantiques  
vérifie que le texte source  $\rightarrow$  AST est conforme à un ensemble de règles de construction des programmes, définie par le manuel de référence du langage

### 2 catégories d'erreurs "sémantiques"

statiques : "vérifiables" à la compilation

dynamiques : "vérifiables" à l'exécution

ex : division par 0, allocation mémoire, dépassement tableau



### Technique de vérification

le nb de réduction c'est le nb d'État Terminal par contexte

le nb de déplacements c'est le nb de terminaux sur les flèches

le nb de transitions c'est le nb de non terminaux sur les flèches

Pour  $LALR(1)$  on regarde si on peut fusionner les états équivalents