Module RSA
Partie Réseaux

Isabelle Chrisment

2013-2014

Plan

① Contrôle de congestion et TCP

② Programmation réseaux

- socket, select(), options de socket, socket raw

③ Communication de groupe (multicast)

④ Introduction IPv6

① Contrôle de congestion et TCP

- TCP : quelques rappels
- Congestion Internet
- TCP Tahoe
- TCP Reno
- RTT et TCP
- TCP Vegas
- Equité TCP

TCP : quelques rappels

RFCs: 793, 1122, 1323, 2018, 2581

- Point-à-point
- Orienté connexion
- Fiable et ordonné
- Pas de frontière de message
- Full duplex
- Flux contrôlé

Structure d'un segment

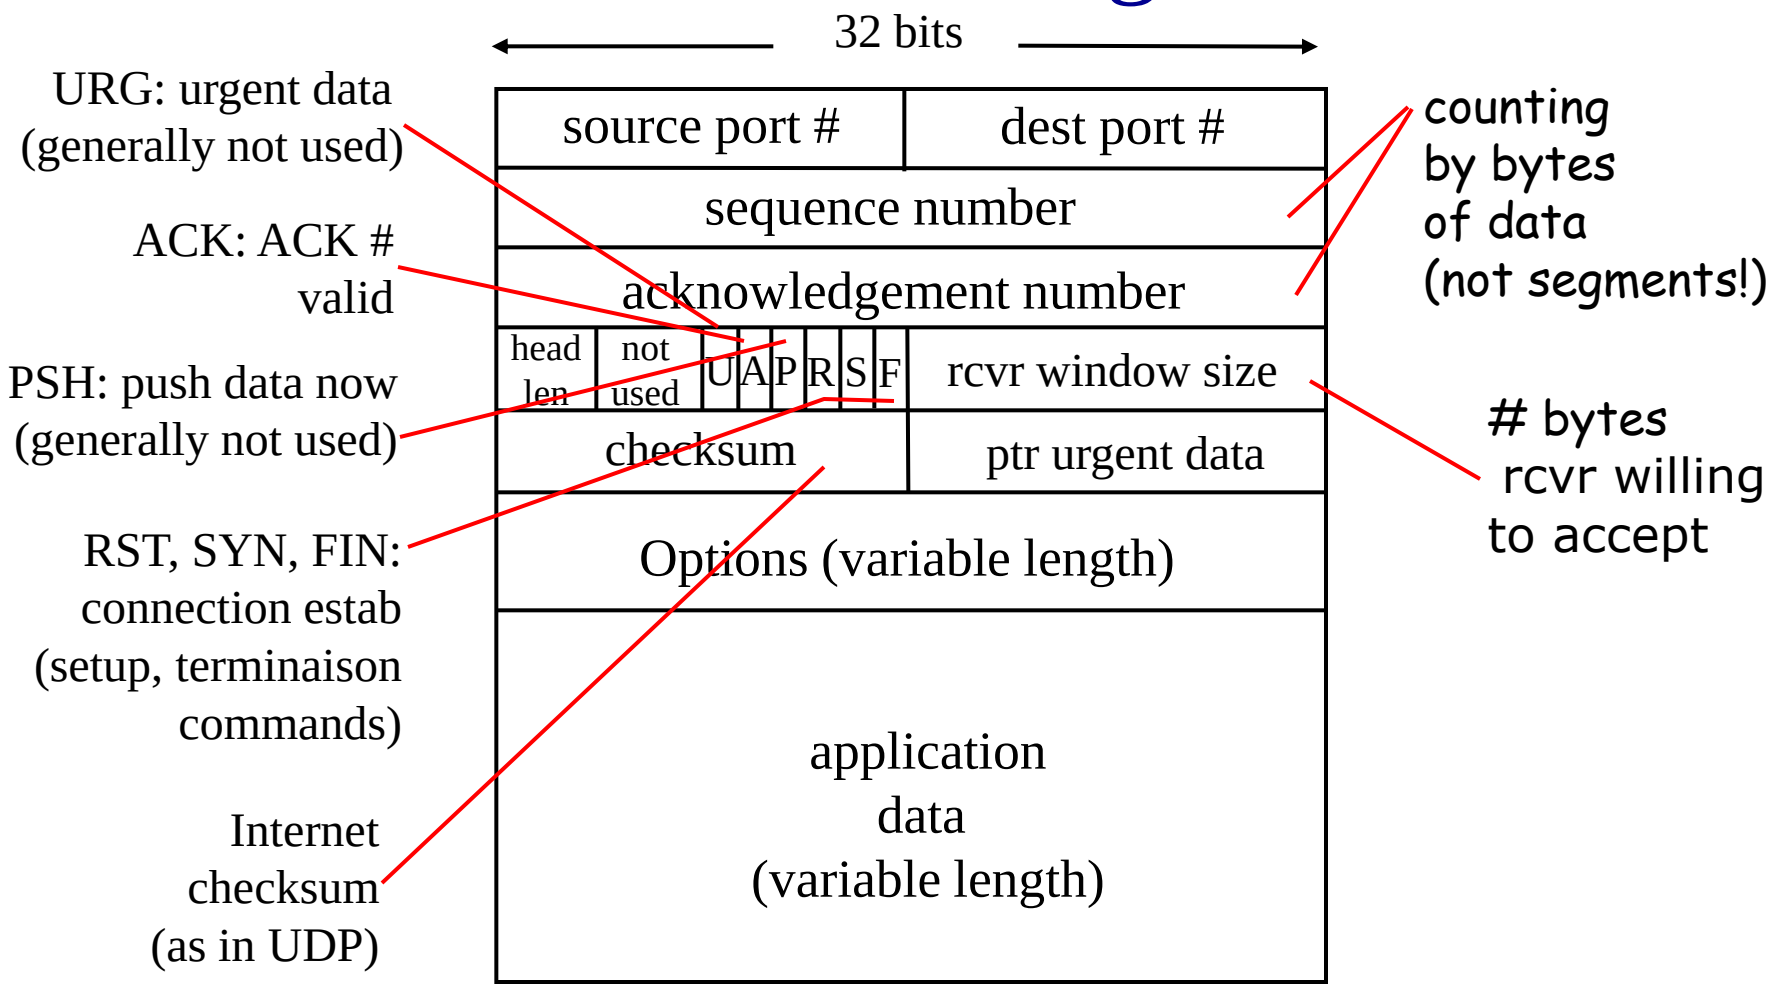

Kurose & Ross

TCP seq. #'s - ACKs

Seq. #'s:

- Flux d'octets "numéro" du premier octet dans les données du segment

ACKs:

- seq # du prochain octet attendu de l'autre côté
- ACK cumulatif

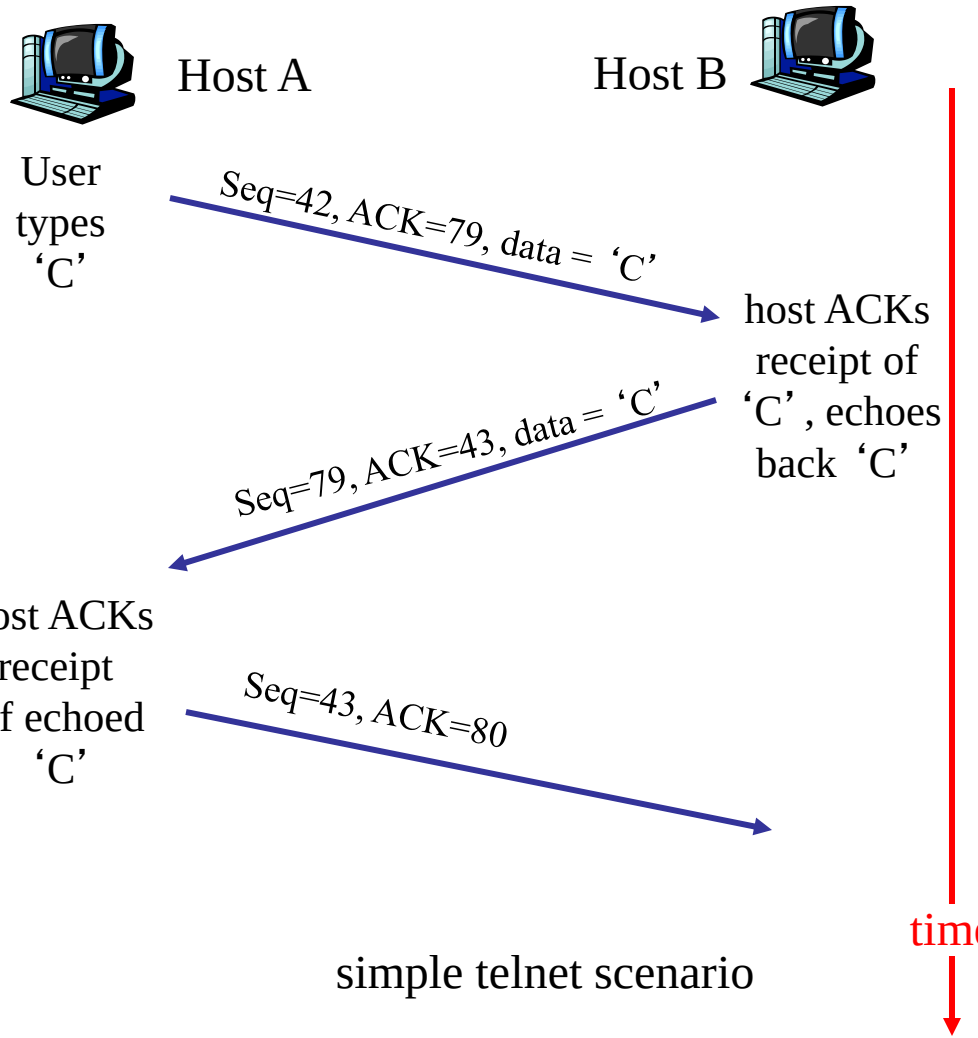

simple telnet scenario

Kurose & Ross

TCP Etablissement d'une connexion

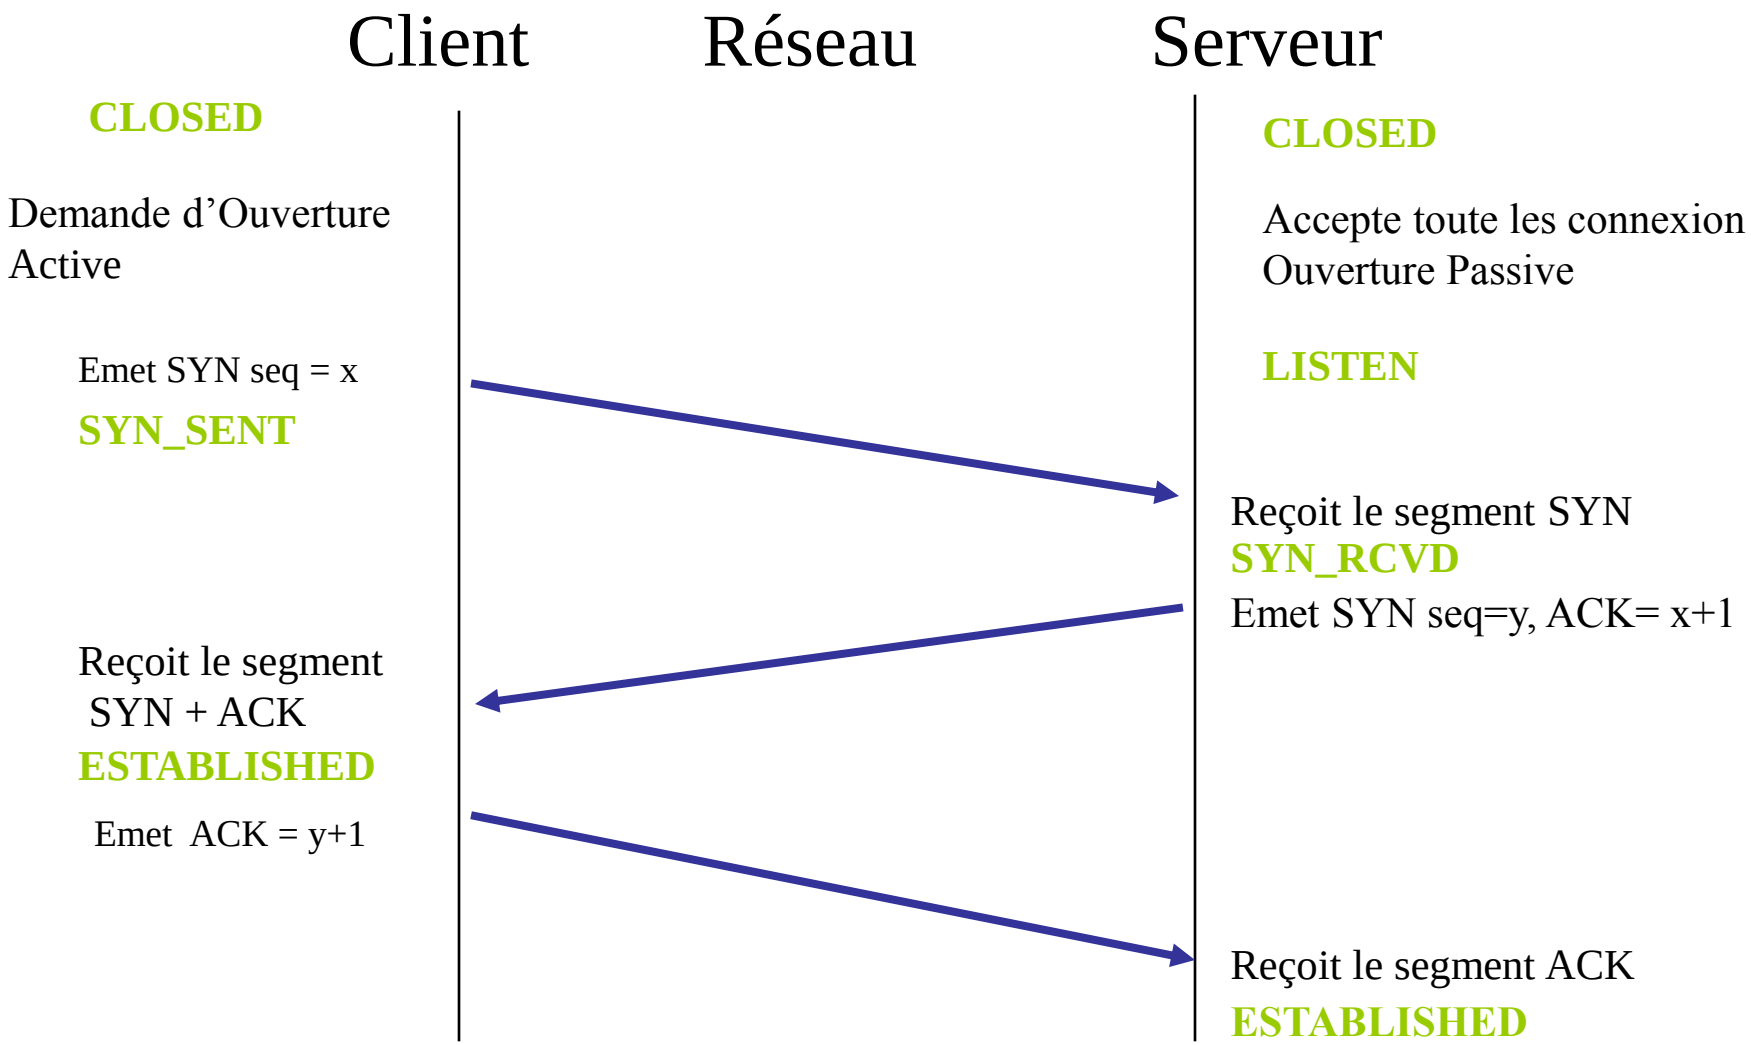

TCP syn cookies

- Choix particulier du numéro de séquence côté serveur :

(cf http://cr.yp.to/syncookies.html)

- 5 bits = t mod32 (t compteur de temps sur 32 bits)
- 3 bits : encodage de la valeur du MSS du serveur
- 24 bits F(adr. src, port src, adr. dest, port dest, t, secret)

  avec F = fonction crypto

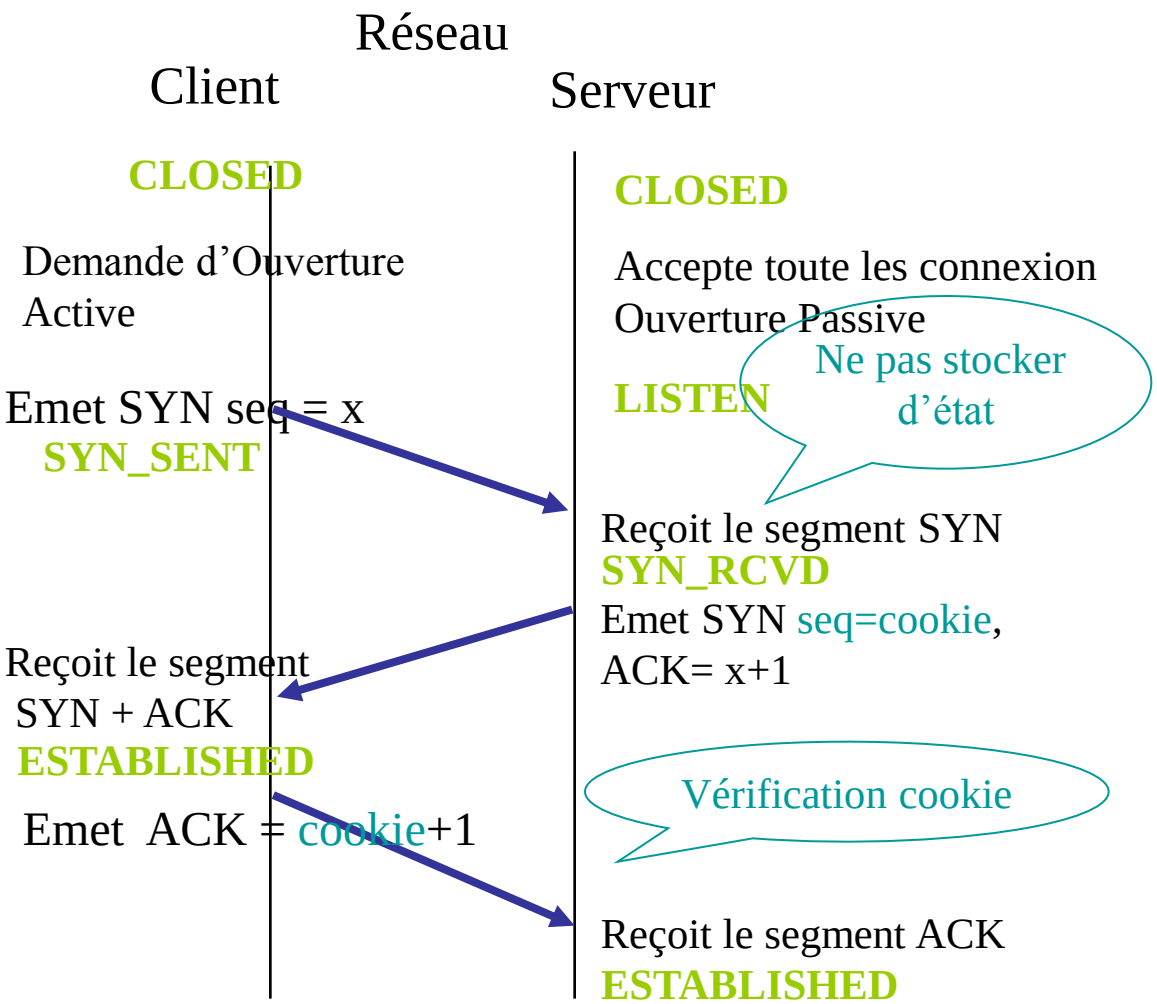

TCP fermeture connexion

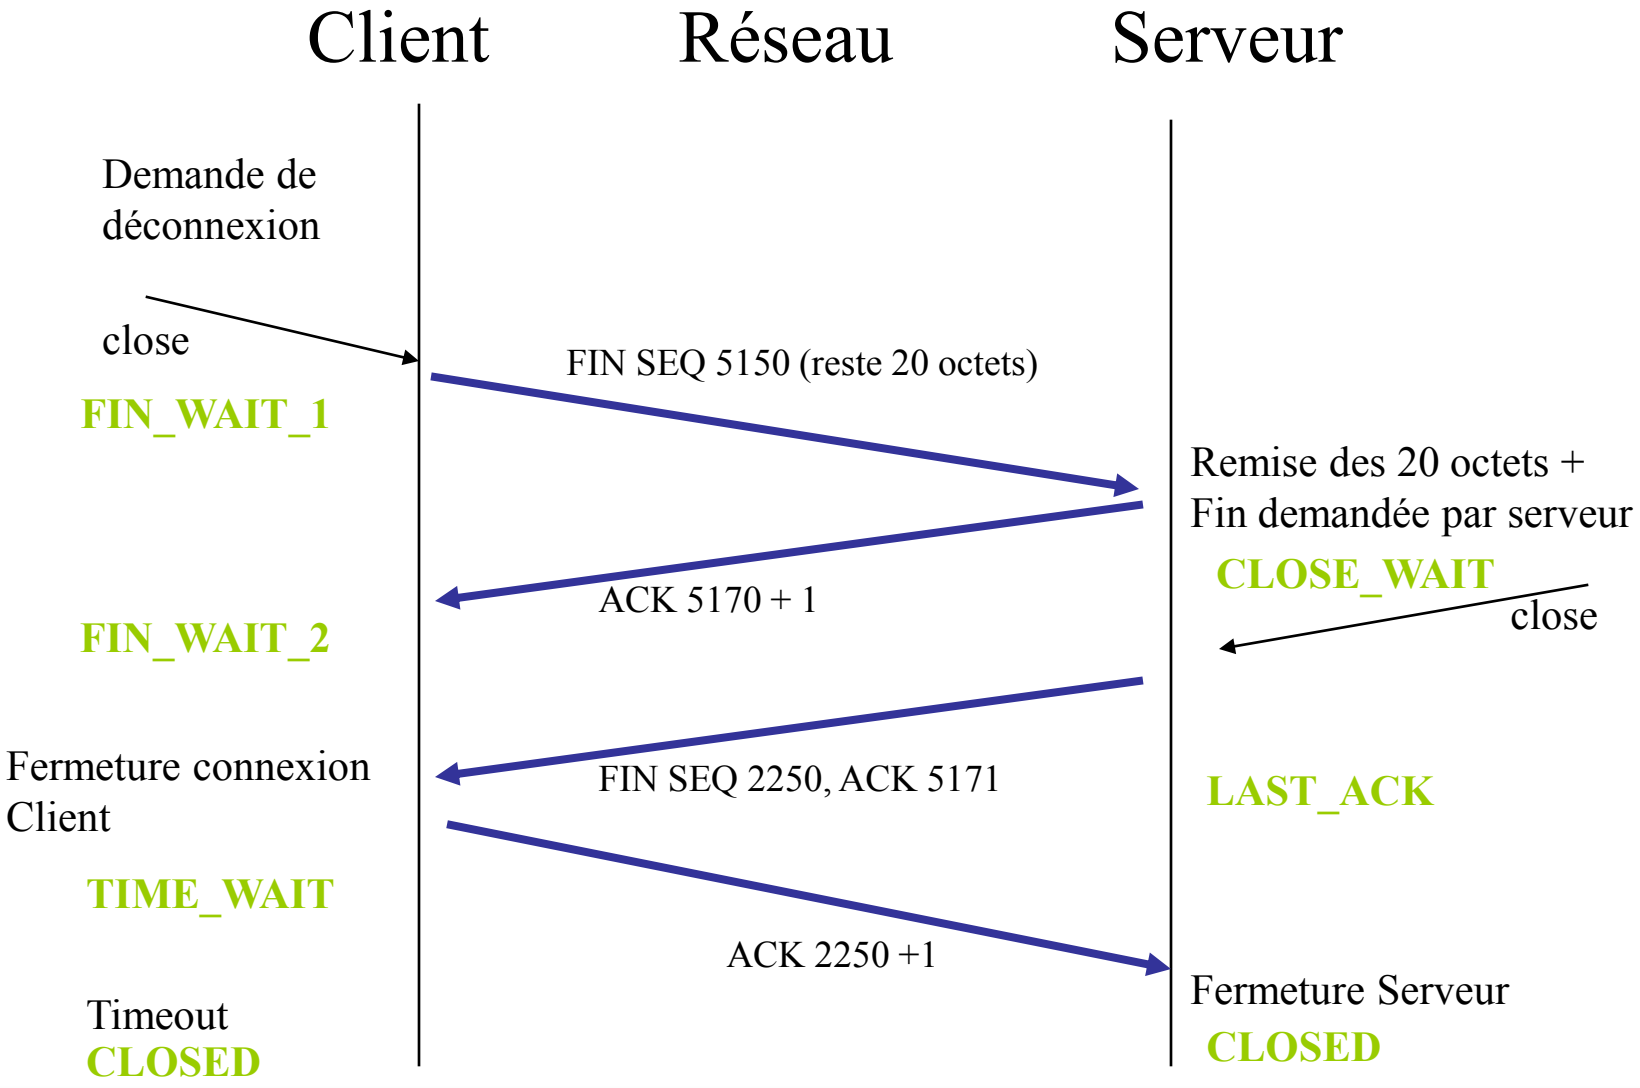

TCP: scénario de retransmission

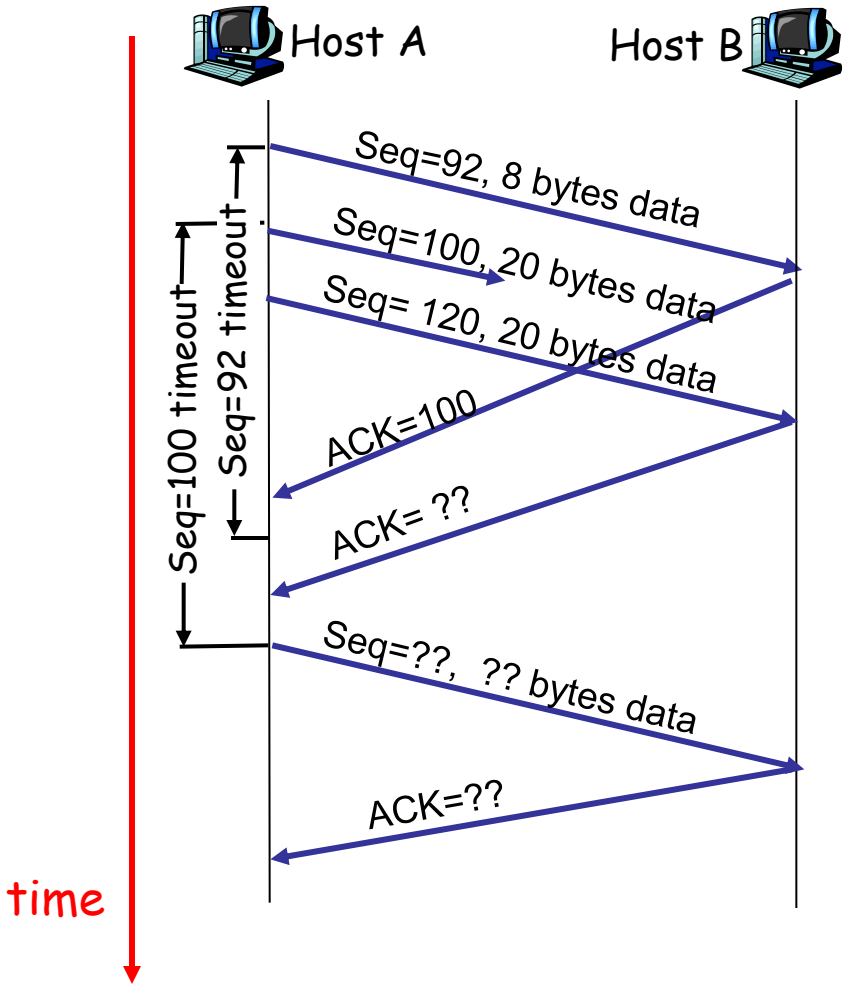

Silly window avoidance
TCP Illustrated Stevens

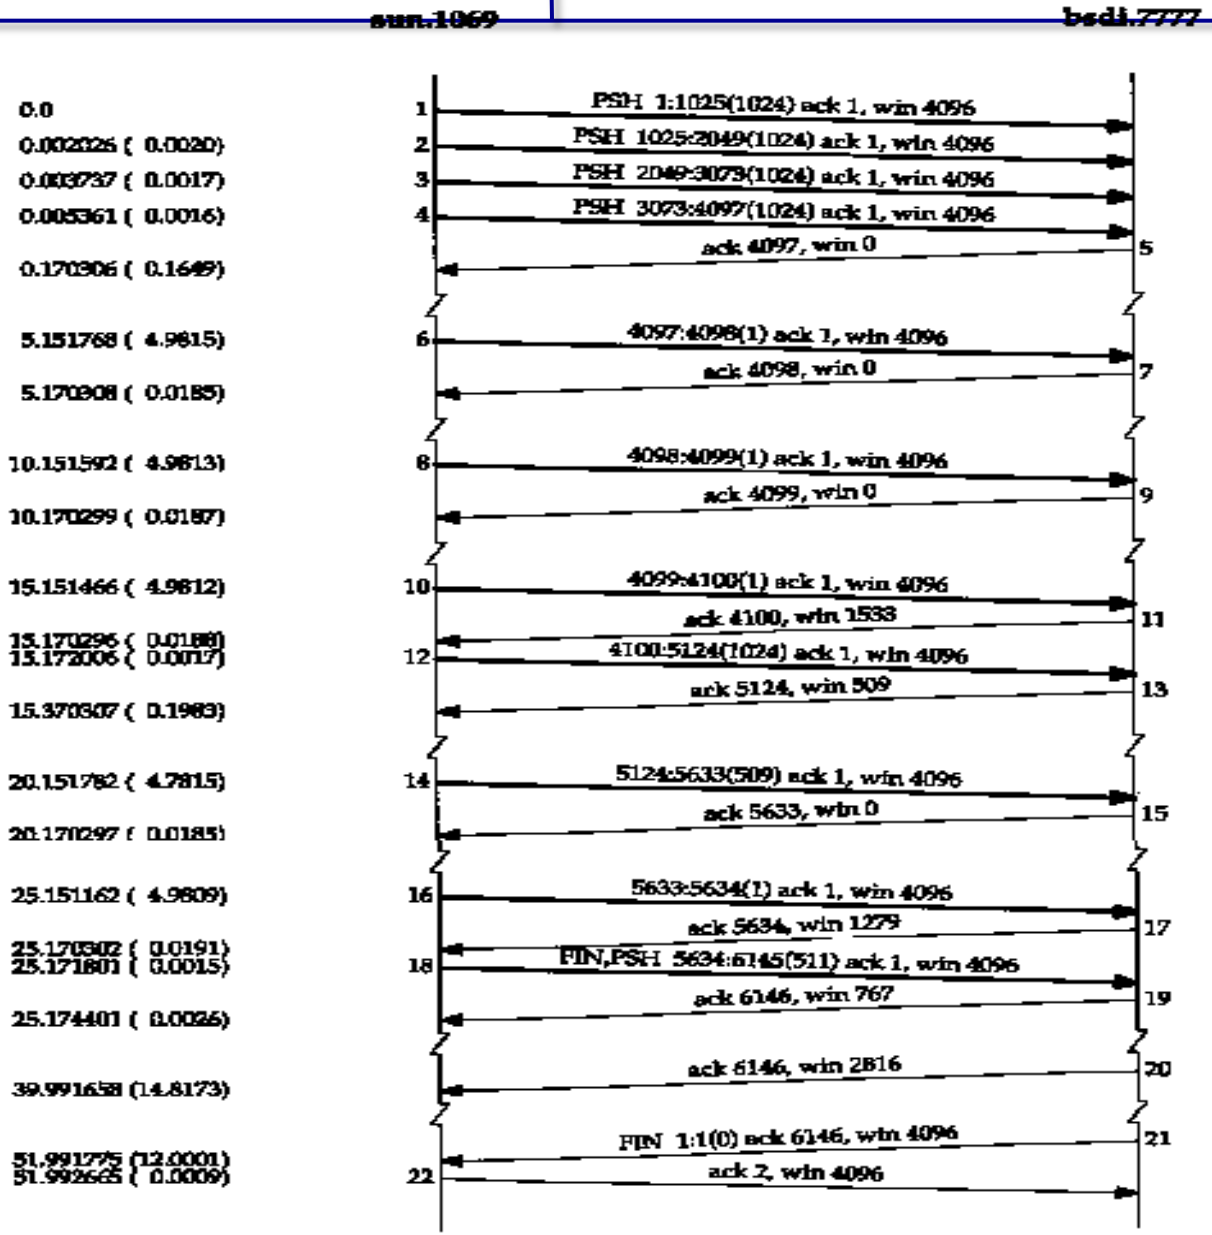

Congestion Internet - Problématique

- Dans les années 80, avenir de TCP/IP en question
  - Trop de congestion

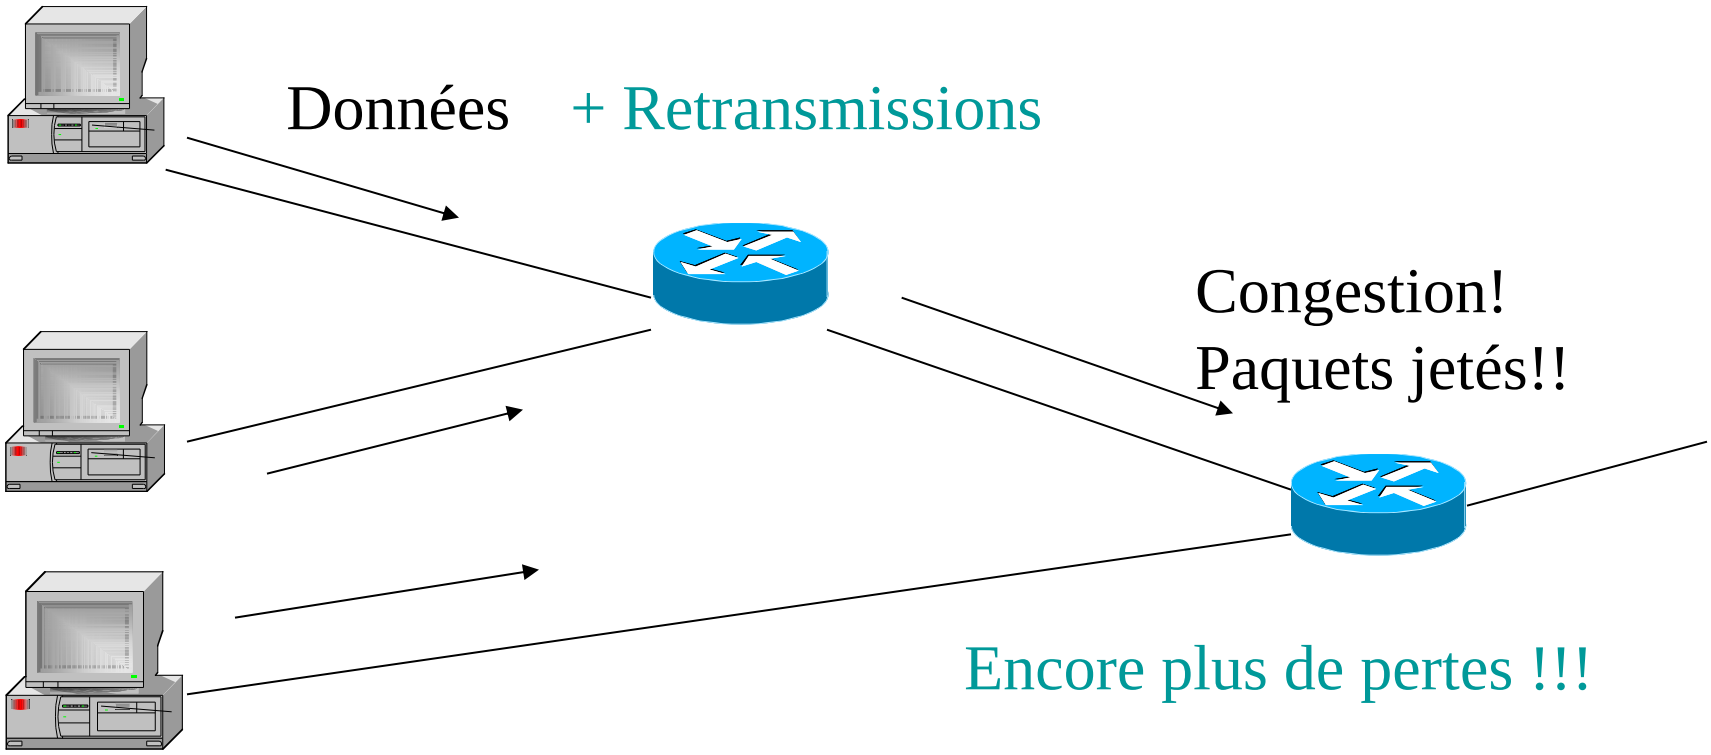

Causes/coûts de la congestion : scénario 1

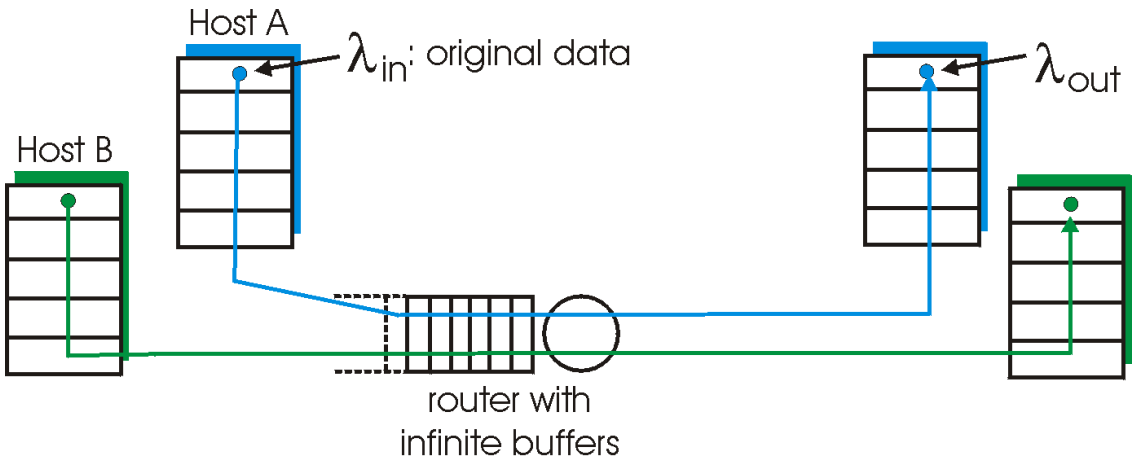

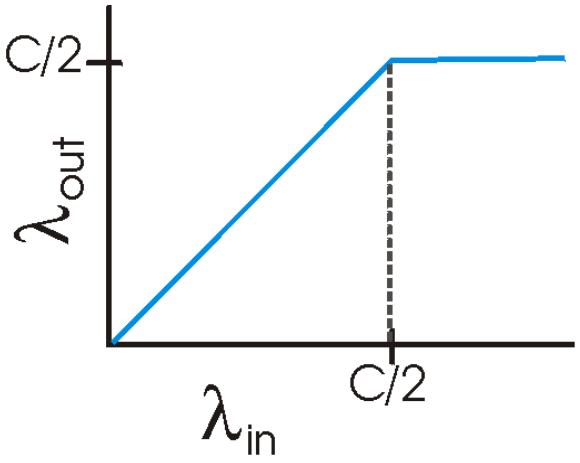

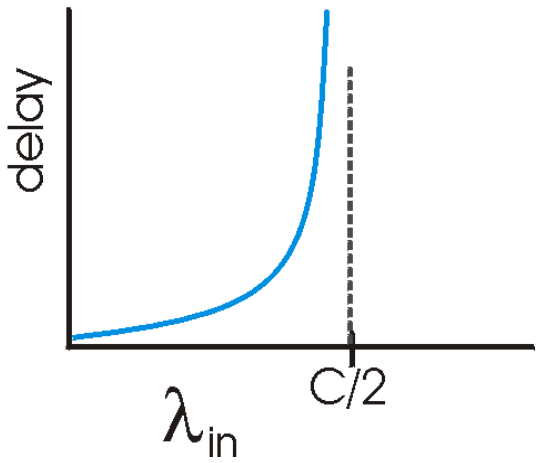

Kurose & Ross

Causes/coûts de la congestion : scénario 2

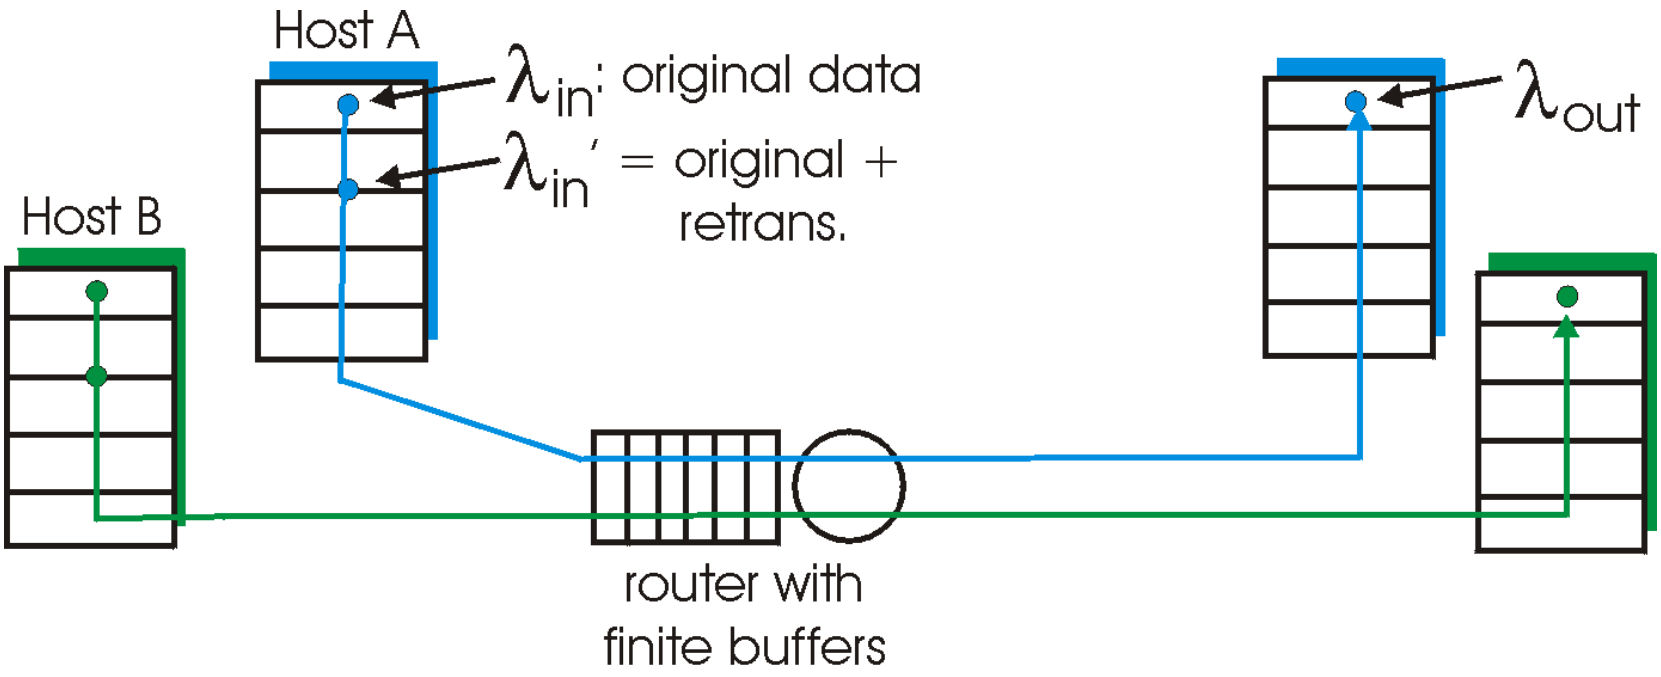

Kurose & Ross

Causes/coûts de la congestion : scénario 2

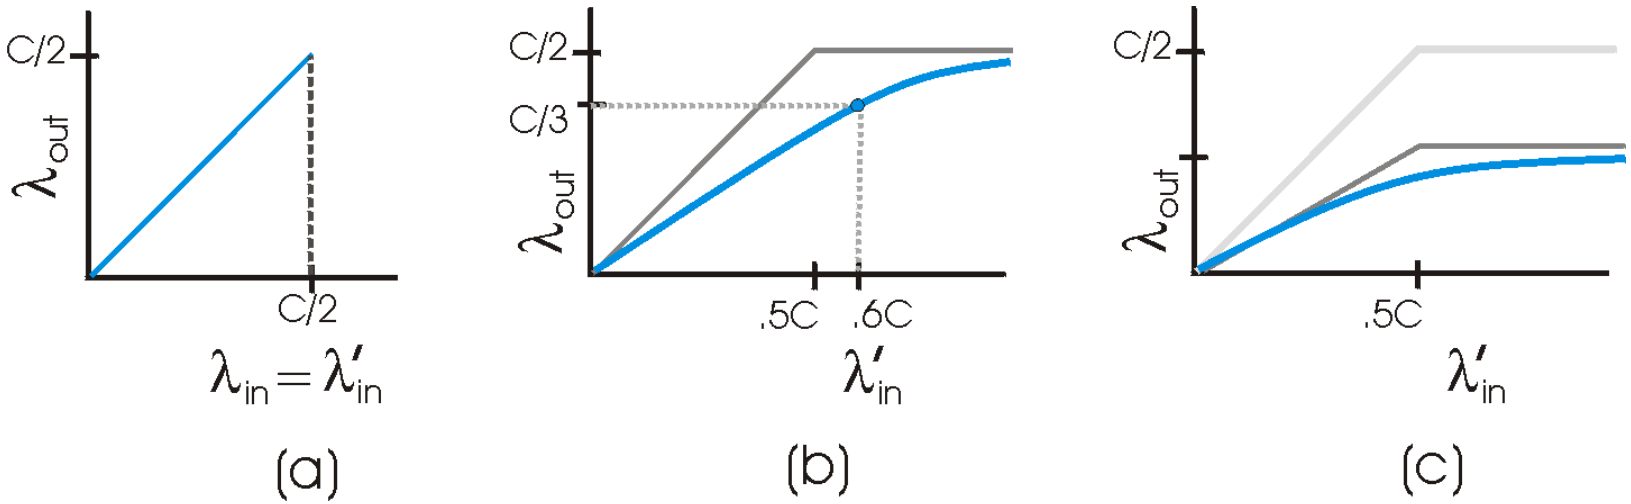

Kurose & Ross

Causes/coûts de la congestion: scenario 3

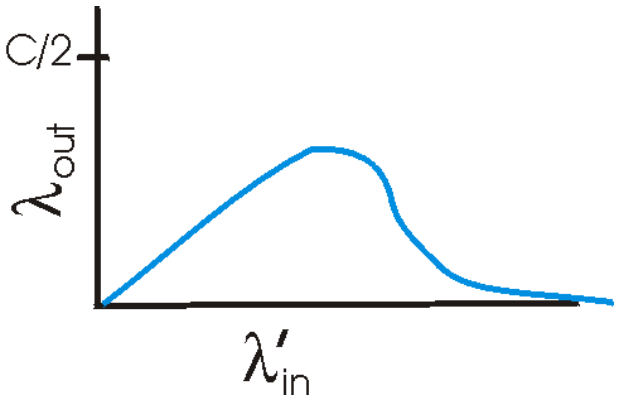

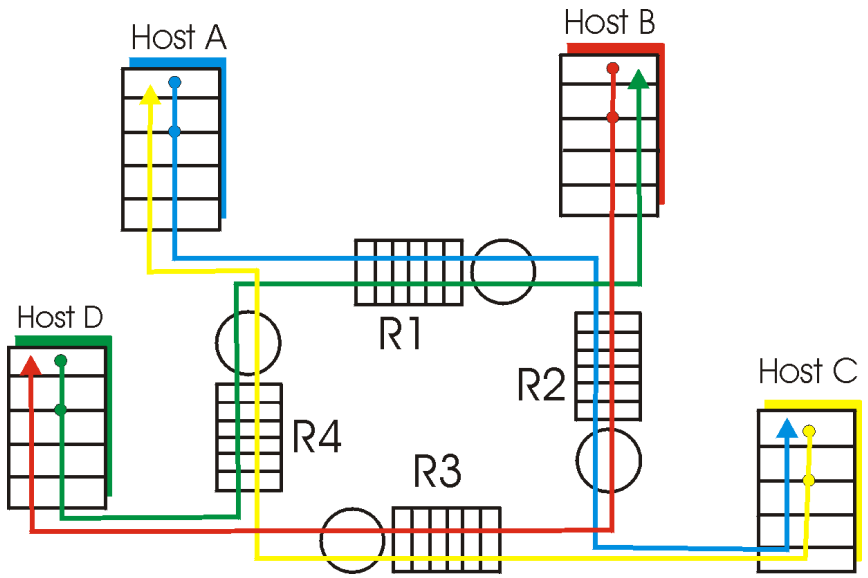

Kurose & Ross

- Comment améliorer TCP afin qu'il envoie moins de trafic quand le réseau est congestionné ?
  - Comment détecter la congestion ?
  - Comment rendre le flux de données sensible au niveau de congestion ?

Détection de la congestion

- Elimination de paquets = indicateur de congestion ?

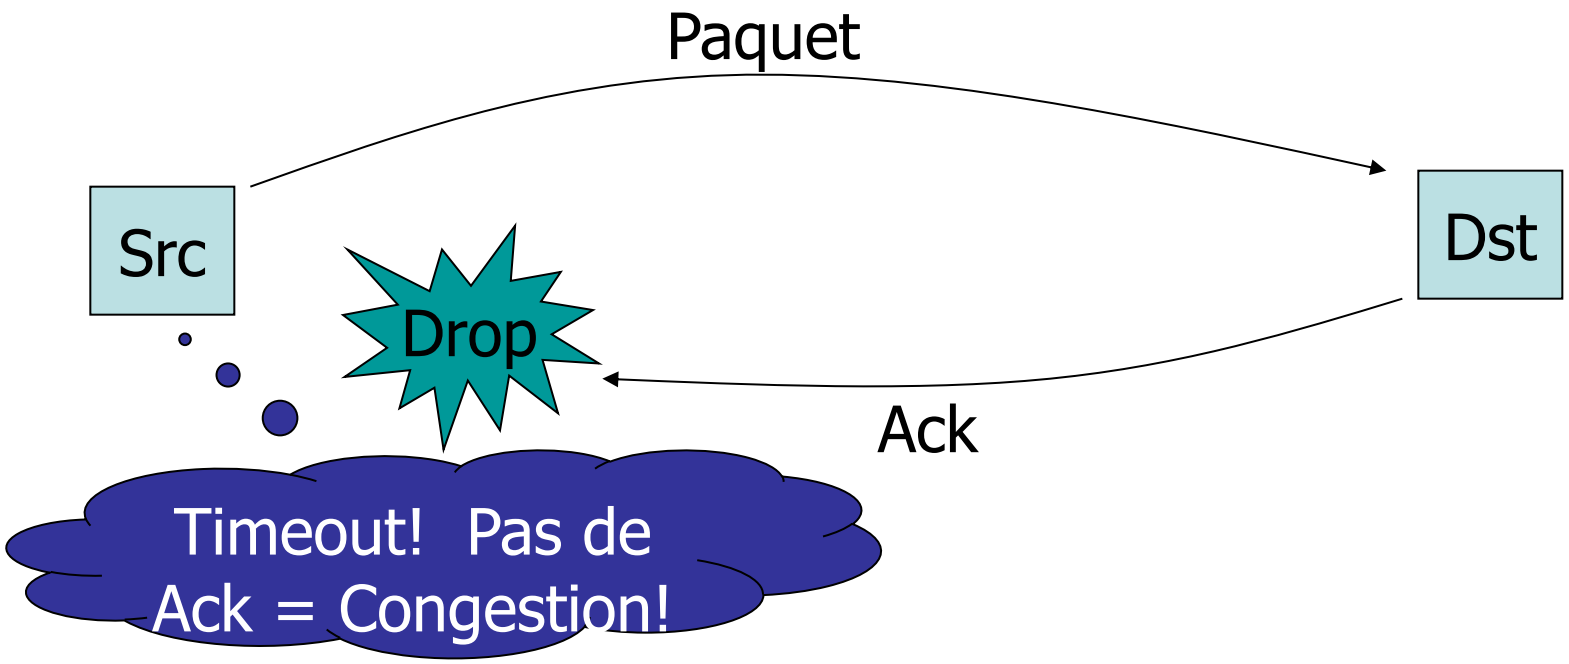

Contrôle de Congestion – l'effet de la taille de la fenêtre

- Noter que la fenêtre de l'émetteur est égale au nombre de paquets en transit dans le réseau

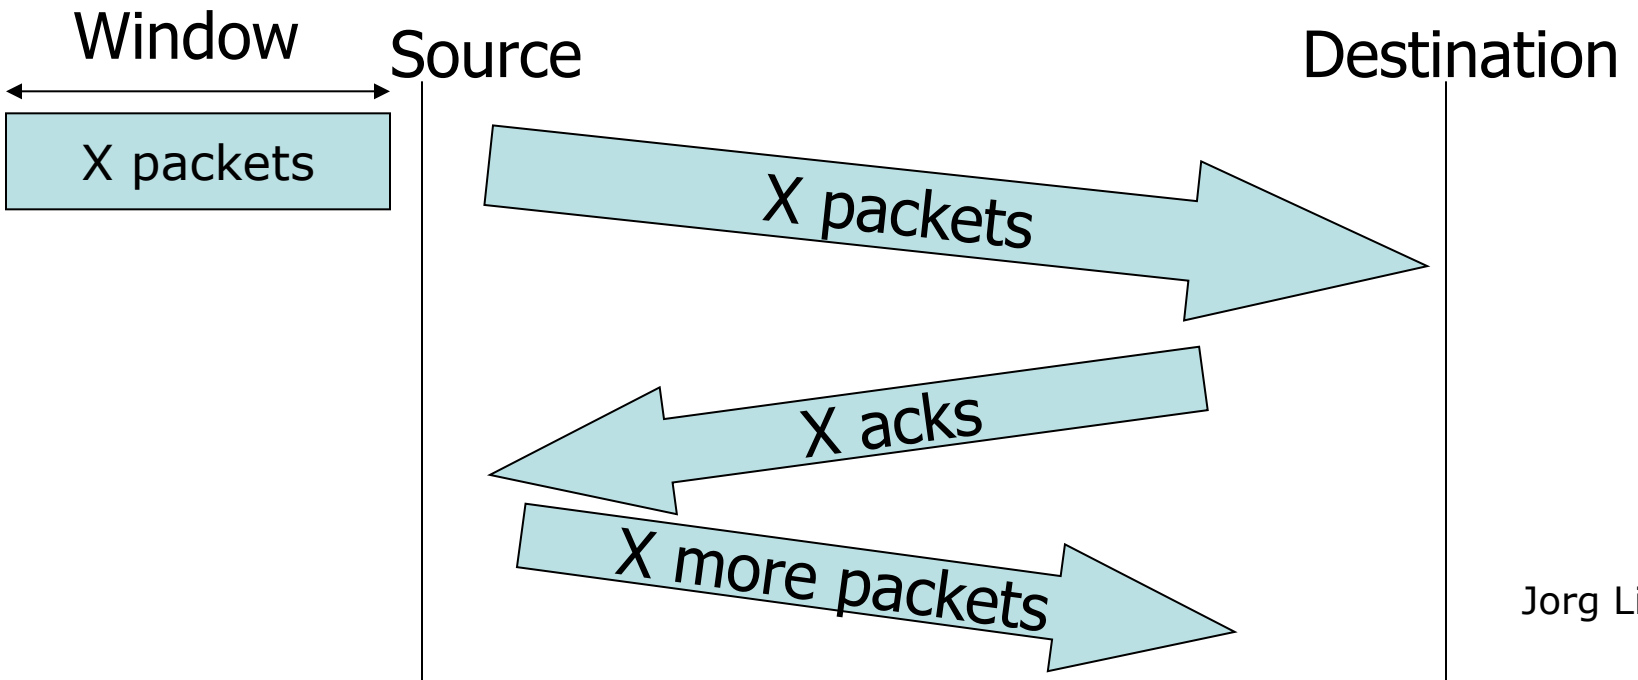

Jorg Liebherr

Contrôle de congestion TCP

- Contrôle de bout-en-bout (pas d'assistance du réseau)
- Débit de transmission limité par taille de fenêtre

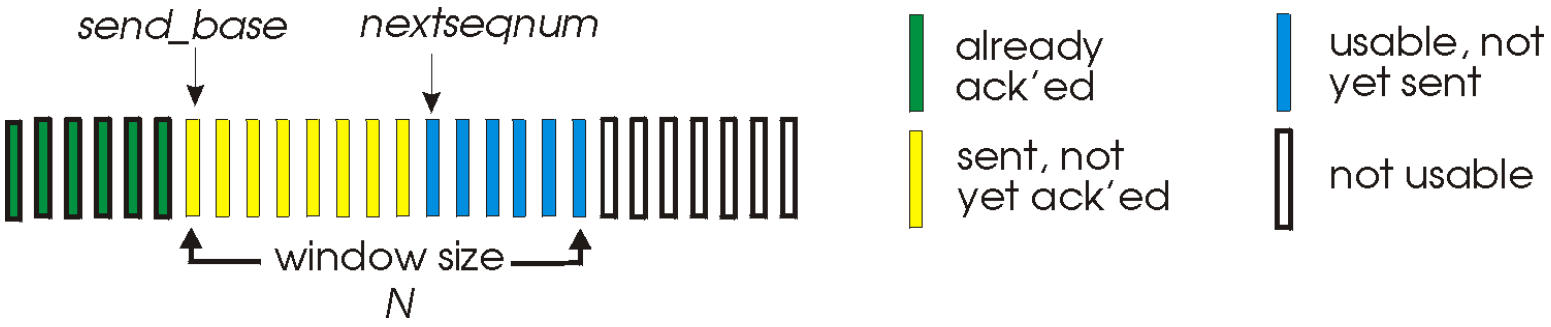

Kurose & Ross

Contrôle de congestion TCP

- w segments, chacun avec MSS octets émis en un RTT:

$$\text{throughput} = \frac{w * MSS}{RTT} \quad \text{Bytes/sec}$$

Contrôle de congestion TCP

- "sonder" pour la bande passante utilisable:
  - idéalement: transmettre aussi vite que possible (fenêtre la + grande possible) sans perte
  - *augmenter* la fenêtre (→ plus de paquets dans le réseau) jusqu'à l'apparition de pertes (congestion)
  - pertes: *diminuer* la fenêtre (→ moins de paquets dans le réseau) et recommencer à sonder (augmenter) à nouveau

Contrôle de Congestion

- Idée: Concept de la *congestion window*
  - fenêtre qui est petite quand la congestion est importante
  - fenêtre qui est grande quand la congestion est petite
- Fenêtre autorisée = minimum (fenêtre récepteur, fenêtre de congestion)

Contrôle de congestion de Van Jacobson

- Van Jacobson a introduit le contrôle de congestion dans TCP en 1988-1989
- La version d'origine de TCP qui implante le contrôle de congestion de Van Jacobson est connue sous le nom de TCP Tahoe

Éléments de contrôle de congestion dans TCP Tahoe

- AIMD
  - Additive increase, multiplicative decrease
- Slow start
- Congestion Avoidance

Additive Increase, Multiplicative Decrease

- Chaque fois qu'un paquet est détruit (perdu), réduire la taille de la fenêtre de manière significative (multiplicative decrease)
  - Multiplicative decrease est nécessaire pour éviter la congestion
- Si aucune perte n'est observée, augmenter de manière graduelle la taille de la fenêtre (additive increase)

Problèmes

- Quelle doit être la taille de la fenêtre
  - Initialement ?
  - Quand il y perte de paquet ?
- Taille de fenêtre pessimiste? (e.g., 1)
  - Additive increase est trop lent
  - Les connexions courtes n'utiliseront jamais la bande passante disponible
- Taille de fenêtre optimiste?
  - Un flux trop important de données peut impliquer un overflow dans les files des routeurs

Slow Start

- Objectif: déterminer la capacité disponible rapidement
- Idée:
  - Utiliser **CongestionThreshold** comme une estimation optimiste de **CongestionWindow**
  - Commencer avec **CongestionWindow** = 1 segment
  - doubler **CongestionWindow** à chaque RTT (incrémenter de 1 paquet pour chaque ACK)
  - Quand **CongestionThreshold** est atteint utiliser additive increase

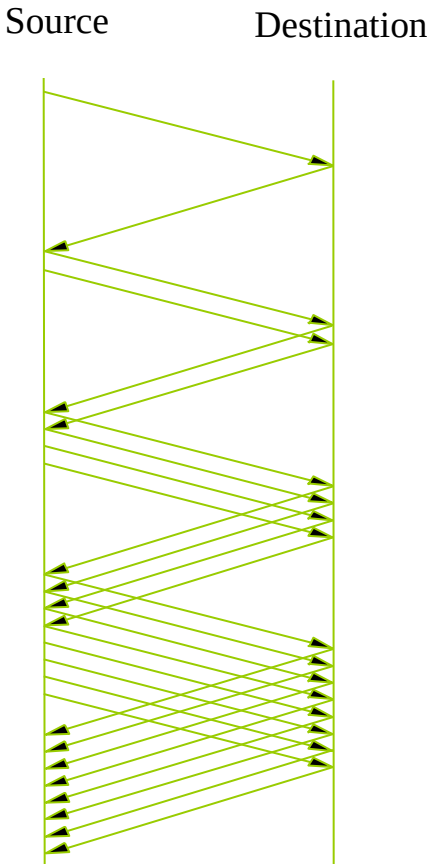

Slow-start TCP

Algorithme du slow start

initialise: Congwin = 1
Pour (chq segment ACKed)
    Congwin++
Jusqu'à (evt de perte OR
    CongWin >= threshold)

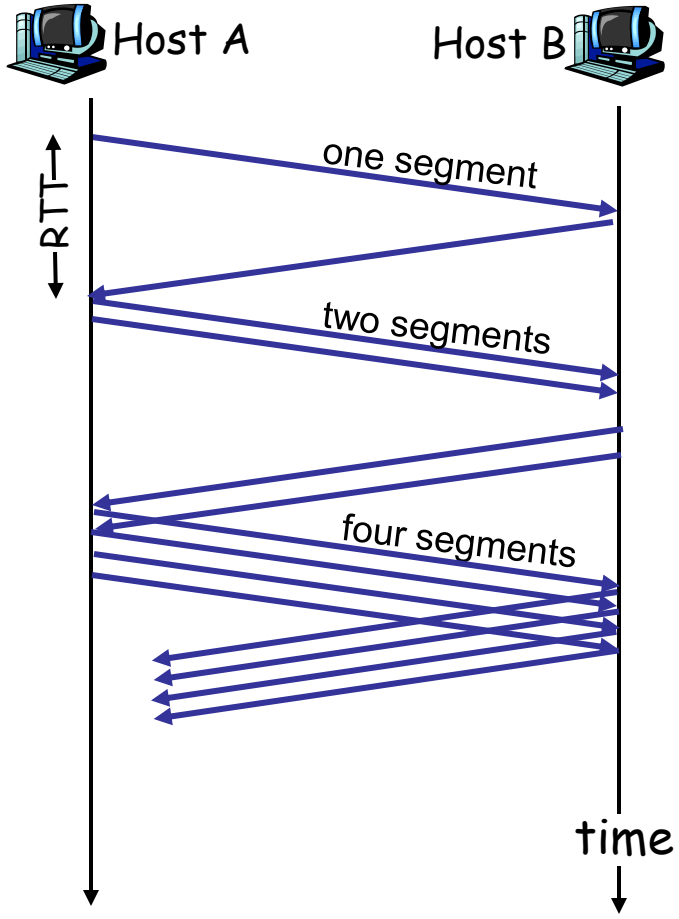

- Croissance exponentielle (par RTT) de la taille de fenêtre (pas si lent!)
- Evt de perte: timeout et/ou trois ACKs dupliqués (Tahoe TCP)

Kurose & Ross

Illustration du Slow Start

Hypothèse

CongestionThreshold = 8

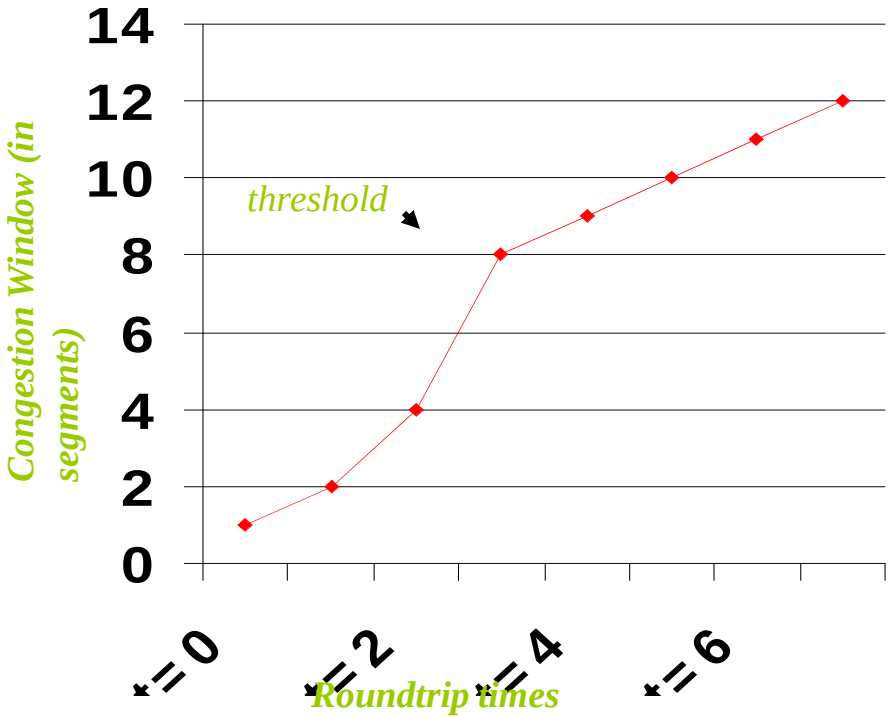

AIMD + congestion avoidance

- Algorithme :
  - Incrémenter **CongestionWindow** d'un paquet par RTT (*linear increase*)
  - Réduire **CongestionThreshold** et **CongestionWindow** (*multiplicative decrease*) quand perte

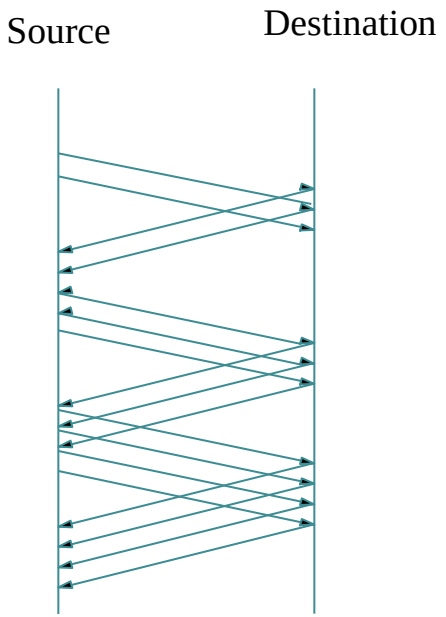

Evitement de congestion TCP
Congestion avoidance

Evitement de congestion

```
/* slowstart est terminé  */
/* Congwin >= threshold */
Until (evt de perte) {
  chq w segments ACKed:
      Congwin++
  }
threshold = Congwin/2
Congwin = 1
effectuer slowstart [1]
```

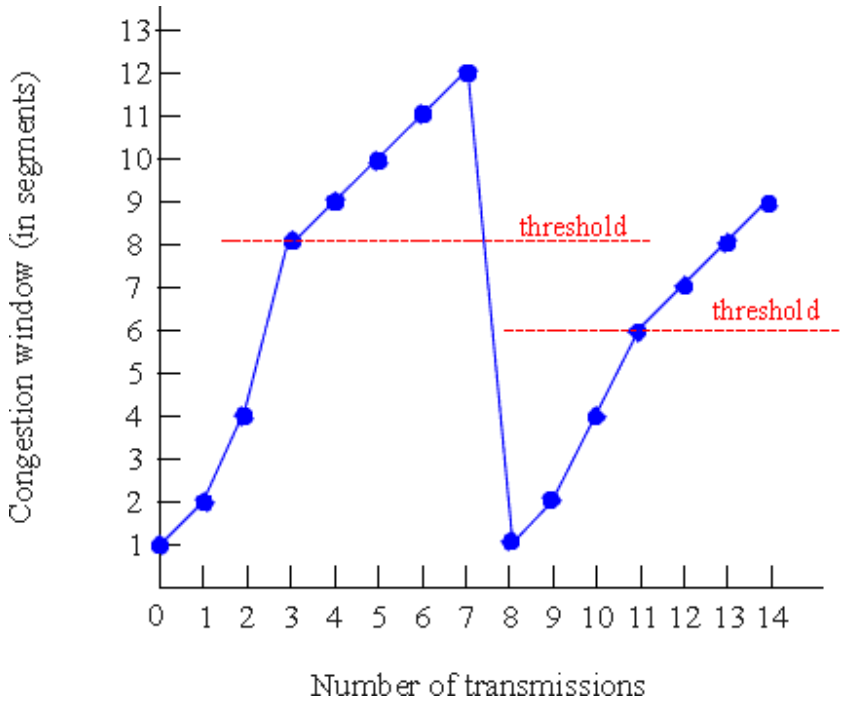

1: TCP Reno évite slowstart (fast recovery) après 3 ACKs dupliqués

Kurose & Ross

TCP Reno

- TCP Reno (1990) et ses dérivés sont les plus utilisés aujourd'hui
- TCP Reno implémente :
  - Fast Retransmit
  - Fast Recovery
- RFC 2581

Fast Retransmit

- Problème : les timers TCP peuvent conduire à des périodes d'inactivité

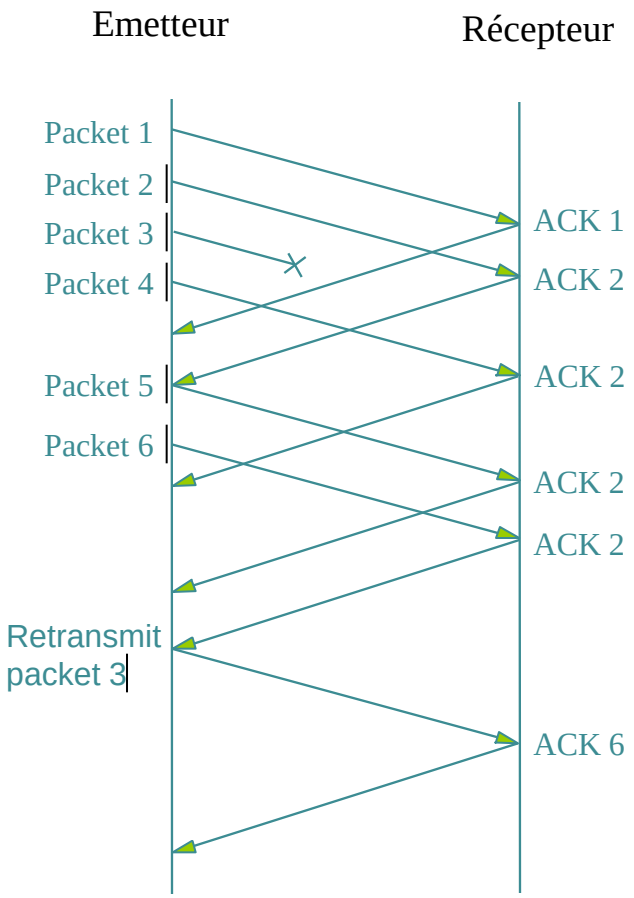

Fast Retransmit

- Envoi d'un acquittement sur réception d'un paquet
- Envoi d'une duplication du dernier acquittement quand un paquet est reçu en désordre
- Utilisation des acquittements dupliqués pour déclencher des retransmissions
  - Si 3 (ou plus) d'acquittements dupliqués reçus, le segment est considéré comme perdu
  - TCP réalise une retransmission du segment manquant sans attendre l'expiration du timer

Fast Recovery

- Fast Recovery est implémenté avec Fast Retransmit
- Fast Recovery supprime la phase de slow start après retransmission due à un Fast Retransmit
- Fast Recovery gère la transmission des données jusqu'à l'arrivée d'un ACK non dupliqué

Fast Recovery

- Algorithme :
  - Quand le 3ème ACK dupliqué est reçu,
    - positionner le seuil (ssthresh) à la moitié de la congestion window (cwnd) courante
    - retransmettre le segment manquant
    - Positionner cwnd à la valeur du ssthresh + 3*MSS
  - Chaque fois qu'un autre ACK dupliqué arrive
    - Incrémenter cwnd
    - Transmettre un paquet si possible
  - Quand ACK arrive qui acquitte la nouvelle donnée
    - Positionner cwnd à la valeur de ssthresh

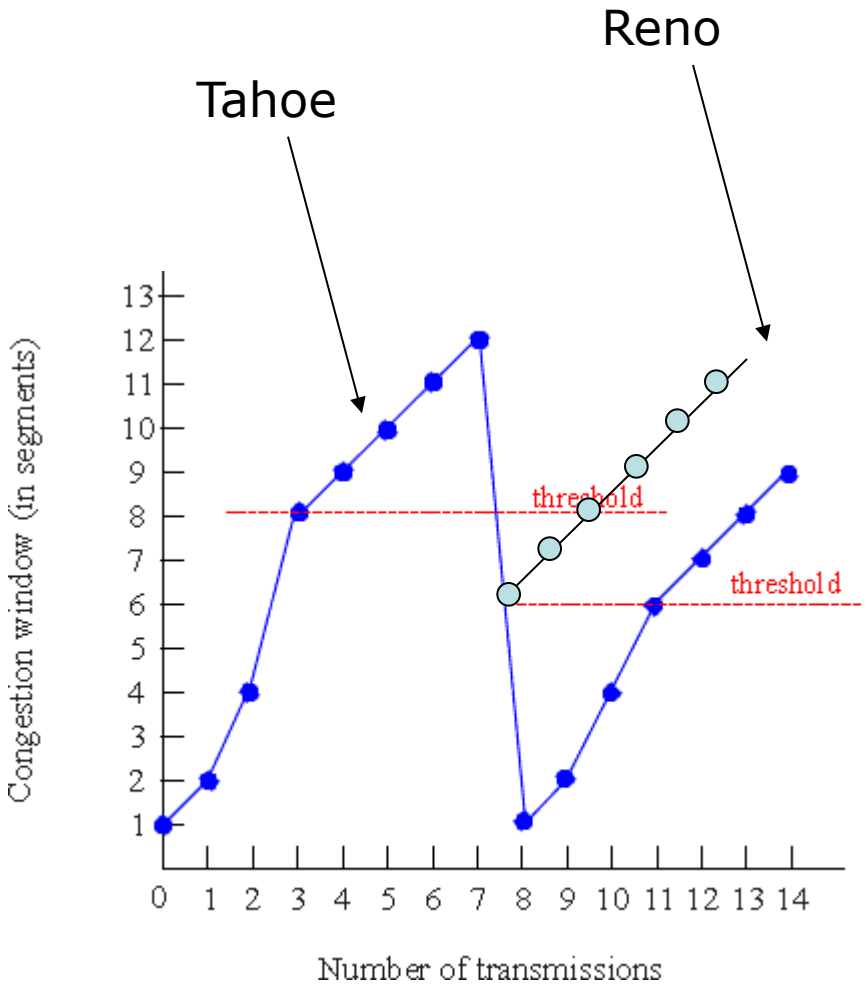
Reno
Tahoe
Congestion window (in segments)
Number of transmissions
threshold
threshold
1
2
3
4
5
6
7
8
9
10
11
12
13
0
1
2
3
4
5
6
7
8
9
10
11
12
13
14

Kurose & Ross

Résumé Congestion Control

- Essayer d'éviter que la source applique le slow-start
  - Source utilise slow-start au début et sur timeout uniquement
  - Source divise la fenêtre de congestion window de la moitié suite à un fast retransmit
- La perte d'un seul paquet peut être détectée par les mécanismes de fast retransmit/fast recovery algorithm
- La perte de plusieurs paquets consécutifs forcera la source à appliquer le slow start
    - TCP New Reno (RFC3782)

Tahoe/Reno
Timers de retransmission

- Les timers de retransmission sont basés sur les calculs du round-trip time (RTT) que TCP effectue

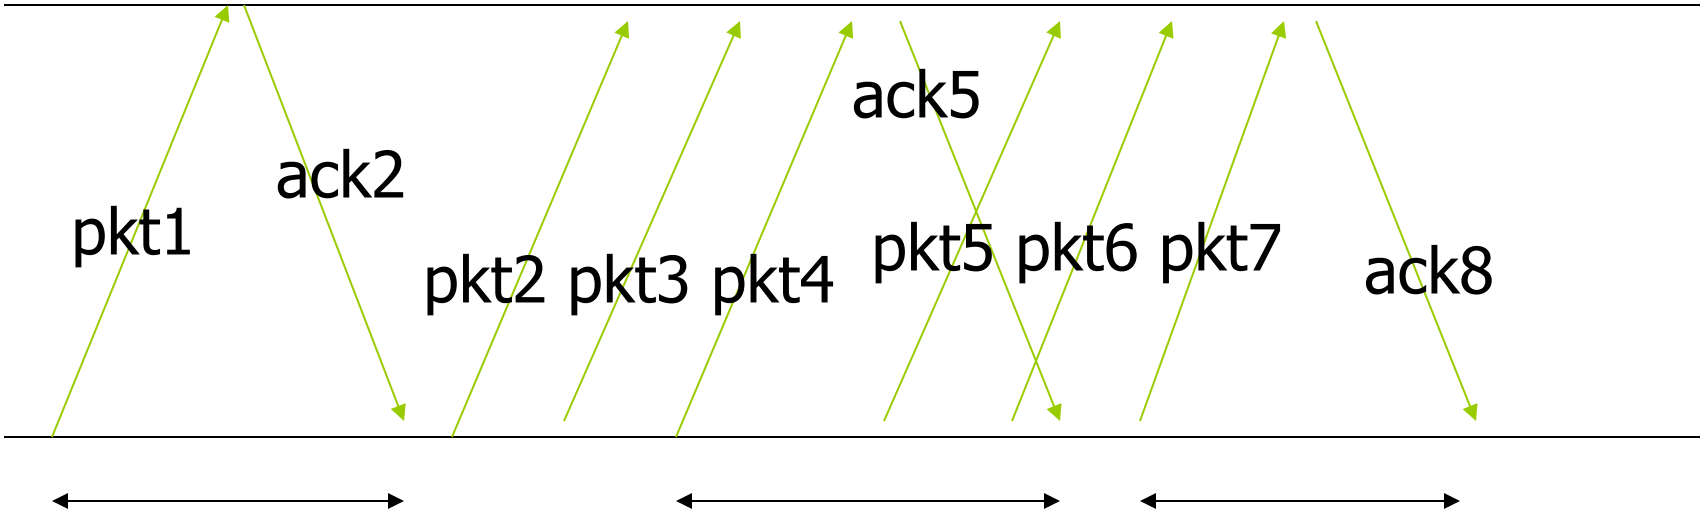

TCP Round Trip Time et Timeout

- Comment positionner le Timeout TCP ?
- Plus long que RTT
  - note: RTT va varier
- Trop court: timeout prématuré
  - Retransmissions inutiles
- Trop long: réaction lente à la perte de segments

TCP Round Trip Time et Timeout

Comment estimer RTT ?

- **SampleRTT**: temps mesuré entre l'envoi d'un segment et la réception d'un ACK

- **SampleRTT** va varier, besoin d'un RTT moyen, plus lissé
  - Utilisation de plusieurs mesures récentes, pas uniquement le **SampleRTT courant**

TCP Round Trip Time et Timeout

- Moyenne fluctuante
- L'influence d'un échantillon diminue de façon exponentielle
- Valeur typique de α: 0.125 (1/8)
- Extrait du rfc 2988

EstimatedRTT = (1-α).EstimatedRTT + α.SampleRTT

TCP Round Trip Time et Timeout

- Valeur du timeout
  - **EstimatedRTT** plus "marge de sécurité"
  - large variation dans **EstimatedRTT** → marge de sécurité accrue

RetransmissionTimeout ou RTO = EstimatedRTT + 4*Deviation

Deviation = (1-β).Deviation +

β.|SampleRTT-EstimatedRTT|

Avec β = 0.25

Problème

- Si un segment est retransmis, TCP ne peut pas calculer le RTT
  - Pourquoi ?

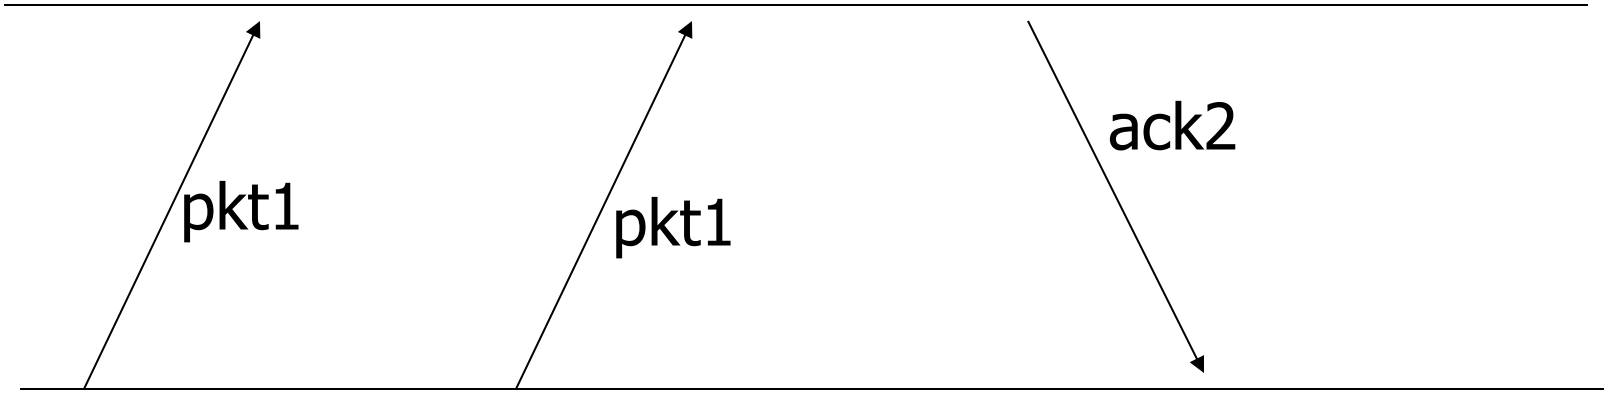

Algorithme de Karn

- Ne pas mettre à jour le RTT sur des segments qui ont été retransmis.

- Quand TCP retransmet, positionner :

  RTO = min (2 RTO, 64)

Stratégies de contrôle de congestion

- Stratégie TCP
  - Contrôle de congestion une fois détectée
  - De manière répétitive, augmente la charge pour trouver le point de congestion puis diminution de la charge quand congestion
- Stratégie alternative
  - Prédire quand la congestion va se produire
  - Réduire le débit avant que le paquet soit détruit
  - Deux possibilités :
    - Orientée routeur : mécanisme RED
    - Orientée hôte : TCP Vegas

TCP Vegas

- Vegas: Prédit et évite la congestion avant qu'elle se produise
- Tahoe, Reno: Réagit à la congestion une fois qu'elle s'est produite
- Question: comment prédire la congestion ?

Principe

- L. Brakmo, S.O'Malley et L. Peterson (SIGCOMM'94)
- Idée :
  - La source observe si des signes indiquent que les files des routeurs se remplissent et qu'une congestion risque de se produire
    - RTT augmente
    - Le débit d'émission fluctue

Observation

- L'accumulation de paquets dans le réseau peut se déduire en observant le RTT et débit en émission

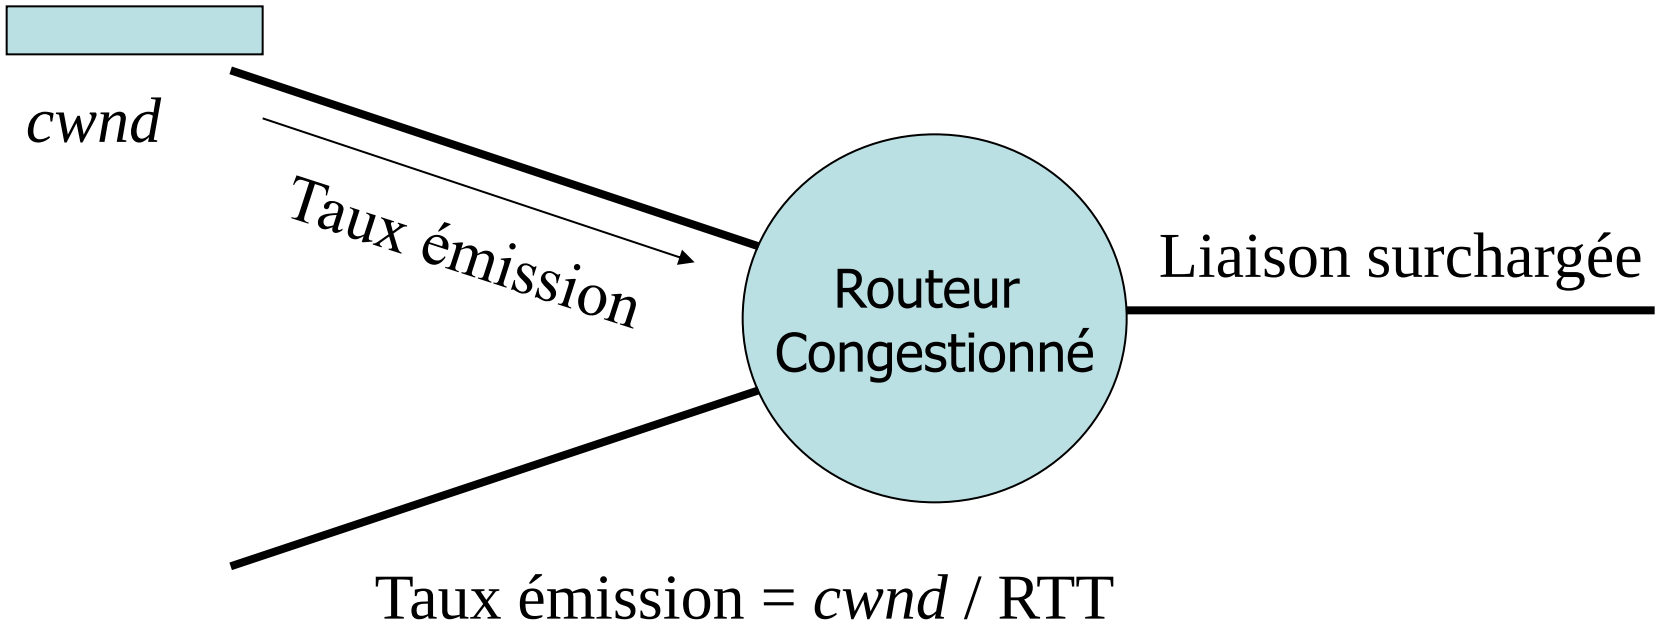

Jorg Liebherr

Algorithme

- Soit **BaseRTT** le minimum de tous les RTT mesurés (généralement RTT du premier paquet)

ExpectRate = CongestionWindow/BaseRTT

- Source calcule **ActualRate** une fois par RTT

Algorithme

- Source compare **ActualRate** avec **ExpectRate**

```
Diff = ExpectedRate - ActualRate
if Diff < a
  augmente CongestionWindow linéairement
else if Diff > b
  décroître CongestionWindow linéairement
else
  laisser CongestionWindow inchangée
```

Equité TCP

Si N sessions TCP partagent le même lien goulot d'étranglement, chacun doit avoir 1/N de la capacité du lien

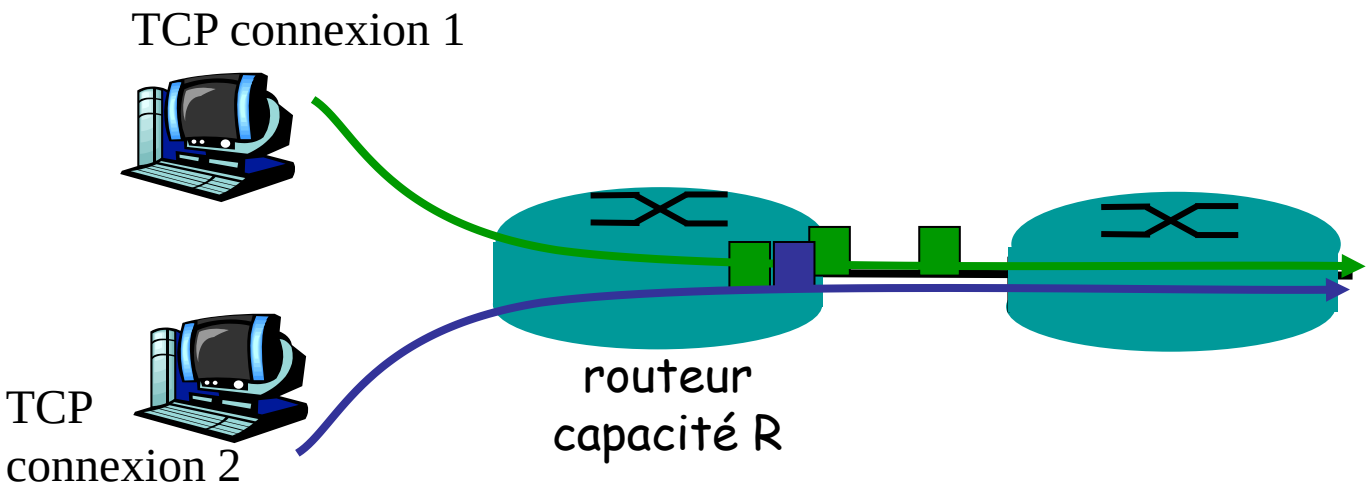

Pourquoi TCP est équitable ?

Deux sessions en compétition:

- Augmentation additive donne une pente de 1, lorsque le débit augmente
- Diminution multiplicative diminue le débit proportionnellement

Pourquoi TCP est équitable ?

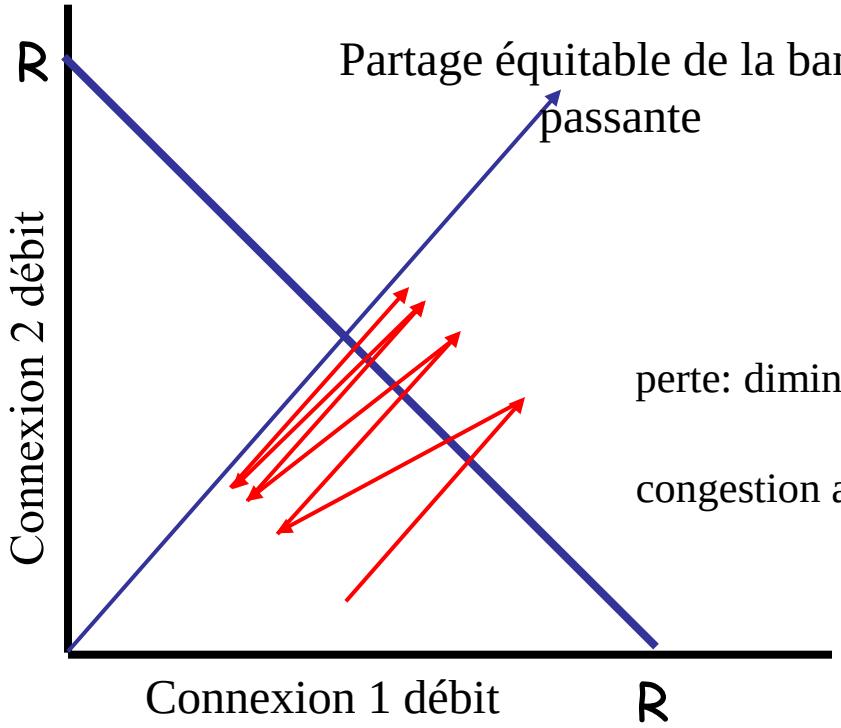

perte: diminution fenêtre par facteur de 2

congestion avoidance: augmentation linéaire

Kurose & Ross

Plan

① Contrôle de congestion et TCP

② Programmation réseaux

- socket, select(), options de socket, socket raw

③ Communication de groupe (multicast)

④ Introduction IPv6

② Programmation réseaux

- Modèle Client Serveur
- Introduction socket
- Client-Serveur TCP
- Client-Serveur UDP
- Entrée/sortie multiplexée : select
- Entrée/sortie asynchrone
- Options de socket
- Socket raw

Le modèle Client Serveur

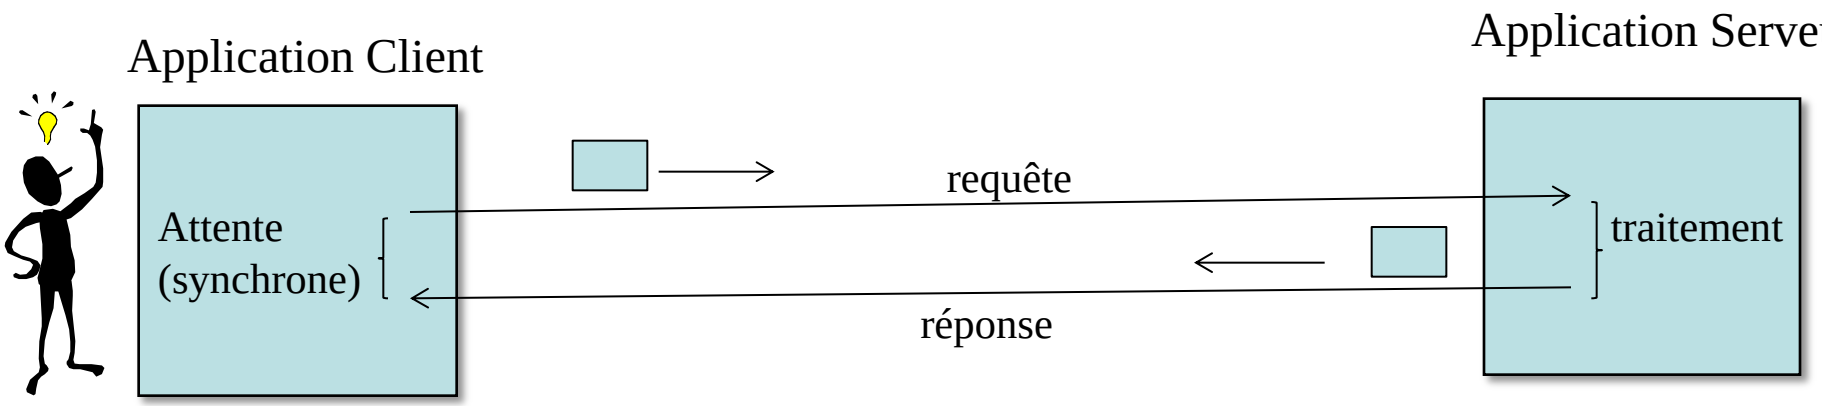

- Modèle asymétrique :
  - Le client :
    - demande l'exécution d'un service
    - est bloqué en attente de la réponse (mode synchrone)
  - Le serveur :
    - est en attente de requêtes (processus en arrière plan)
    - réalise le service demandé d'un client et envoie la réponse (traitement séquentiel ou concurrent)
    - peut gérer plusieurs clients en même temps (serveur multi-clients)

Le modèle Client Serveur

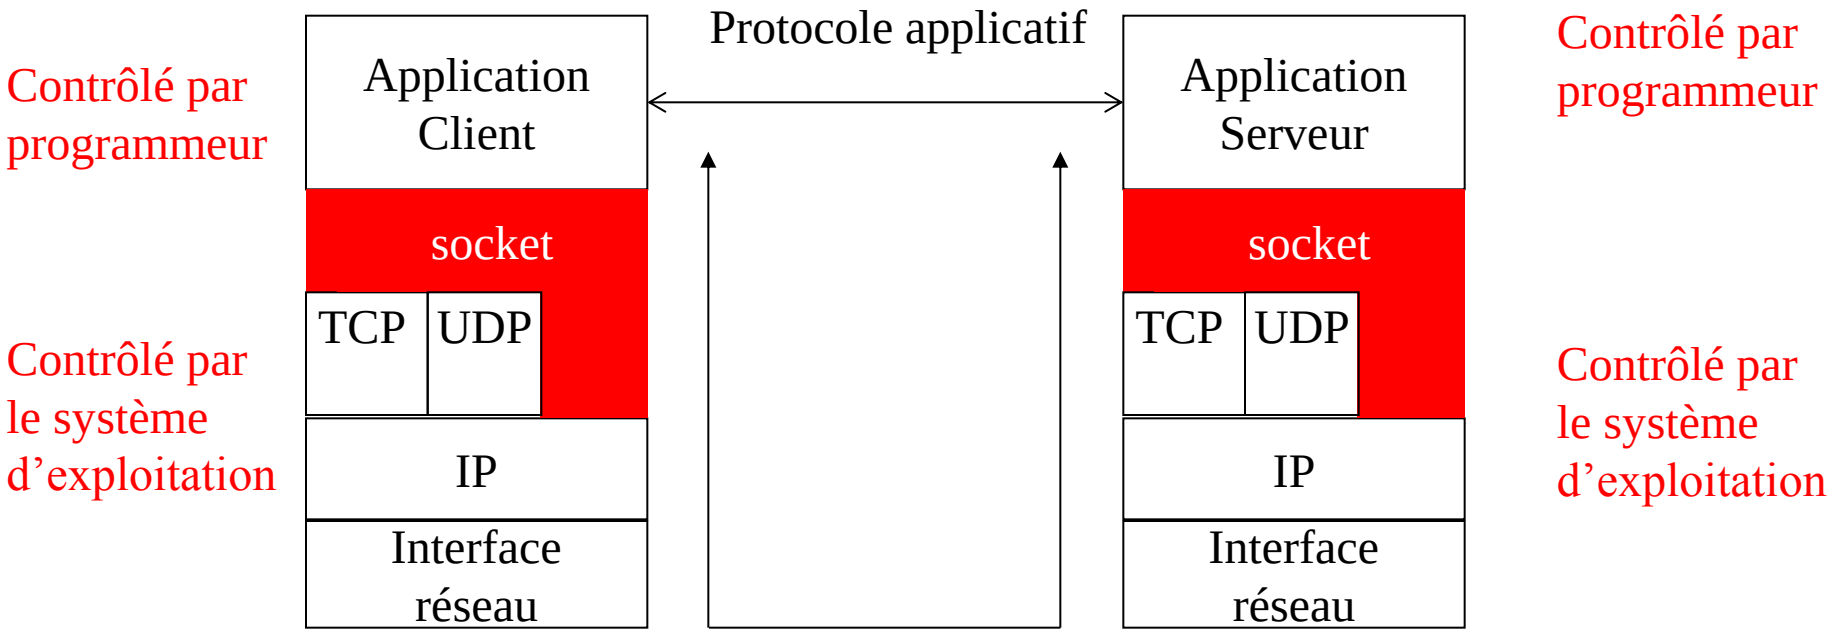

② Programmation réseaux

- Modèle client serveur
- Introduction socket
- Client-Serveur TCP
- Client-Serveur UDP
- Entrée/sortie multiplexée : select
- Entrée/sortie asynchrone
- Options de socket
- Socket raw

Définition d'un(e) socket

- Interface de programmation (API) permettant d'envoyer et recevoir des données
- Point de communication bidirectionnel
  - à l'intérieur d'une même machine ➔ domaine Unix
  - à travers les réseaux ➔ domaine Internet
- Initialement liée à la version BSD (Berkeley) de Unix
- Descripteur de socket ➔ similaire descripteur fichier (ressources système)
- Accessible par des appels systèmes

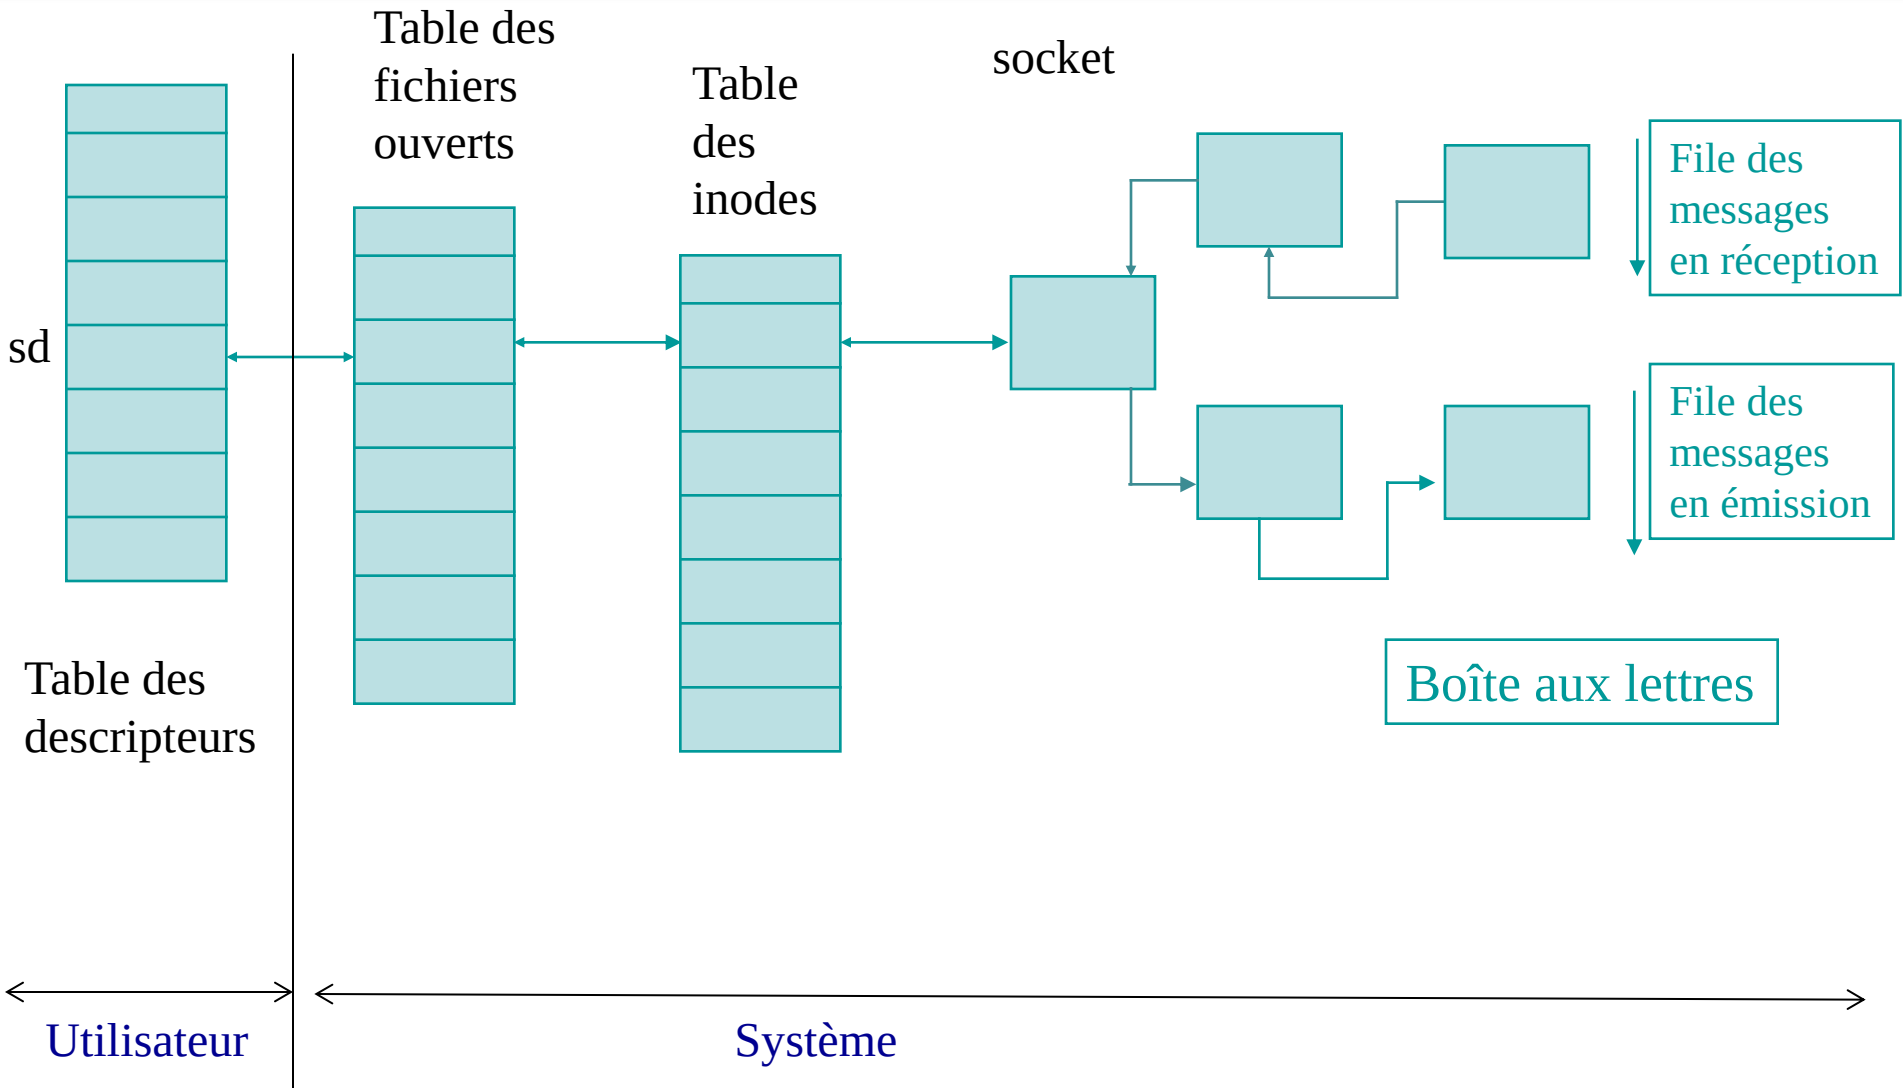
Table des fichiers ouverts
Table des inodes
socket
sd
File des messages en réception
File des messages en émission
Boîte aux lettres
Table des descripteurs
Utilisateur
Système

Les types de sockets

- Précise le type de communication utilisé
  - SOCK_STREAM
    - transmission fiable, ordonnée, sans duplication
    - en mode connecté
    - autorise messages urgents
    - pas de préservation des limites de messages
    - TCP
  - SOCK_DGRAM
  - SOCK_RAW

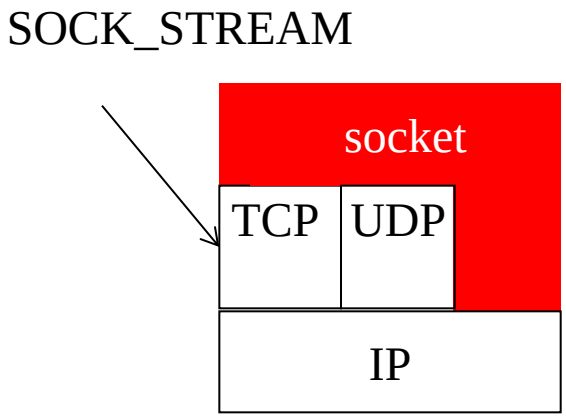

Les types de sockets

- Précise le type de communication utilisé
  - SOCK_STREAM
  - SOCK_DGRAM
    - transmission non fiable, non ordonnée, avec possibilité de duplication
    - en mode non connecté
    - préservation des limites de messages
    - UDP
  - SOCK_RAW

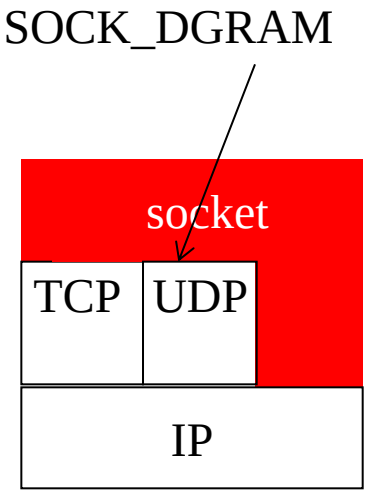

Les types de sockets

- Précise le type de communication utilisé
  - SOCK_STREAM
  - SOCK_DGRAM
  - SOCK_RAW
    - protocoles de bas niveau (super-user)
    - permet de ne pas passer par la couche transport et d'utiliser IP directement
    - ICMP

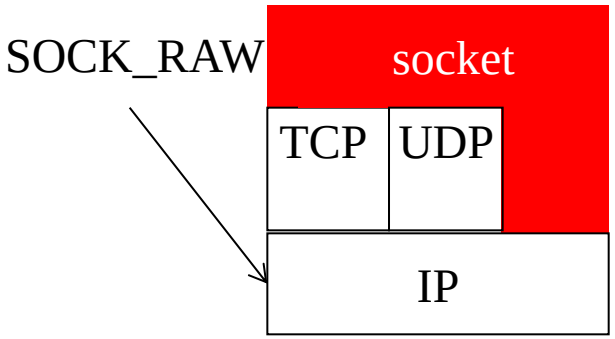

Les familles de sockets

- Une famille ou un domaine définit :
  - La convention d'adressage ou format des adresses à utiliser
  - Le ou les protocoles réseaux supportés
- AF_UNIX (AF_LOCAL)
  - Local à la machine : domaine UNIX
- AF_INET
  - Domaine Internet et adresses IPv4
- AF_INET6
  - Domaine Internet et adresses IPv6

Structure générique d'une socket

Format général décrit dans
<sys/socket.h>

```
struct sockaddr {
    uint8_t sa_len;
    sa_family_t sa_family;
    char s_data[14];
}
```

sa_len ➔longueur de la structure

sa_family ➔ AF_UNIX ou AF_INET,….

s_data ➔ jusqu'à 14 octets pour décrire l'adresse spécifique au protocole

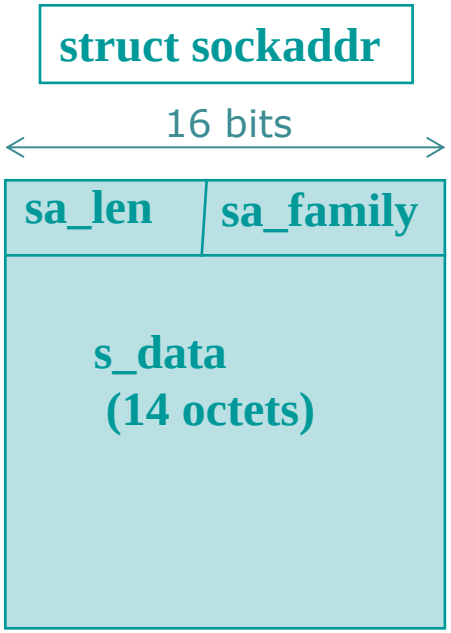

Structure spécifique d'une socket

- Format spécifique au protocole de communication

struct sockaddr_xx {
}

- xx est un suffixe unique fonction du protocole
  xx = **in** pour Internet (IPv4)
  in6 pour Internet (IPv6)
  un pour Unix

Structure dans le domaine UNIX

Format décrit dans **<sys/un.h>**

```
struct sockaddr_un {
    uint8_t sun_len;
    sa_family_t  sun_family;
    char sun_path[104];
}
```

sun_family ➔ AF_UNIX

sun_path ➔ /* chemin = nom de fichier */

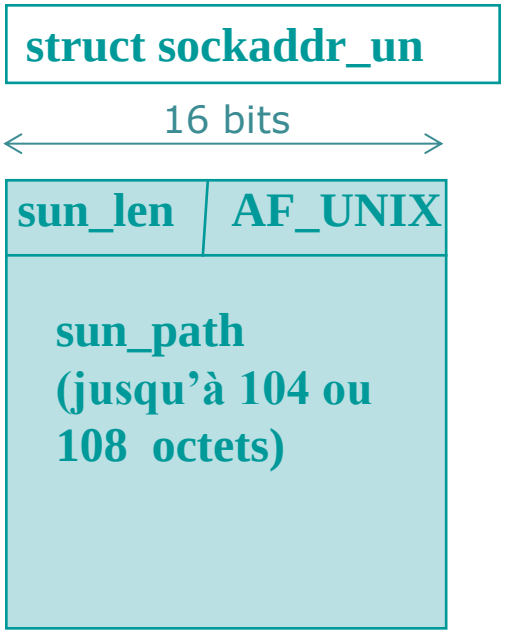

Structure dans le domaine INET

Format décrit dans <**netinet/in.h**>

```
struct sockaddr_in {
    uint8_t sin_len;
    sa_family_t sin_family;
    in_port_t sin_port;
    struct in_addr  sin_addr;
    char    sin_zero[8];
 }
```

```
struct in_addr {
    in_addr_t s_addr;
}
typedef uint32_t in_addr_t;
```

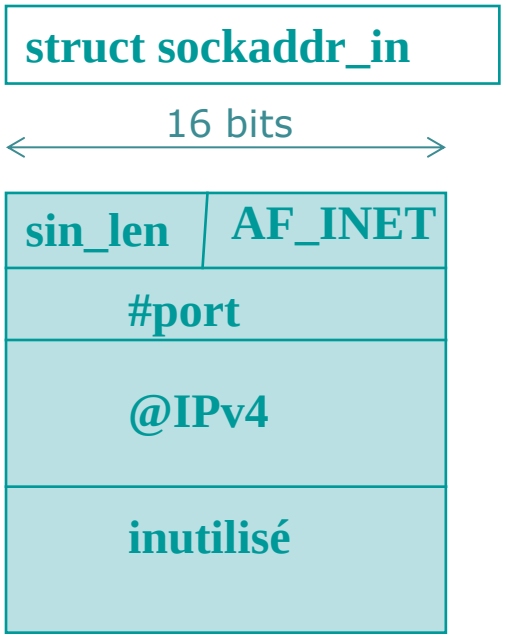

sin_family ➔ AF_INET

sin_port ➔ numéro sur 16 bits dans **l'ordre du réseau (network byte ordered)**

sin_addr ➔ adresse Internet sur 32 bits dans **l'ordre du réseau**

sin_zero ➔ inutilisé (doit être mis à zéro)

Structure dans le domaine INET

Numéro de port

- Identifie de manière unique, sur une machine, un processus exécutant un service donné
  - Il existe des ports prédéfinis (cf **/etc/services**)
    - serveur web : port 80
    - serveur mail : port 25
    - appel de la fonction **getservbyname()**
  - Le port peut être choisi par le programmeur d 'application >= IPPORT_RESERVED (1024)
  - Le port peut être attribué par le système **(sin_port ←0)**

Structure dans le domaine INET

Numéro de port – fonction getservbyname()

#include <netdb.h>

struct servent * **getservbyname** (const char *name, const char *proto)

name ➔ pointeur sur la chaîne décrivant le nom du service

proto ➔ pointeur sur la chaîne où se trouve le nom du protocole (tcp)

valeur de retour -1 si erreur

```
struct servent{
        char *s_name; /* nom  du service*/
        char **s_aliases; /* liste alias */
        int s_port; /* numéro port (ordre réseau)*/
        int s_proto ; /* protocole utilisé */
        }
```

Structure dans le domaine INET

Adresse IP

- Identifie de manière unique une machine sur un réseau
  - soit obtenue par les fonctions :
    - **gethostbyname(), gethostbyname2() getipnodebyname(), getaddrinfo()**
  - dans le cas d'un programme serveur la valeur INADDR_ANY est choisie : les messages peuvent être reçus sur n'importe quelle interface réseau
- Exprimée sur la forme ddd.ddd.ddd.ddd
  - exemple : 193.54.8.4
  - Dans la structure ➔entier format réseau

Structure dans le domaine INET
Adresse IP – fonction gethostbyname()

#include <netdb.h>

struct hostent ***gethostbyname*** (const char *name)

name ➔ pointeur sur la chaîne où se trouve le nom du système

valeur de retour -1 si erreur

```
struct hostent{
        char *h_name; /* nom machine*/
        char **h_aliases; /* liste alias */
        int h_addrtype; /* type famille */
        int h_length ; /* longueur adresse */
        char **h_addr_list; /* liste adresses */
#define h_addr h_addr_list[0]
    }
```

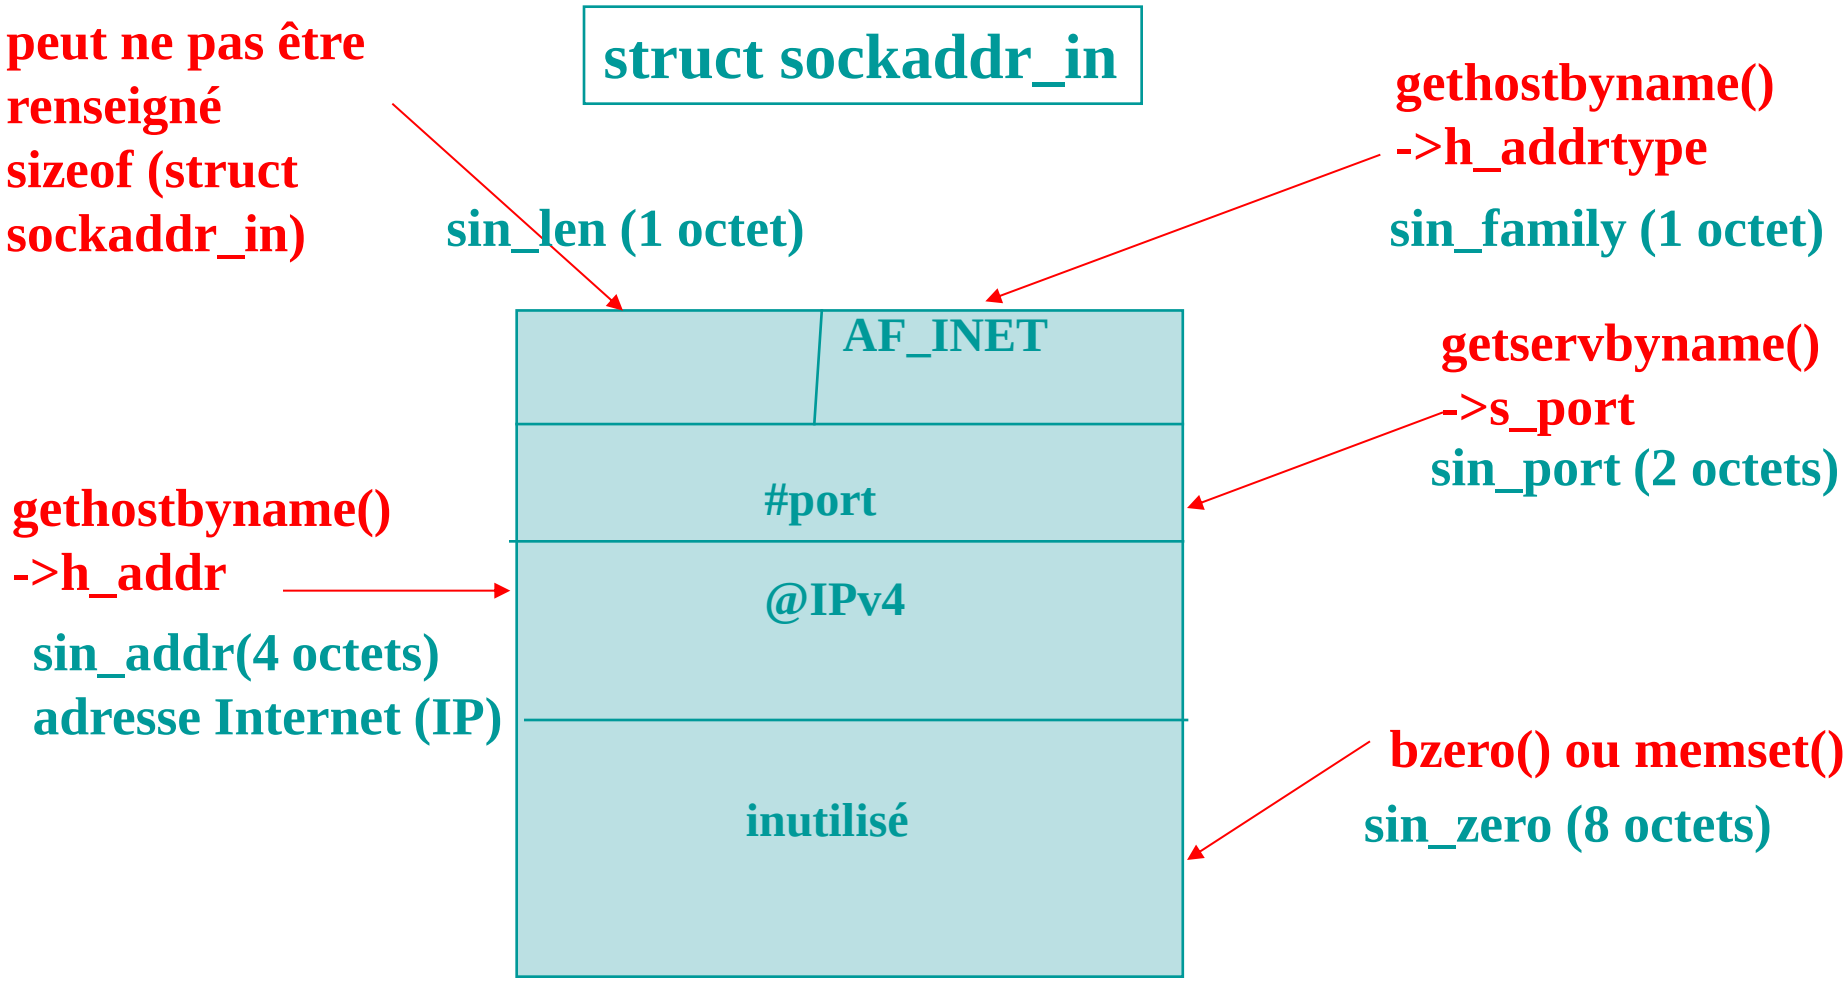
struct sockaddr_in
peut ne pas être renseigné
sizeof (struct sockaddr_in)
sin_len (1 octet)
gethostbyname()
->h_addrtype
sin_family (1 octet)
AF_INET
#port
@IPv4
inutilisé
getservbyname()
->s_port
sin_port (2 octets)
gethostbyname()
->h_addr
sin_addr(4 octets)
adresse Internet (IP)
bzero() ou memset()
sin_zero (8 octets)

Structure dans le domaine INET

Format de représentation des données

- Les machines hôtes stockent les données (entiers) dans un format
  - Little endian
  - Big endian
- Pour communiquer il faut un format de transfert des données
  - *network byte order :* **big endian**

Structure dans le domaine INET

Fonctions d'ordonnancement des octets (Byte Ordering Functions)

```
#include <arpa/inet.h>
uint16_t htons  (uint16_t host16bitvalue);
uint32_t htonl  (uint32_t host32bitvalue);
```

retournent une valeur dans l'ordre du réseau

```
uint16_t ntohs (uint16_t net16bitvalue);
uint32_t ntohl  (uint32_t net32bitvalue);
```

retournent une valeur dans l'ordre de la machine hôte

Structure dans le domaine INET

Fonctions de manipulation d'octets

```
#include <strings.h>
void bzero  (void *dest, size_t nbytes) ;
void bcopy  (const void *src,  void * dest,  size_t nbytes) ;
int bcmp  (const void *ptr1, const void *ptr2, size_t nbytes );
```

retourne 0 si égal

Fonctions obsolètes

```
#include <string.h>
void *memset   (void *dest, int c, size_t len) ;
void *memcpy  (void *dest,  const void *src,  size_t nbytes) ;
int  memcmp  (const void *ptr1, const void *ptr2, size_t nbytes );
```

retourne 0 si égal

Structure dans le domaine INET

Fonctions de manipulation d'adresses

```
#include <arpa/inet.h>
int inet_aton (const char *strptr, struct in_addr *addrptr) ;
```

retourne 1 si string valide 0 sinon

```
in_addr_t  inet_addr (const char *srcptr)  ;
```

retourne une valeur de 32 bits ordonnée réseau sinon INADDR_NONE

```
char *inet_ntoa  (struct in_addr inaddr) ;
```

retourne un pointeur vers une chaîne contenant une adresse IP « aaa.bbb.ccc.ddd »

```
int inet_pton(af, src, dst)
    int af;             /* AF_INET ou AF_INET6 */
    const char *src;    /* l'adresse (chaine de caract.) à traiter */
    void *dst;          /* le tampon où est rangé le résultat */
const char * inet_ntop(af, src, dst, size)
    int af;             /* AF_INET ou AF_INET6 */
    const void *src;    /* l'adresse binaire à traiter */
    char *dst;          /* le tampon où est rangé le résultat */
    socklen_t size;     /* la taille de ce tampon */
```

```
struct sockaddr_in  serv_addr;
Struct hostent *hp;


bzero( (&serv_addr, sizeof(serv_addr) );
memset (&serv_addr, 0, sizeof(serv_addr) );
serv_addr.sin_port = htons ((ushort) atoi(argv[2]));
hp = (struct hostent *)gethostbyname (argv[1]);
if (hp == NULL) {
    fprintf(stderr, "%s: %s non trouve dans in /etc/hosts ou dans le DNS\n",
            argv[0], argv[1]);
    exit(1);
}
serv_addr.sin_family = hp->h_addrtype ; /* AF_INET */
serv_addr.sin_addr = * ((struct in_addr *)(hp->h_addr));
printf ("IP address: %s\n", inet_ntoa (serv_addr.sin_addr));
```

② Programmation réseaux

- Modèle client serveur
- Introduction socket
- Client-Serveur TCP
- Client-Serveur UDP
- Entrée/sortie multiplexée : select
- Entrée/sortie asynchrone
- Options de socket
- Socket raw

Dialogue Client-Serveur TCP

Création de socket

Ouverture de dialogue

Echange de données

Fermeture de socket

Type de Dialogue TCP/IP

- transmission fiable , ordonnée, sans duplication
- en mode connecté
- autorise messages urgents
- pas de préservations de limites de messages

Mode de communication TCP/IP (SOCK_STREAM)

Transmission Control Protocol/Internet Protocol

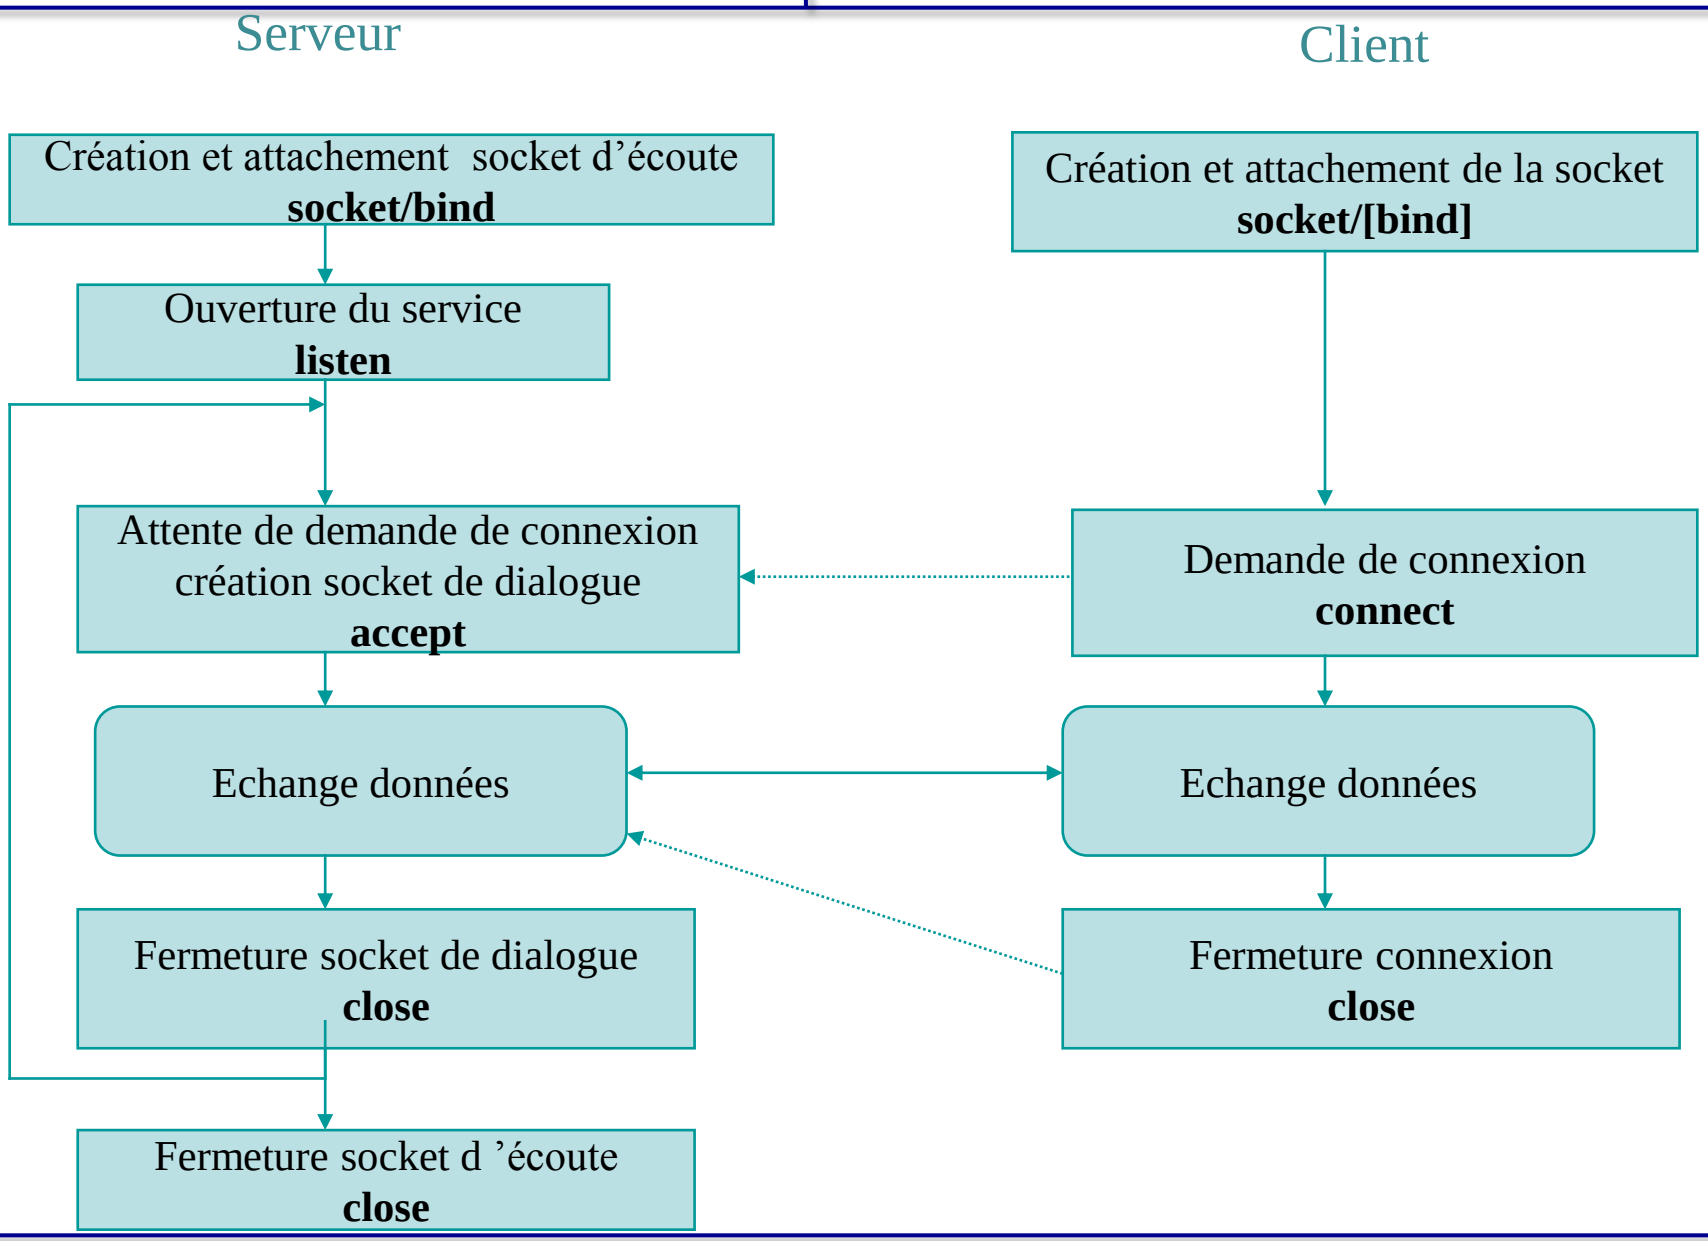
Serveur
Client
Création et attachement socket d'écoute
socket/bind
Création et attachement de la socket
socket/[bind]
Ouverture du service
listen
Attente de demande de connexion
création socket de dialogue
accept
Demande de connexion
connect
Echange données
Echange données
Fermeture socket de dialogue
close
Fermeture connexion
close
Fermeture socket d 'écoute
close

Création d'une socket (C/S)

#include <sys/types.h>
#include <sys/socket.h>
int **socket** (int domain, int type, int protocol)

domain ➔ [AF_UNIX ou AF_INET]
➔ PF_UNIX ou PF_INET
type ➔ SOCK_STREAM
protocol ➔ 0 par défaut
valeur de retour ➔-1 si erreur sinon descripteur de socket

```
int serverSocket;
/*
  * Ouvrir socket (socket STREAM)
  */
 if ((serverSocket = socket(PF_INET,
SOCK_STREAM, 0)) <0) {
    perror ("erreur socket");
    exit (1);
 }
```

Attachement/nommage d'une socket (C/S)

- Association entre une socket et une adresse

```
#include <sys/types.h>
#include <sys/socket.h>
int bind (int s, const struct sockaddr
*name, socklen_t  addrlen)
```

s ➔ descripteur retourné par socket()
name ➔ pointeur sur une structure contenant l'adresse Internet
addrlen ➔longueur de l'adresse
valeur de retour ➔ -1 si erreur

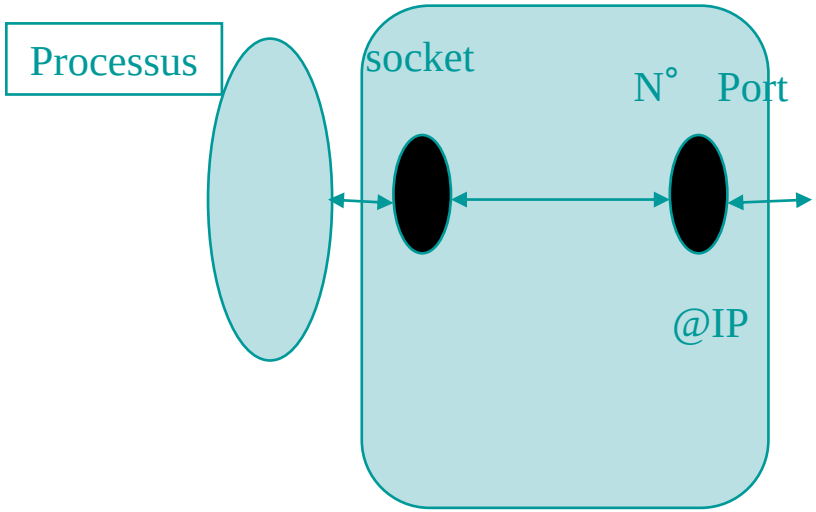

Bind : ceci est mon adresse et tous les messages reçus sur cette adresse doivent m'être délivrés

Si la machine a plusieurs adresses IP, lors du bind on pourra utiliser INADDR_ANY

```
#define SERV_PORT 2222
struct sockaddr_in  serv_addr;

/*
  * Lier l'adresse  locale à la socket
  */;
  memset (&serv_addr, 0, sizeof(serv_addr) );
  serv_addr.sin_family = AF_INET ;
  serv_addr.sin_addr.s_addr = htonl(INADDR_ANY);
  serv_addr.sin_port = htons(SERV_PORT);

  if (bind(serverSocket,(struct sockaddr *)&serv_addr, sizeof (serv_addr) ) <0) {
   perror ("servecho: erreur bind\n");
   exit (1);
  }
```

Ouverture du service (S)

- Utilisé par le **serveur** en mode connecté pour indiquer qu'il est prêt à recevoir des demandes de connexion
- Après cet appel, seuls des paquets d'ouverture de connexion seront reçus sur ce socket

```
#include <sys/socket.h>
int listen (int s, int backlog)
```

s ➔descripteur retourné par socket()

backlog ➔ nombre de connexions simultanément en attente de traitement

valeur de retour ➔-1 si erreur

```
/* Paramétrer le nombre de connexion "pending" */
 if (listen(serverSocket, SOMAXCONN) <0) {
    perror ("servecho: erreur listen\n");
    exit (1);
 }
```

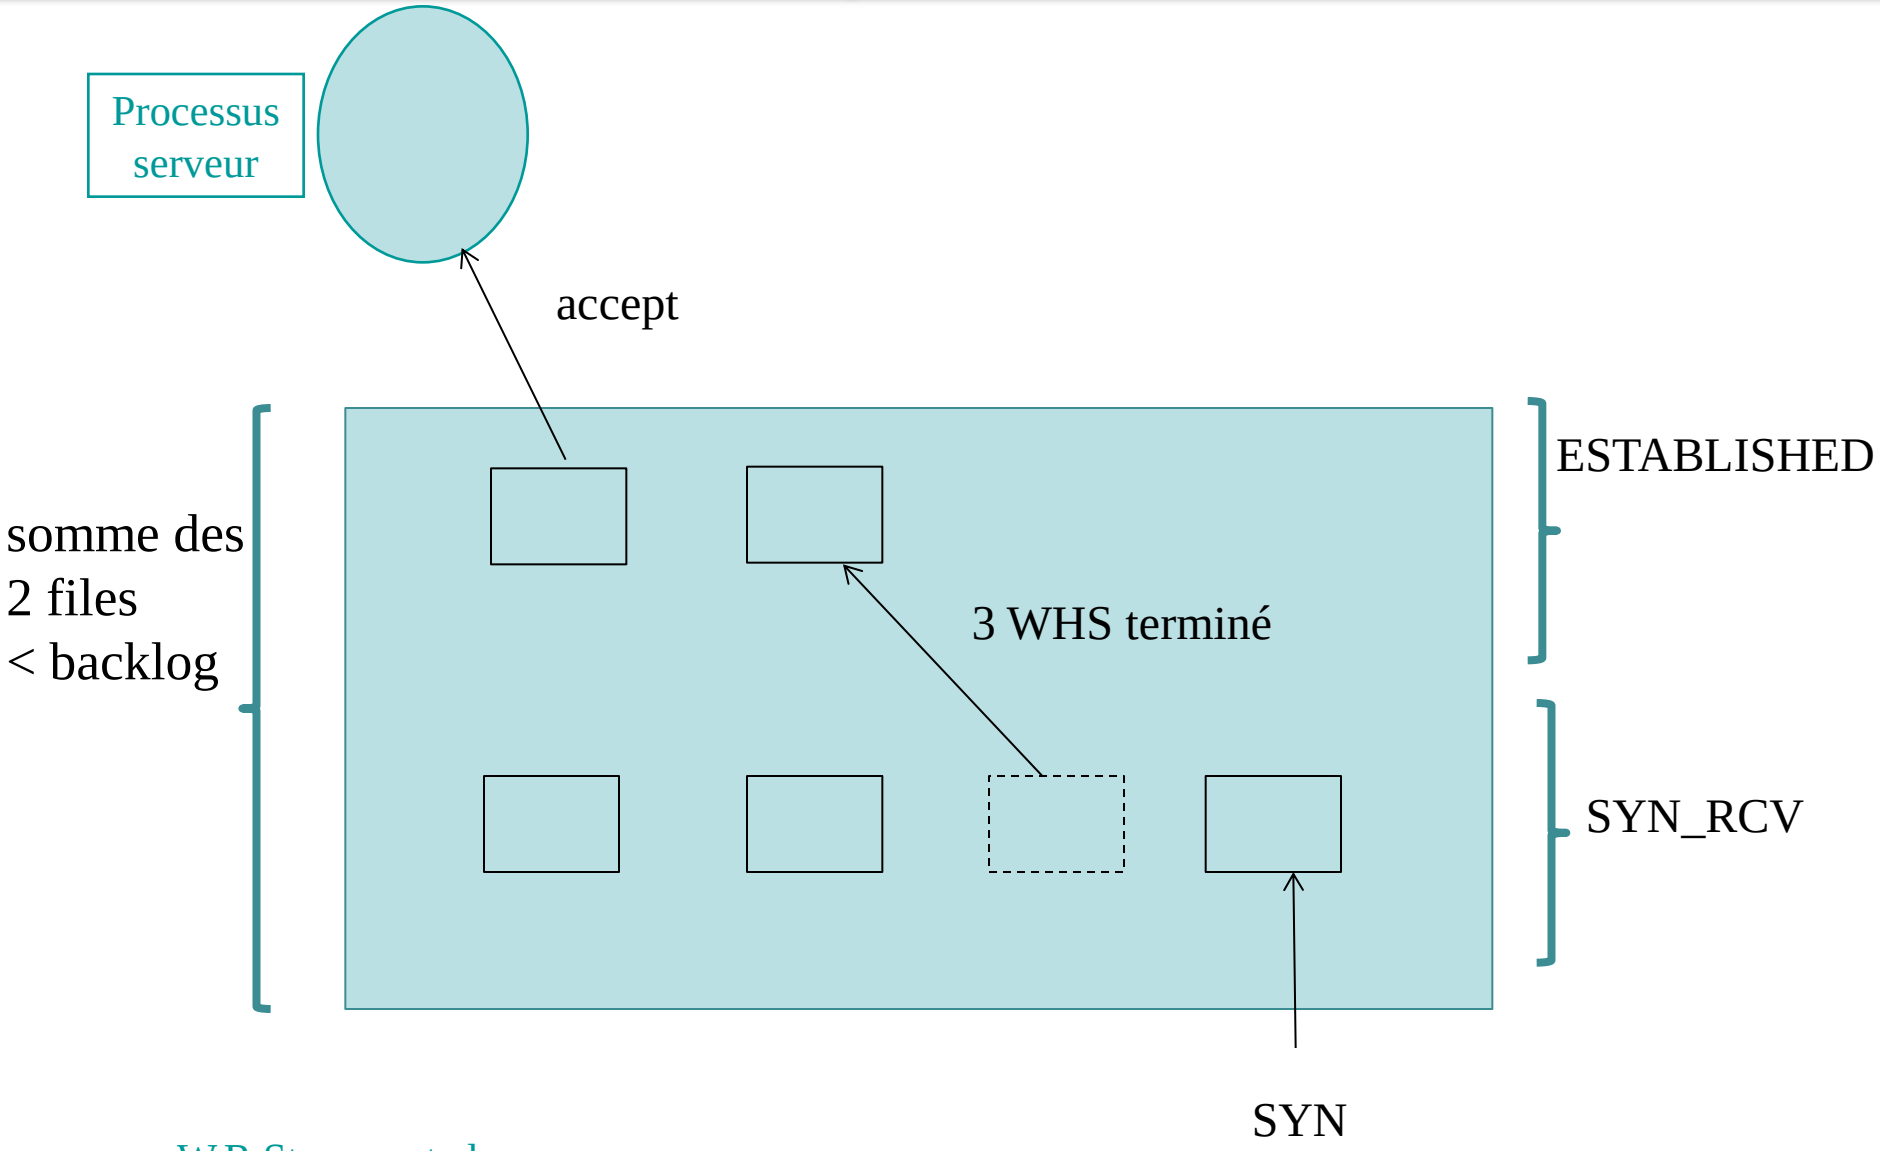

W.R Stevens et al.

Création d'une socket de dialogue (S)

- Crée une nouvelle socket qui servira au dialogue entre l'appelant et l'entité en attente de traitement de la connexion

```
#include <sys/types.h>
#include <sys/socket.h>
int accept (int s, struct sockaddr *peer,
      socklen_t *addrlen)
```

s ➔ descripteur retourné par socket()

peer ➔ pointeur sur l'adresse du client qui a initié la connexion

addrlen ➔pointeur sur la taille allouée pour peer

valeur de retour ➔-1 si erreur

```
int  dialogSocket;
int  clilen,;
struct sockaddr_in cli_addr;

clilen = sizeof(cli_addr);

dialogSocket = accept(serverSocket,
      (struct sockaddr *)&cli_addr,
      (socklen_t *)&clilen);

if (dialogSocket < 0) {
 perror("servecho : erreur accep\n");
 exit (1);
}
```

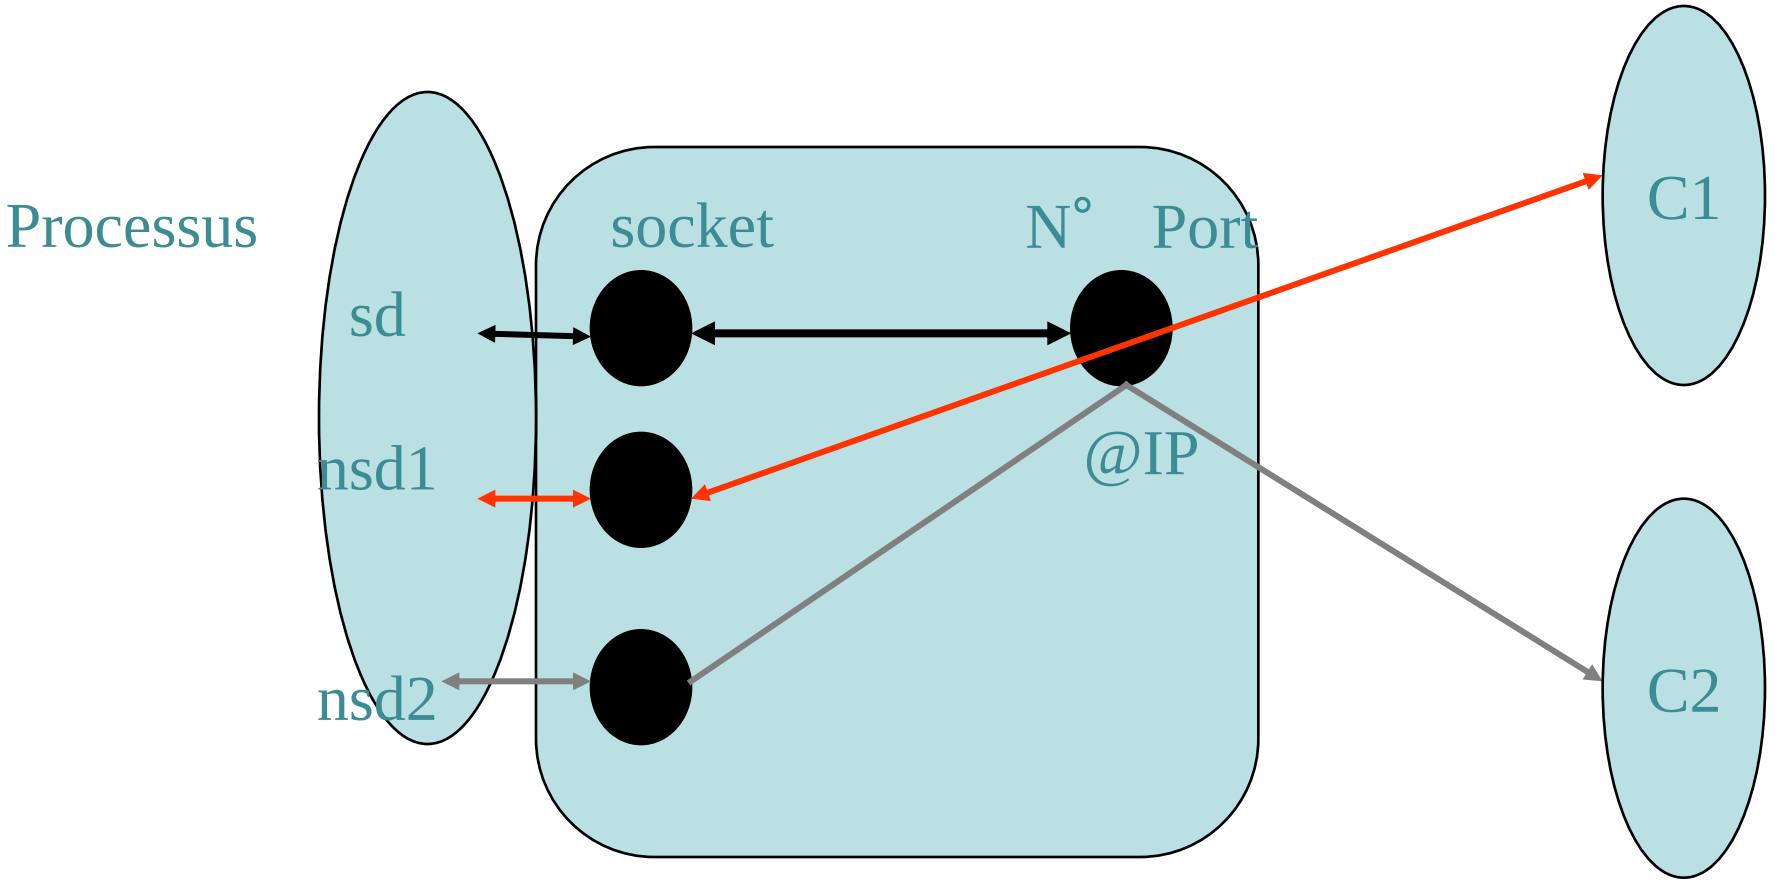
Processus
socket
N° Port
sd
nsd1
nsd2
@IP
C1
C2

Demande de connexion (C)

- Utilisée par un **client** (en mode connecté en général) pour établir une connexion avec un serveur distant
- Pendant cette phase : négociation des paramètres du protocole TCP/IP
- Bloque l'appelant jusqu'à l'établissement de la connexion ou la génération d'une erreur
- L'établissement de connexion permet de débloquer le serveur

Demande de connexion (C)

```
#include <sys/types.h>
#include <sys/socket.h>
int connect (int s, struct sockaddr
    *servaddr, socklen_t addrlen)
```

s ➔ descripteur retourné par socket()

servaddr ➔ pointeur sur l'adresse du serveur vers lequel initié la connexion

addrlen ➔longueur de l'adresse

valeur de retour ➔ -1 si erreur

```
struct sockaddr_in  serv_addr;

/*
 * Remplir la structure  serv_addr avec l'adresse du serve
 */
bzero( (char *) &serv_addr,          sizeof(serv_addr) );
serv_addr.sin_family = AF_INET;
serv_addr.sin_port = htons((ushort) atoi(argv[2]));
serv_addr.sin_addr.s_addr = inet_addr (argv[1]);

if (connect (sockfd, (struct sockaddr *) &serv_addr,
sizeof(serv_addr) ) < 0){
 perror ("cliecho : erreur connect");
 exit (1);
}
```

Dialogue - échange données (C/S)

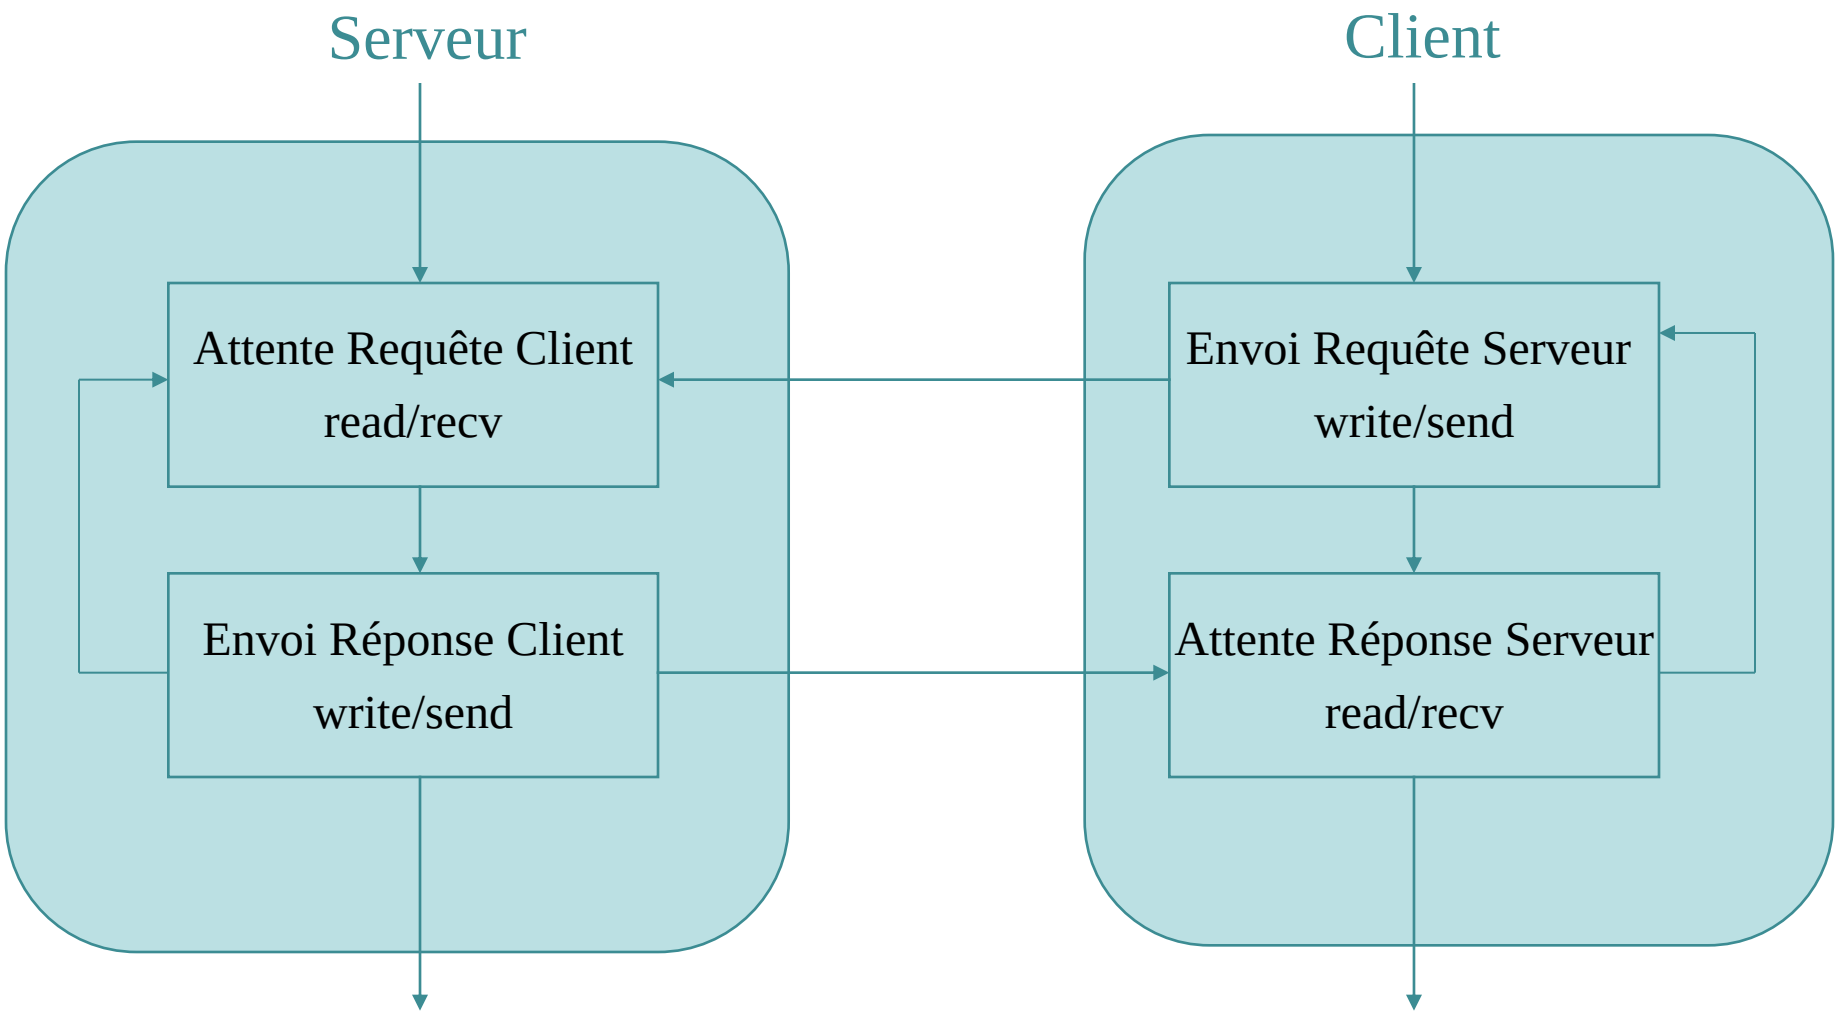

Dialogue - échange de données (C/S)

- send/recv : appels système proches du read() et write() qui peuvent aussi être utilisés pour les sockets

```
#include <sys/types.h>
#include <sys/socket.h>
ssize_t  send (int s, const void *buff, size_t nbytes, int flags)
ssize_t recv (int s, void *buff, size_t nbytes, int flags)
```

s ➔ descripteur retourné par accept()
buff ➔pointeur sur le buffer où doit être stocké le message à émettre/recevoir
nbytes ➔ longueur du message

flags ➔ combinaison logique des trois valeurs suivantes :

- MSG_OOB données urgentes
- MSG_PEEK lecture (sans suppression) de données entrantes
- MSG_DONTROUTE transmission sans routage

valeur de retour ➔ longueur effectivement envoyée/reçue ou -1 si erreur

Fermeture d'une socket (C/S)

- Libération des ressources système

#include <unistd.h>

int **close** (int s)

s ➔ descripteur de socket
valeur de retour ➔-1 si erreur sinon
descripteur de socket

#include <unistd.h>

int **shutdown** (int s, int how)

s ➔ descripteur de socket
how ➔ 0 fermeture en réception
1 fermeture en émission
2 fermeture en émission/réception
valeur de retour ➔1 si erreur sinon
descripteur de socket

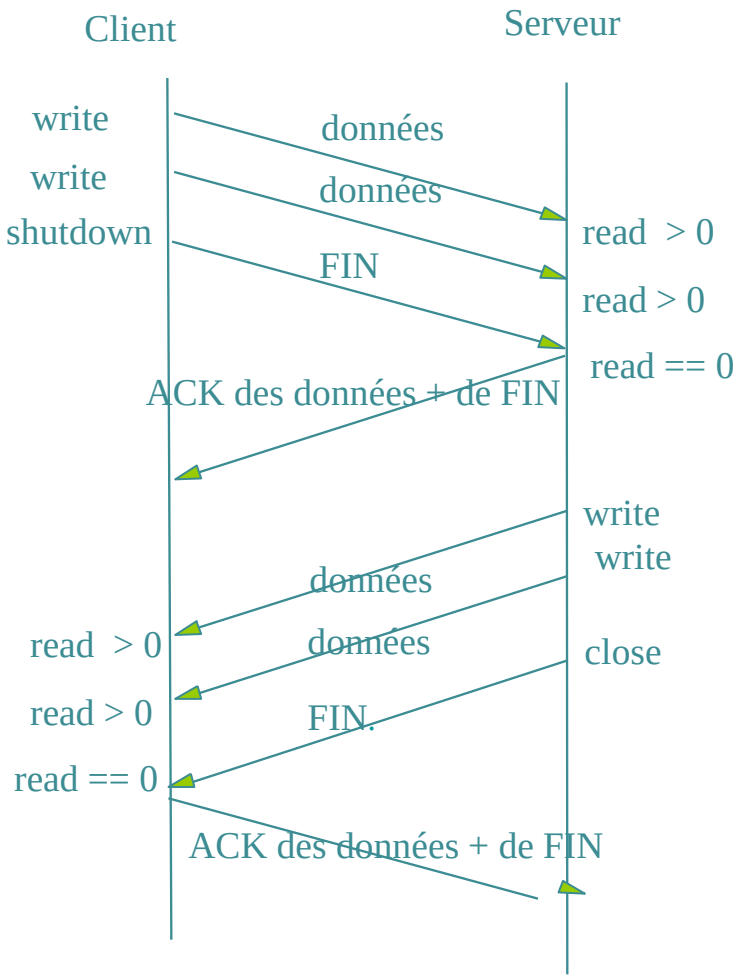

W.R Stevens et al.

Serveur multi-clients ?

- Un serveur capable de traiter plusieurs clients à la fois

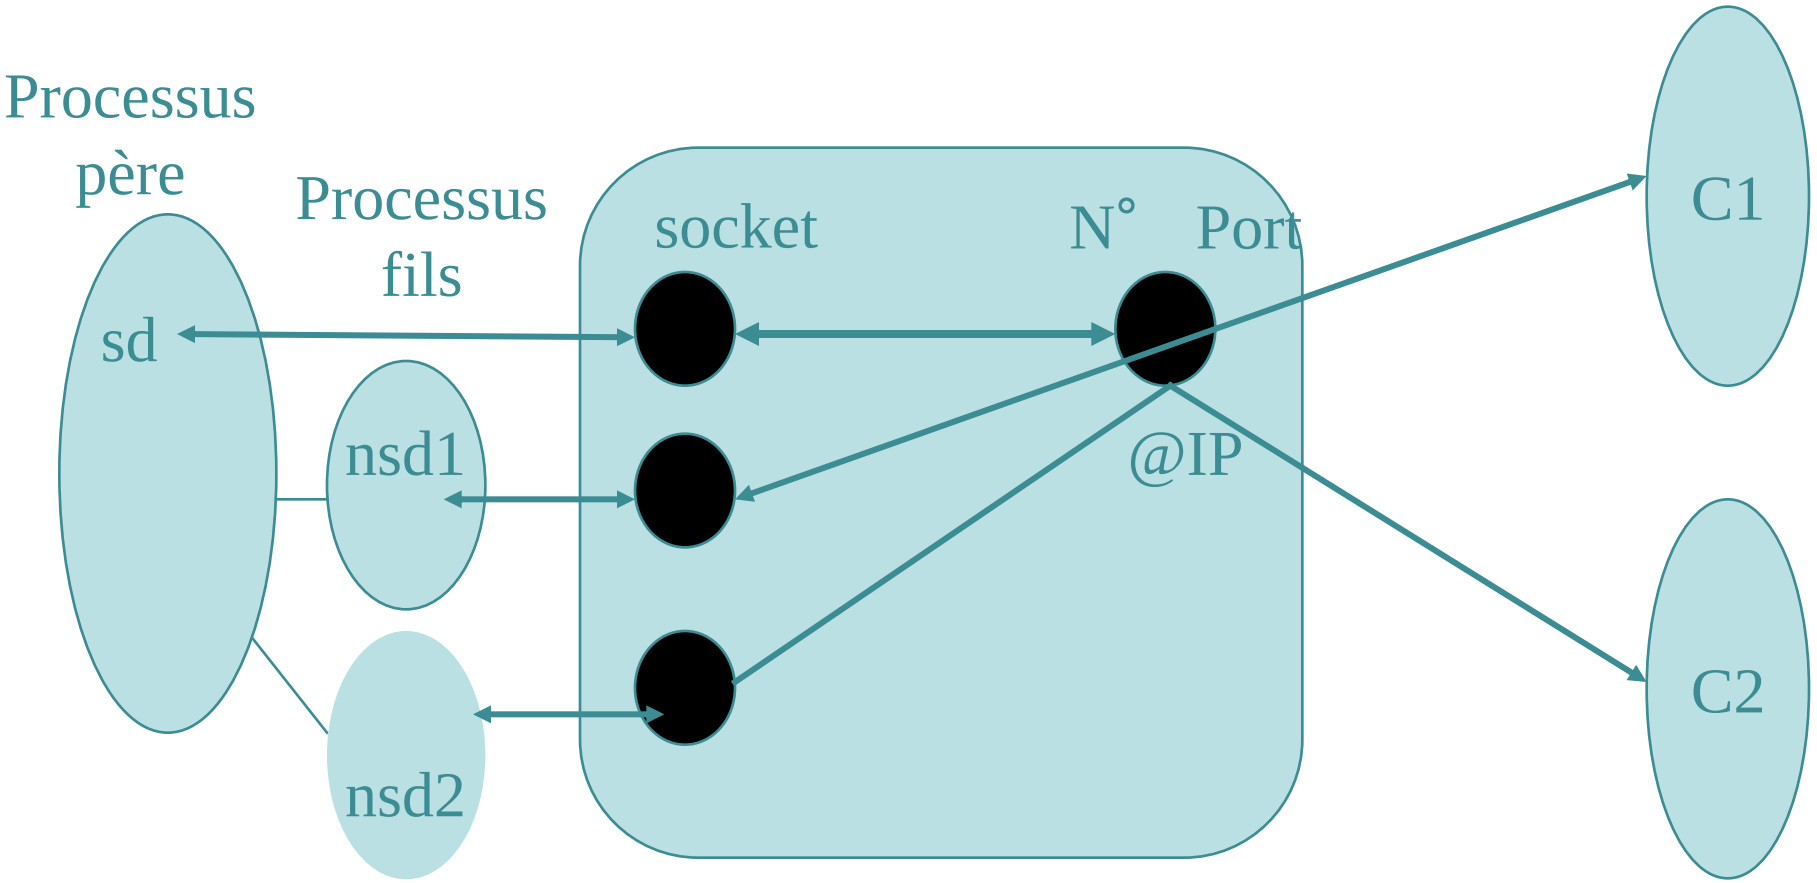

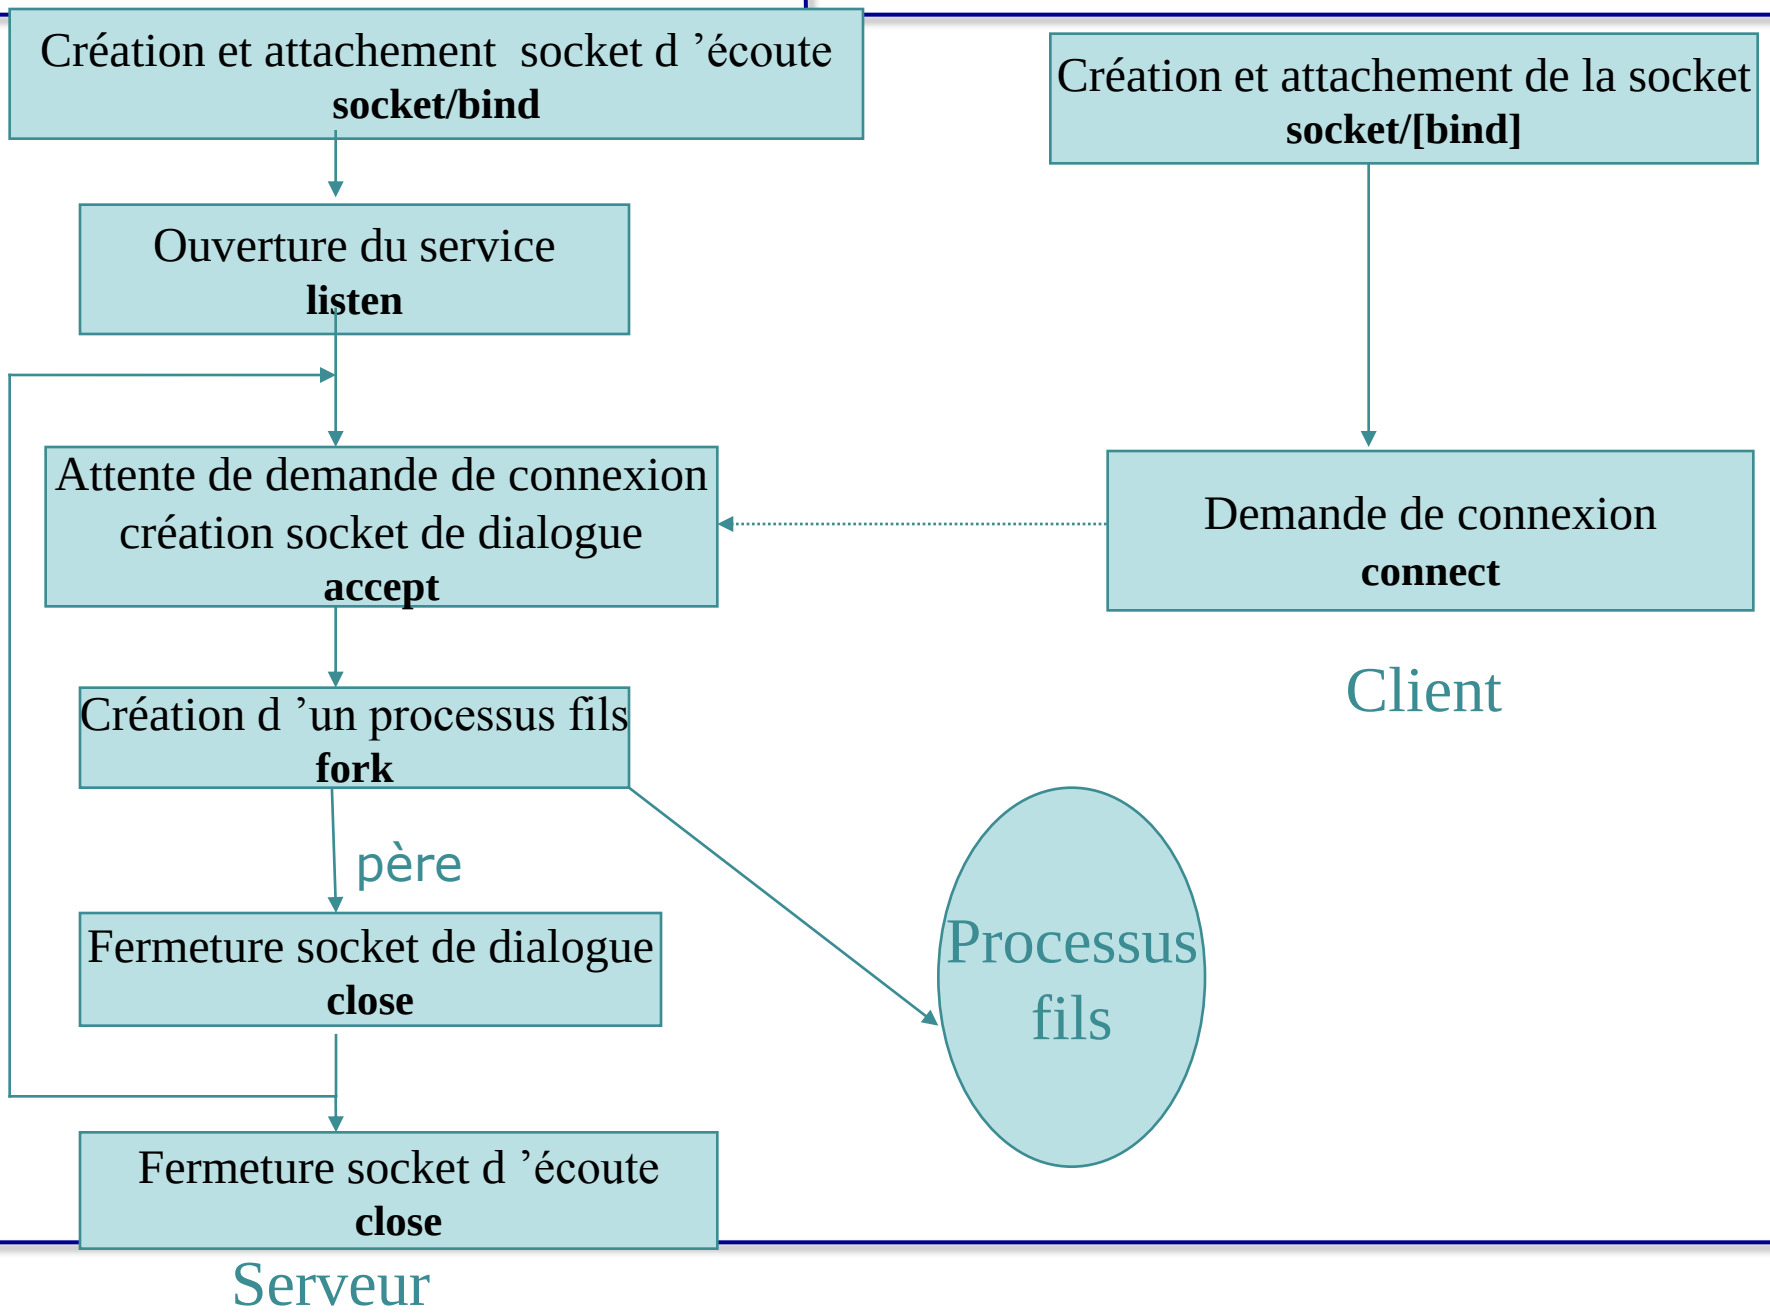
Création et attachement socket d 'écoute
socket/bind
Ouverture du service
listen
Attente de demande de connexion
création socket de dialogue
accept
Création d 'un processus fils
fork
père
Fermeture socket de dialogue
close
Fermeture socket d 'écoute
close
Serveur
Création et attachement de la socket
socket/[bind]
Demande de connexion
connect
Client
Processus
fils

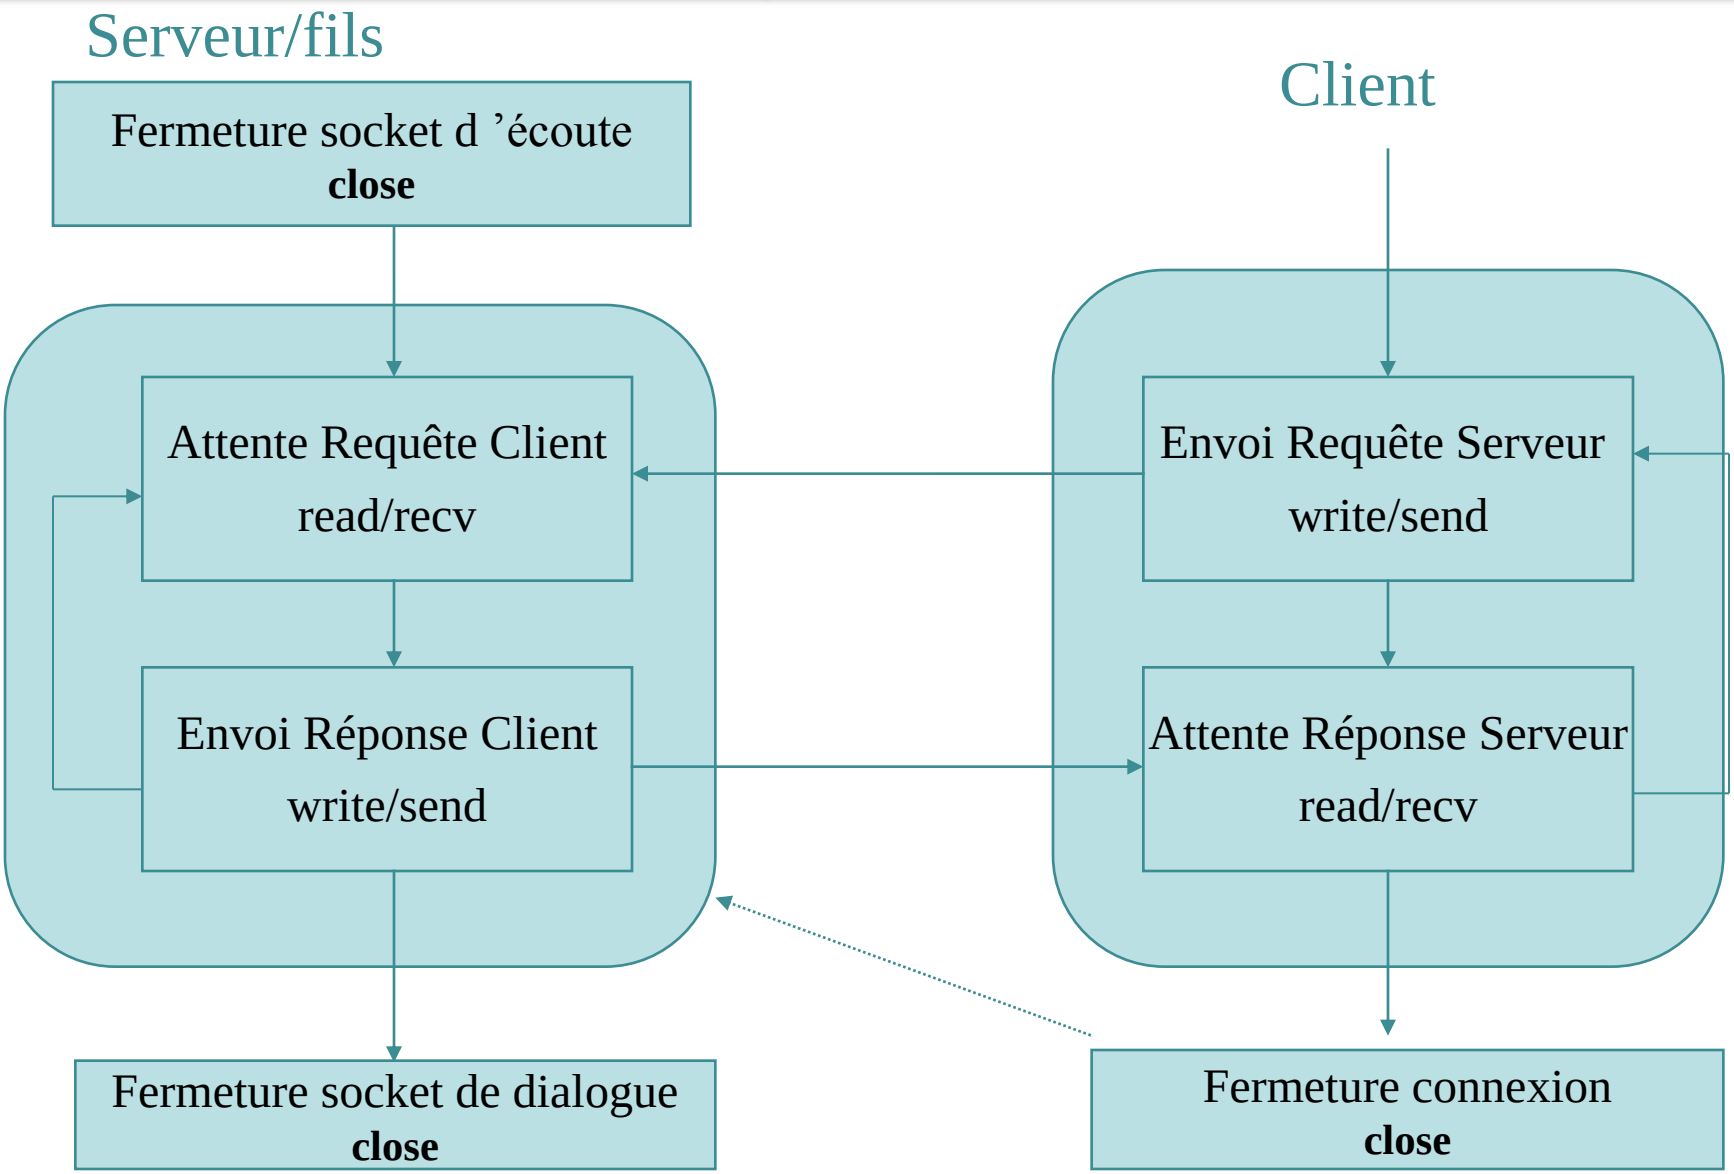
Serveur/fils
Client
Fermeture socket d 'écoute
close
Attente Requête Client
read/recv
Envoi Réponse Client
write/send
Envoi Requête Serveur
write/send
Attente Réponse Serveur
read/recv
Fermeture socket de dialogue
close
Fermeture connexion
close

Scénario serveur concurrent

```
int sockfd, newsockfd;

if ( (sockfd = socket(..)) < 0) {
  perror("probleme ouverture socket");
  exit(1);
}
if bind (sockfd, …) <0) {
   perror("probleme bind");
   exit(1);
}
if listen (sockfd, 5) <0) {
   perror("probleme listen");
   exit(1);
}
for(;;){
   if ( (newsockfd = accept (sockfd,…)) < 0) {
        perror("probleme accept");
        exit(1);
    }
    switch ( fork()) {
                  case -1 : perror("probleme fork");
                  exit(1);
        case 0 : close (sockfd);              /* fils */
                 traiter_requête(newsockfd);
                 close (newsockfd);
                 exit(0);
        default : close(newsockfd);           /* pere*/
    } /* end of switch */
} /* end of for */
```

② Programmation réseaux

- Modèle client serveur
- Introduction socket
- Client-Serveur TCP
- Client-Serveur UDP
- Entrée/sortie multiplexée : select
- Entrée/sortie asynchrone
- Options de socket
- Socket raw

Type de Dialogue – UDP/IP

- transmission non fiable
- en mode non connecté
- N'autorise pas les messages urgents
- préservations de limites de messages

Mode de communication UDP/IP (SOCK_DGRAM)

User Datagram Protocol/Internet Protocol

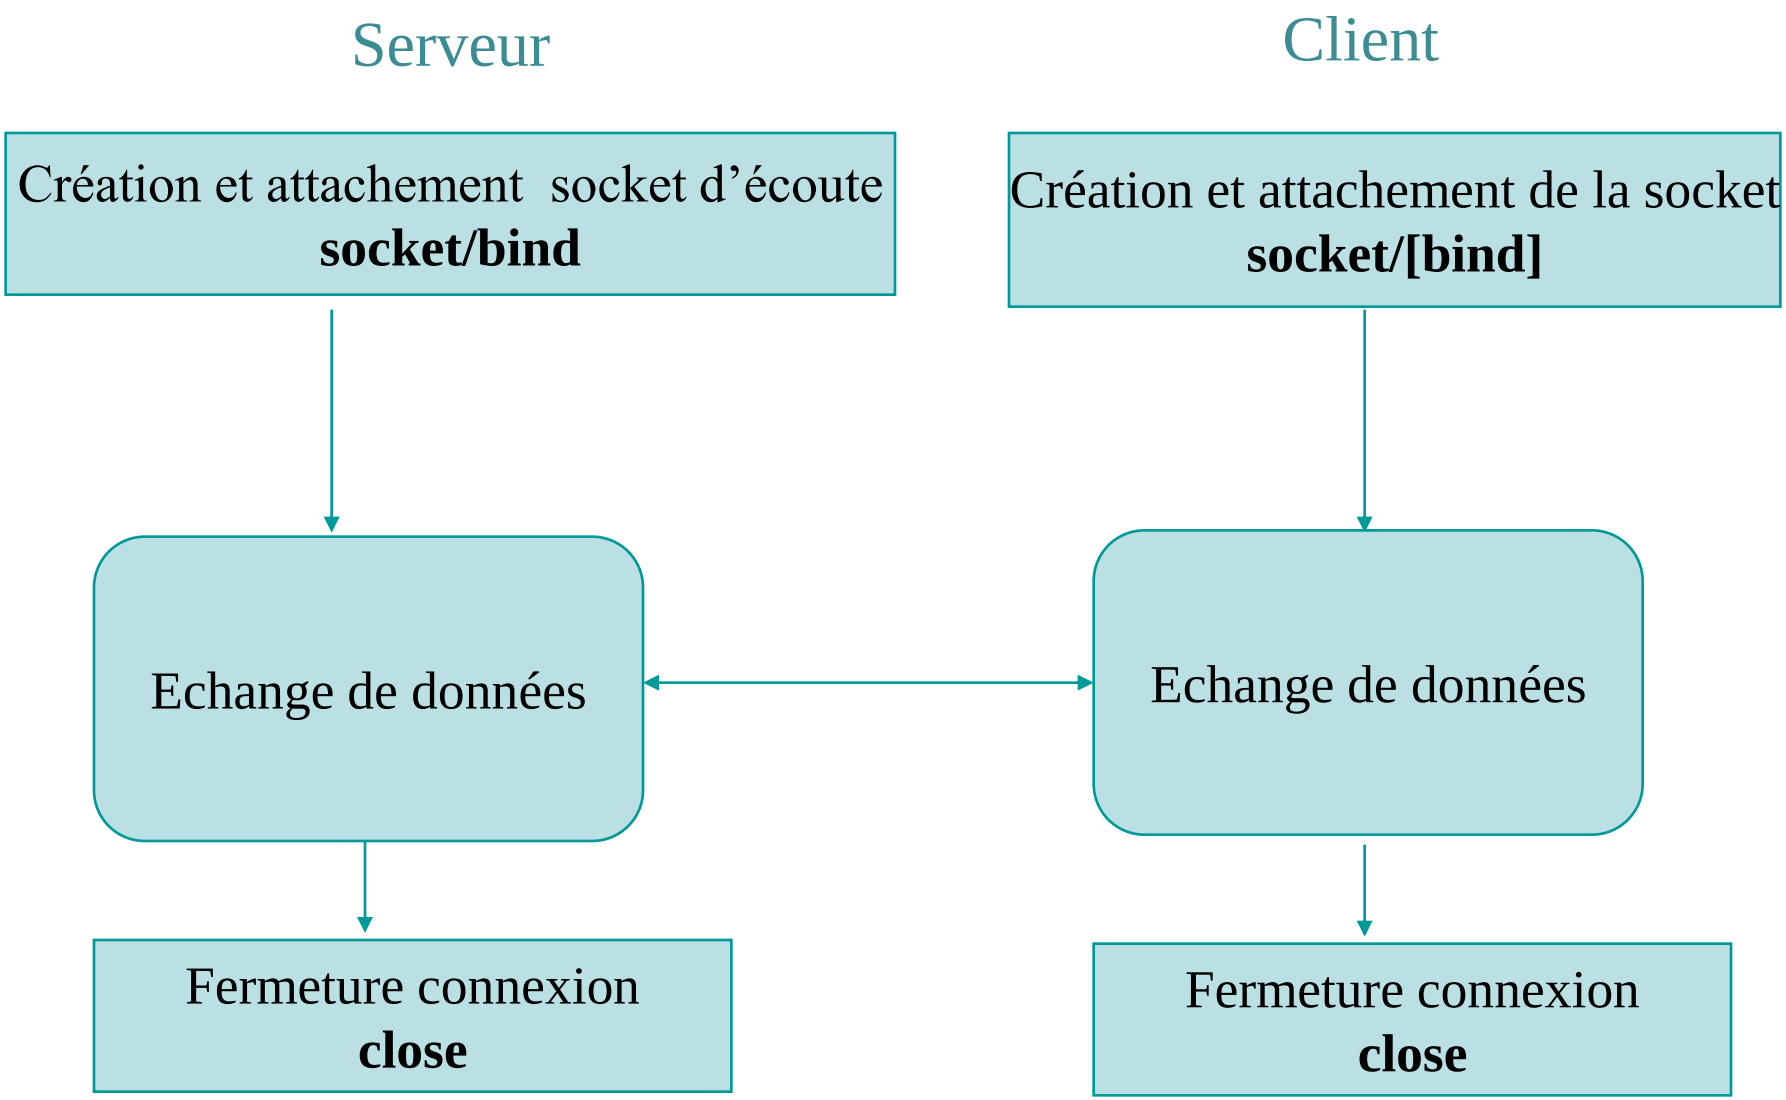
Serveur
Client
Création et attachement socket d'écoute
socket/bind
Création et attachement de la socket
socket/[bind]
Echange de données
Echange de données
Fermeture connexion
close
Fermeture connexion
close

Création d'une socket (C/S)

```
#include <sys/types.h>
#include <sys/socket.h>
```

int **socket** (int domain, int type, int protocol)

domain ➔ [AF_INET]/PF_INET

type ➔ SOCK_DGRAM

protocol ➔ 0 par défaut

valeur de retour ➔ -1 si erreur sinon descripteur de socket

Dialogue - échange données (C/S)

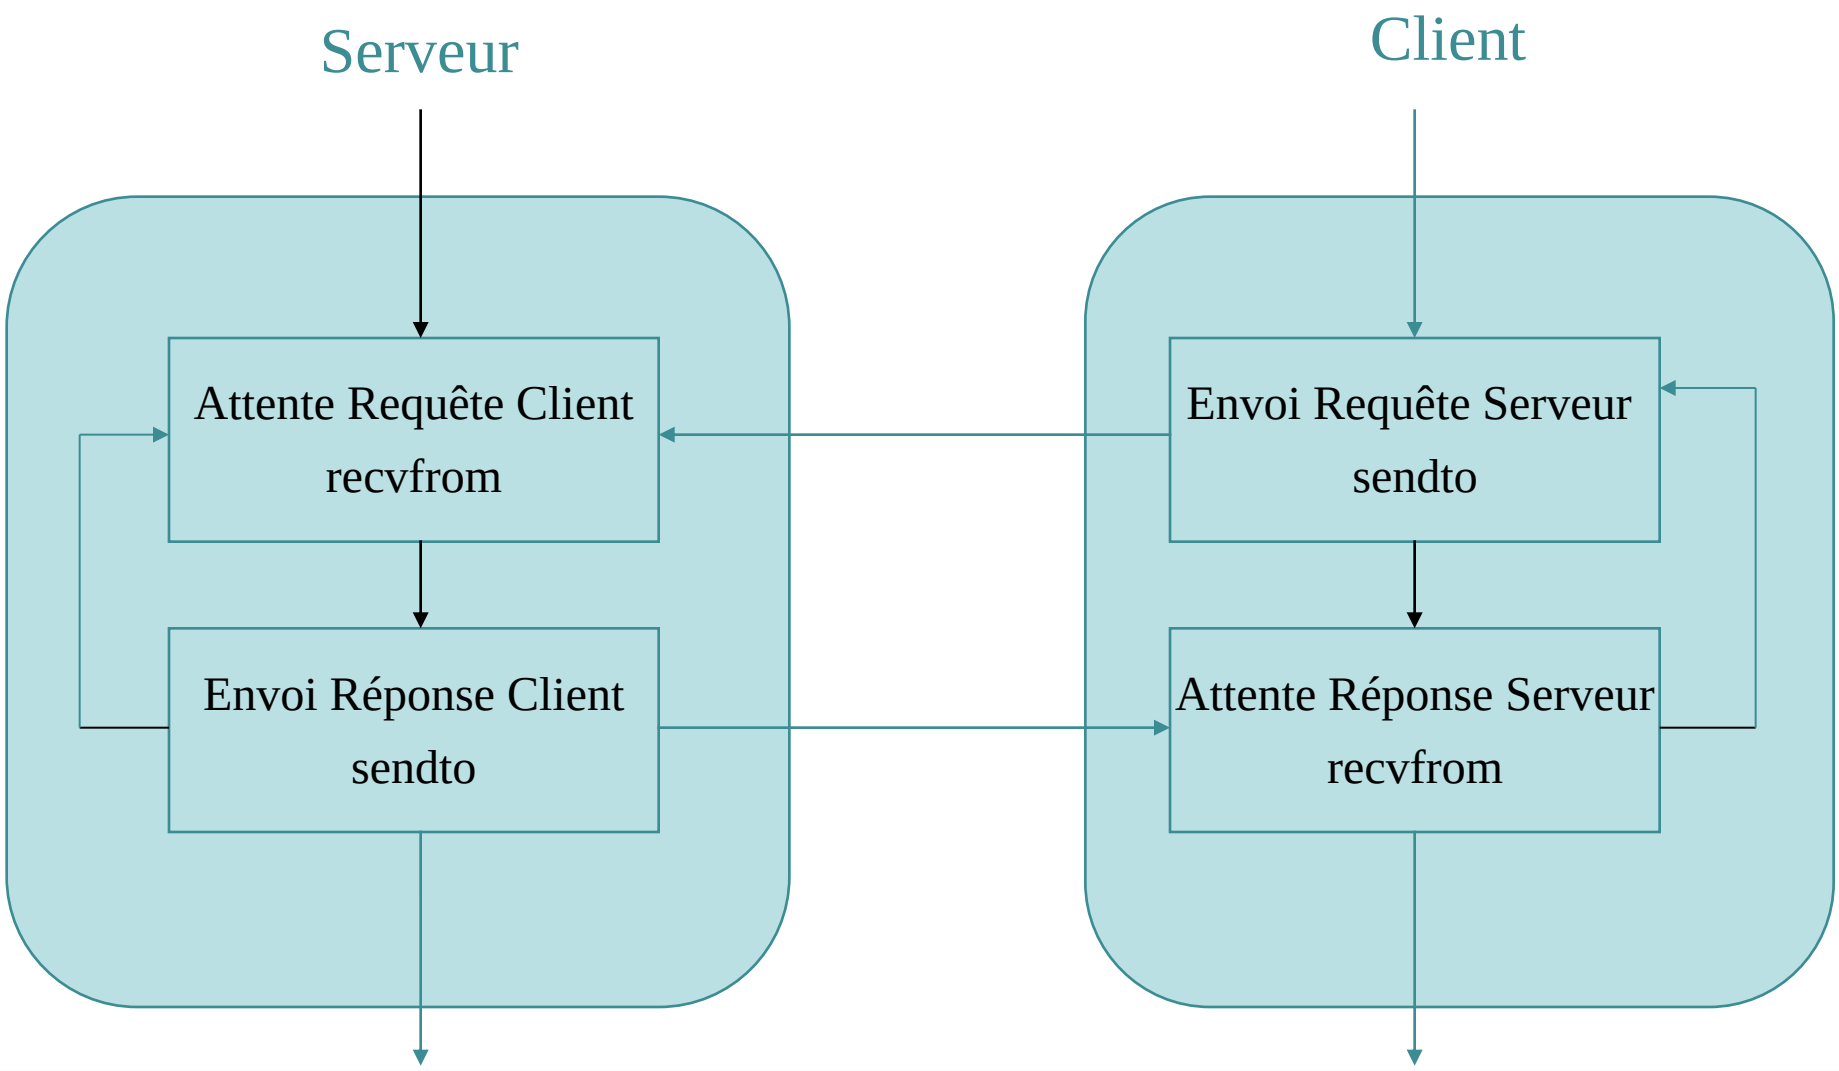

Dialogue - échange de données (C/S)

```
#include <sys/types.h>
#include <sys/socket.h>
ssize_t sendto (int s, const void *buff, size_t nbytes, int flags,
    const struct sockaddr *to, socklen_t tolen)
ssize_t recvfrom (int s, void *buff, size_t nbytes, int flags,
    struct sockaddr *from, socklen_t *fromlen)
```

- Les 4 premiers arguments identiques au send/rcv
- to/from : adresse du destinataire/émetteur du datagramme

② Programmation réseaux

- Modèle client serveur
- Introduction socket
- Client-Serveur TCP
- Client-Serveur UDP
- Entrée/sortie multiplexée : select
- Entrée/sortie asynchrone
- Options de socket
- Socket raw

Modèles Entrée/Sortie

- Quatre modèles d'entrée/sortie
  - E/S bloquante
  - E/S non bloquante
  - E/S multiplexée
  - E/S asynchrone (« signal-driven I/O »)

Entrée/Sortie bloquante

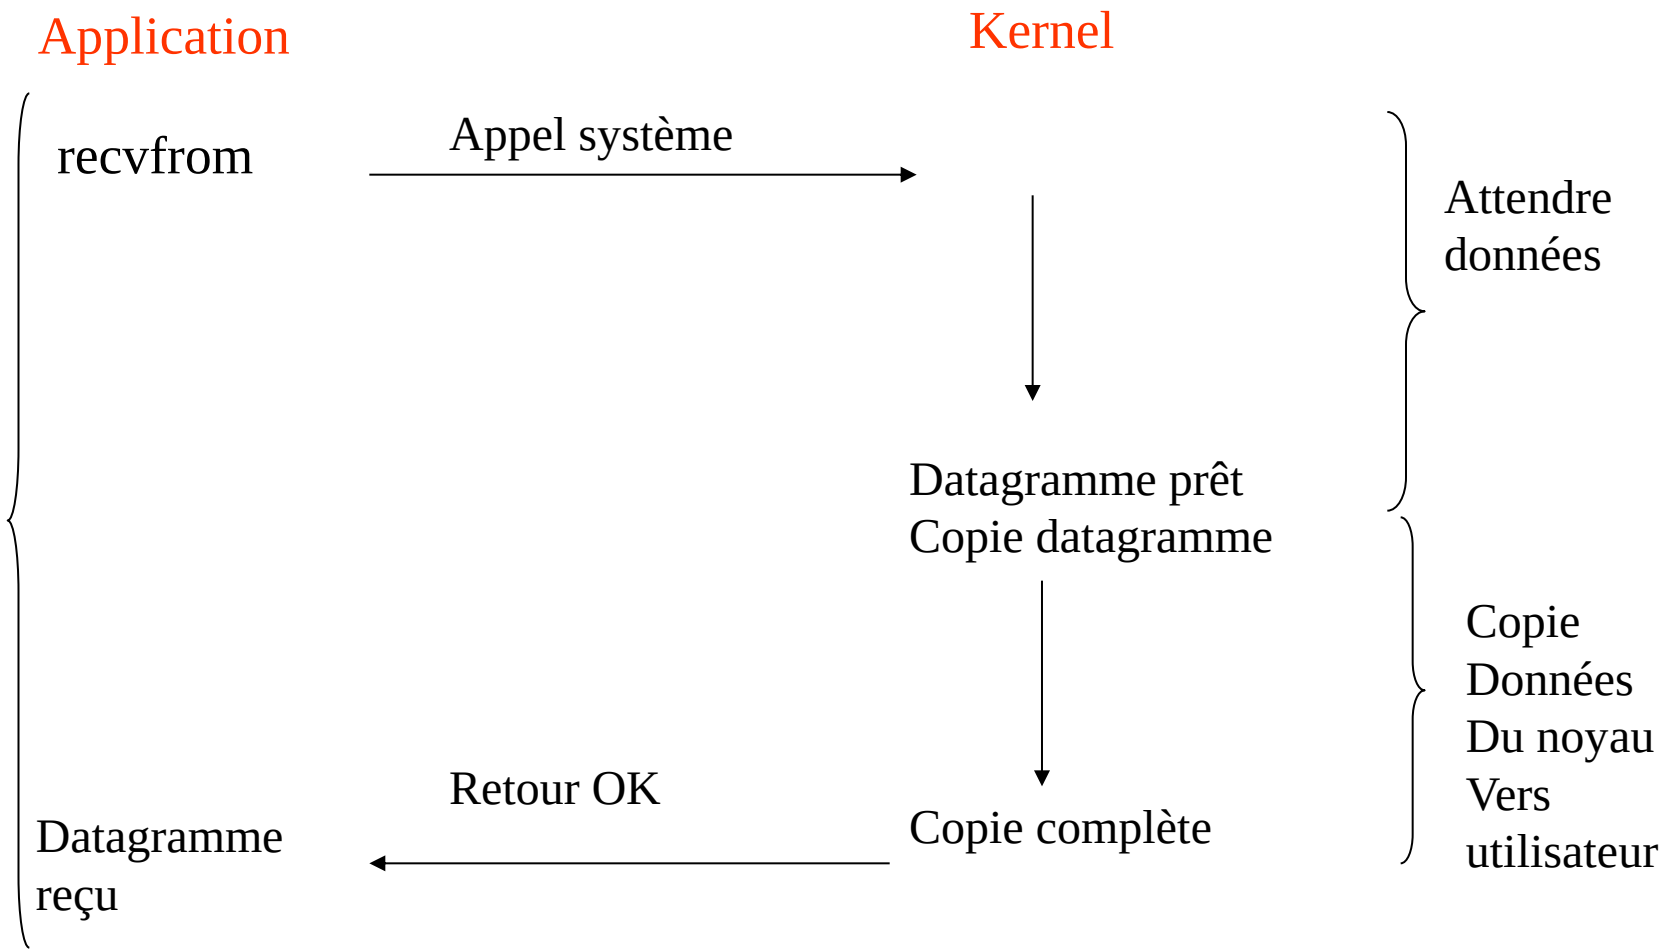

Entrée/Sortie non bloquante

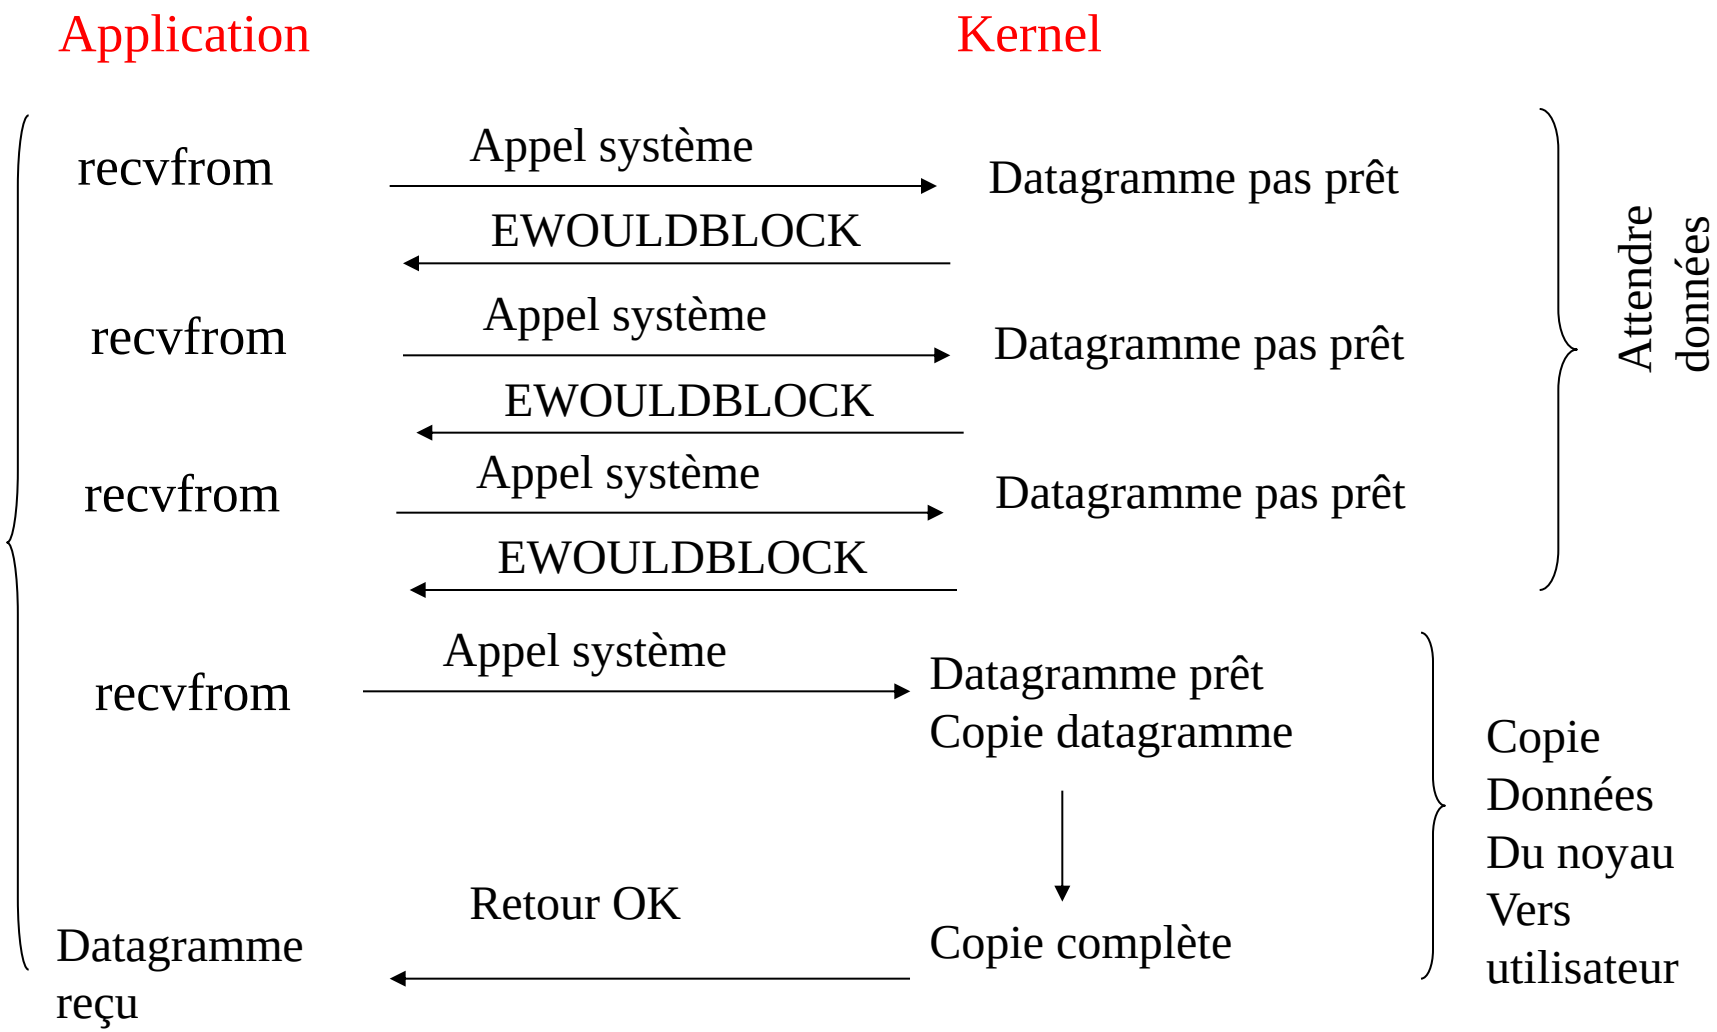

Entrée/Sortie multiplexée

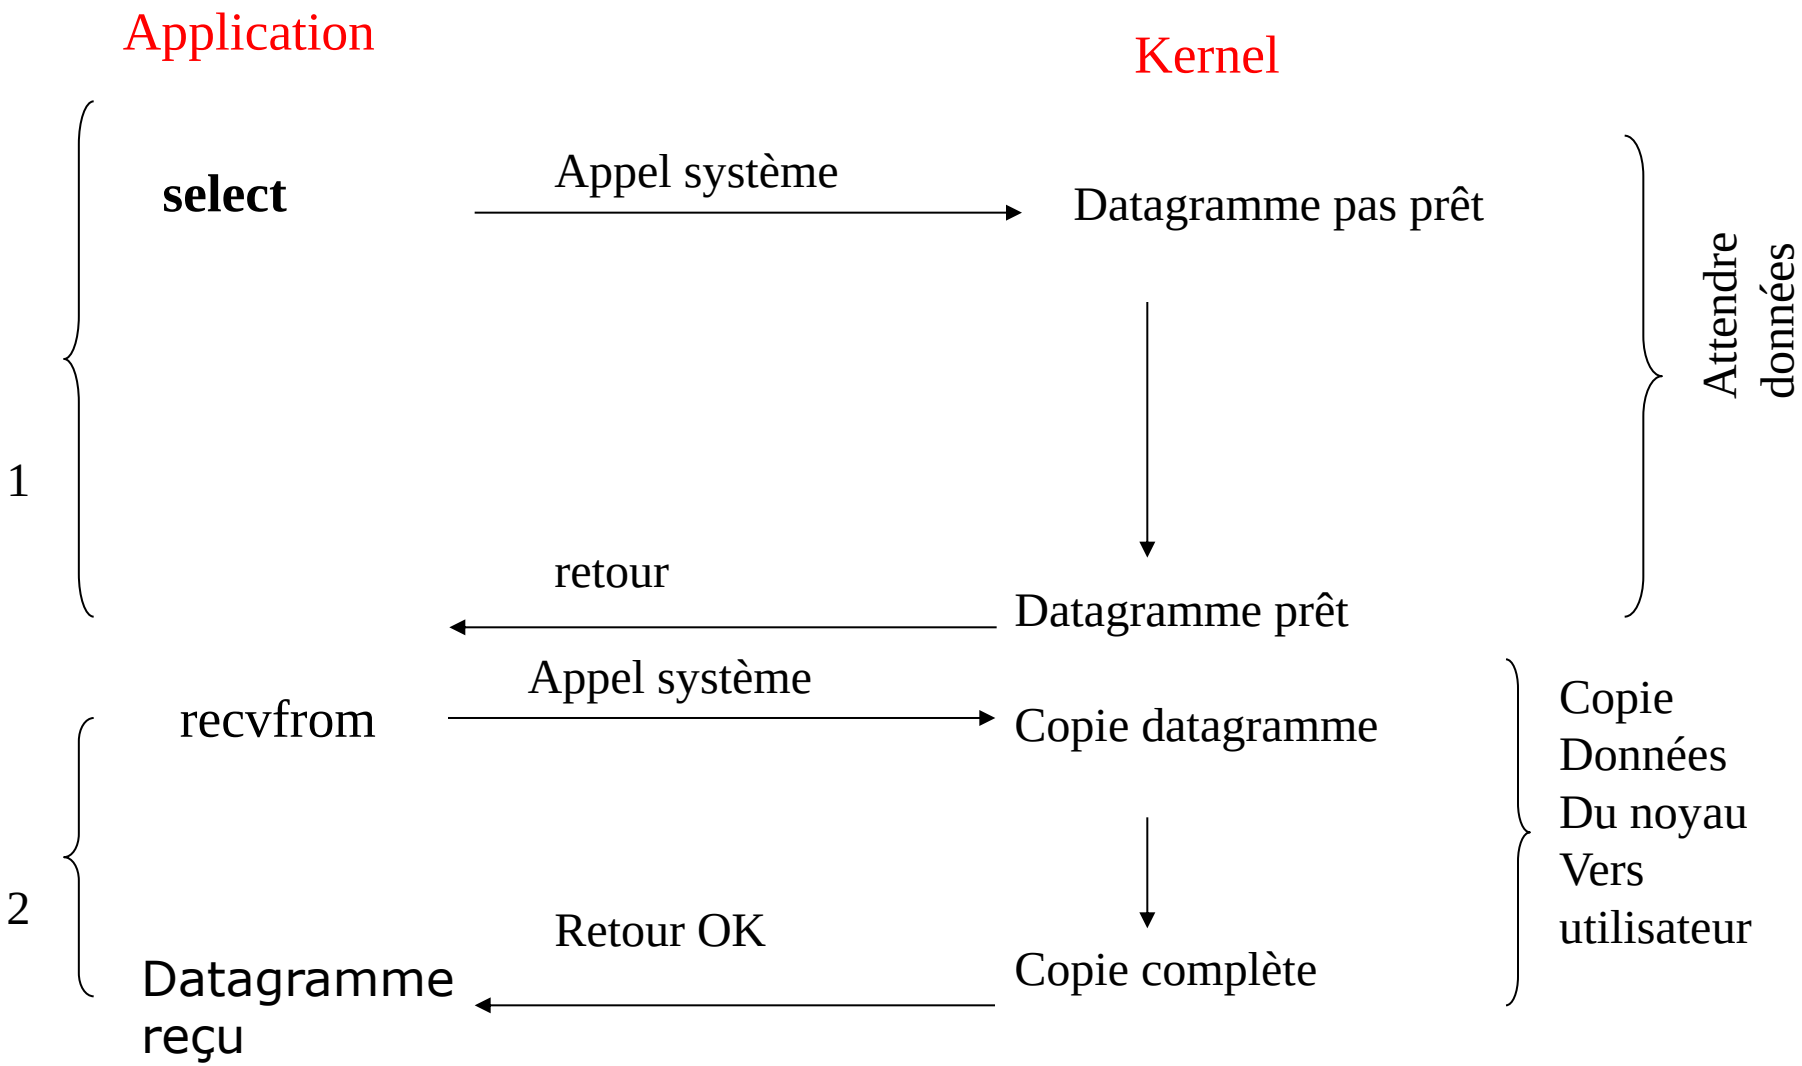

Fonction select()

- Permet l'attente simultanée sur plusieurs flux d'entrée-sortie
- Est utilisée :
  - Quand un client gère plusieurs descripteurs
  - Quand un client gère plusieurs sockets à la fois
  - Dans un serveur TCP, pour gérer à la fois le socket d'écoute et le socket de dialogue
  - Quand un serveur utilise à la fois UDP et TCP
  - Si un serveur gère plusieurs services et plusieurs protocoles
- Se termine :
  - Quand un évènement arrive sur un flux
  - Au bout d'un certain temps

Fonction select()

```
#include <sys/select.h>
#include <sys/time.h>
int select (int maxfdp1, fd_set *readset, fd_set *writeset, fd_set *excepset, const
    struct timeval *timeout)
```

maxfdp1➔ spécifie le nombre maximum de descripteurs à tester
Les descripteurs 0,1,2,… maxfdp1-1 sont testés
FD_SETSIZE : nombre de descripteurs dans le type fd_set
readset, writeset, excepset ➔ masques positionnés par l'appelant et indiquant les descripteurs pour lesquels on veut tester un prédicat en lecture (readset), en écriture (writeset), ou si une condition exceptionnelle se présente (excepset)
valeur de retour ➔le nombre descripteurs prêts ou
0 si timeout
-1 si erreur

Au retour les masques sont modifiés et indiquent les descripteurs pour lesquels le prédicat est vérifié

Fonction select()
fd_set

- fd_set : tableau d'entiers où chaque bit dans chaque entier correspond à un descripteur
- Macros pour manipuler fd_set
  - void FD_ZERO (fd_set *fdset);
  - void FD_SET (int fd, fd_set *fdset);
  - void FD_CLR (int fd, fd_set *fdset);
  - Int FD_ISSET (int fd, fd_set *fdset);

serveur

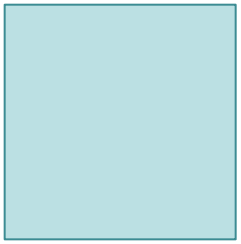

fd_set rset;
FD_ZERO (&rset);

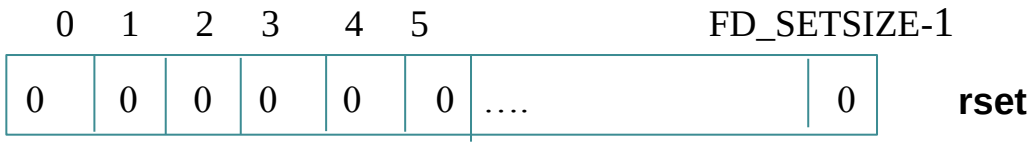

socket () + bind () + listen ()
FD_SET(socketecoute, &rset);

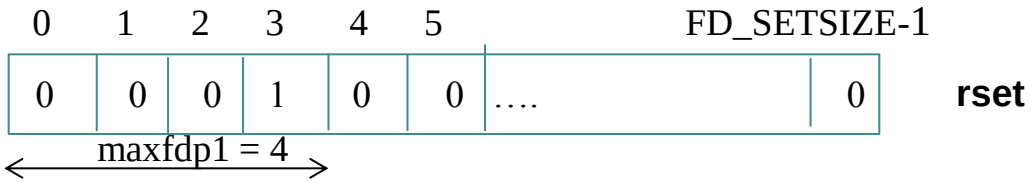

select(maxfdp1, &rset,NULL,NULL, NULL);

client1

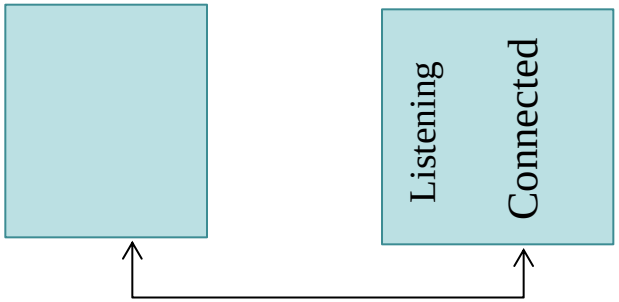

3WHS

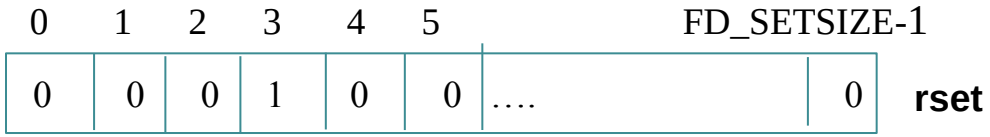

FD_ISSET (socketecoute, &rset) ➔ TRUE
socketdialogueC1 = accept (socketecoute,..)

FD_SET (socketdialogueC1, &rset);

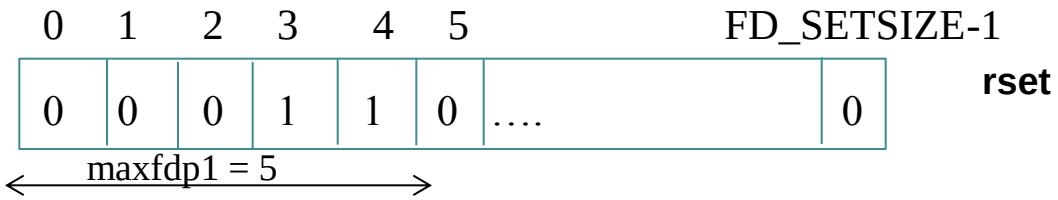

select(maxfdp1, &rset,NULL,NULL, NULL);

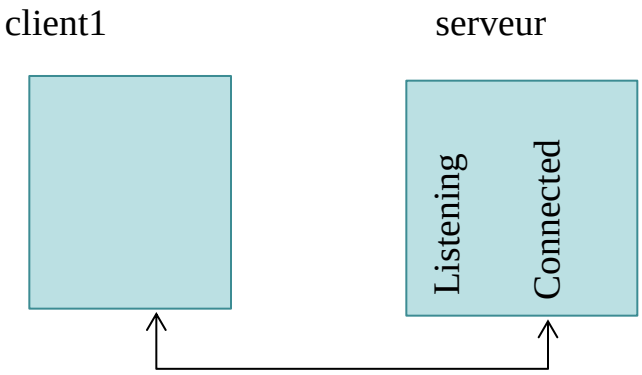

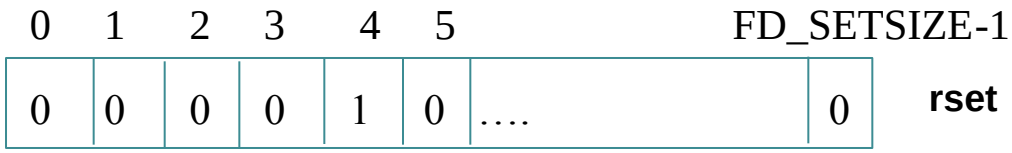

FD_ISSET (socketdialogueC1, &rset) ➔ TRUE
read (socketdialogueC1,…)

Au retour les masques sont modifiés et indiquent les descripteurs pour lesquels le prédicat est vérifié

FD_SET (socketecoute, &rset);

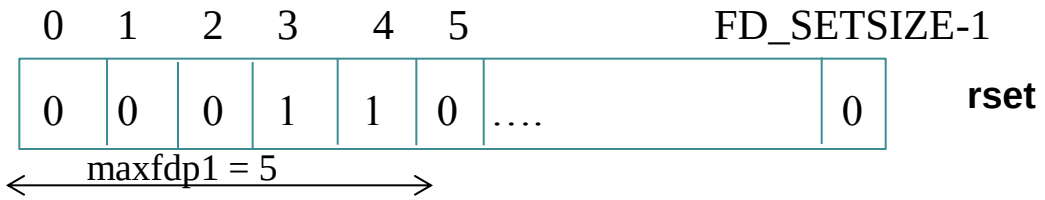

select(maxfdp1, &rset,NULL,NULL, NULL);

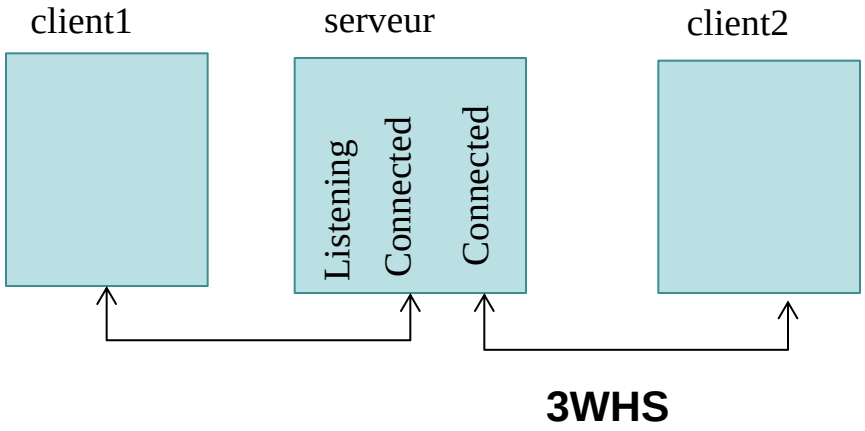

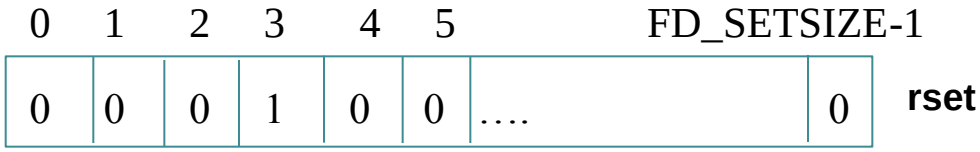

FD_ISSET (socketecoute, &rset) ➔ TRUE
socketdialogueC2 = accept (socketecoute,..)
FD_SET (socketdialogueC2, &rset);

Sauvegarder rset avant appel à select ()
cprset = rset;
ou
FD_COPY(&rset , &cprset); // BSD

Fonction select()
Contrôle de la durée d'attente

```
struct timeval {
        long tv_sec ;   /* secondes */
        long tv_usec;  /* microsecondes */
  } ;
```

- Attendre toujours ➔ pointeur NULL
- Pas d'attente : retour de l'appel immédiat ➔ champs internes de timeout initialisés à 0
- Attente limitée : attente jusqu'à arrivée d'un évènement ou fin du timer ➔ champs internes de timeout initialisés à une valeur différente de 0

```
struct  timeval timeout ;
timeout.tv_sec=1;
timeout.tv_usec=0;

if (select(0, NULL,NULL,NULL, &timeou
< 0) {
    perror ("cliecho : erreur fgets \n");
    exit(1);
}
```

② Programmation réseaux

- Modèle client serveur
- Introduction socket
- Client-Serveur TCP
- Client-Serveur UDP
- Entrée/sorties multiplexée : select
- Entrée/sortie asynchrone
- Options de socket
- Socket raw

Entrée/Sortie asynchrone
Signal driven I/O

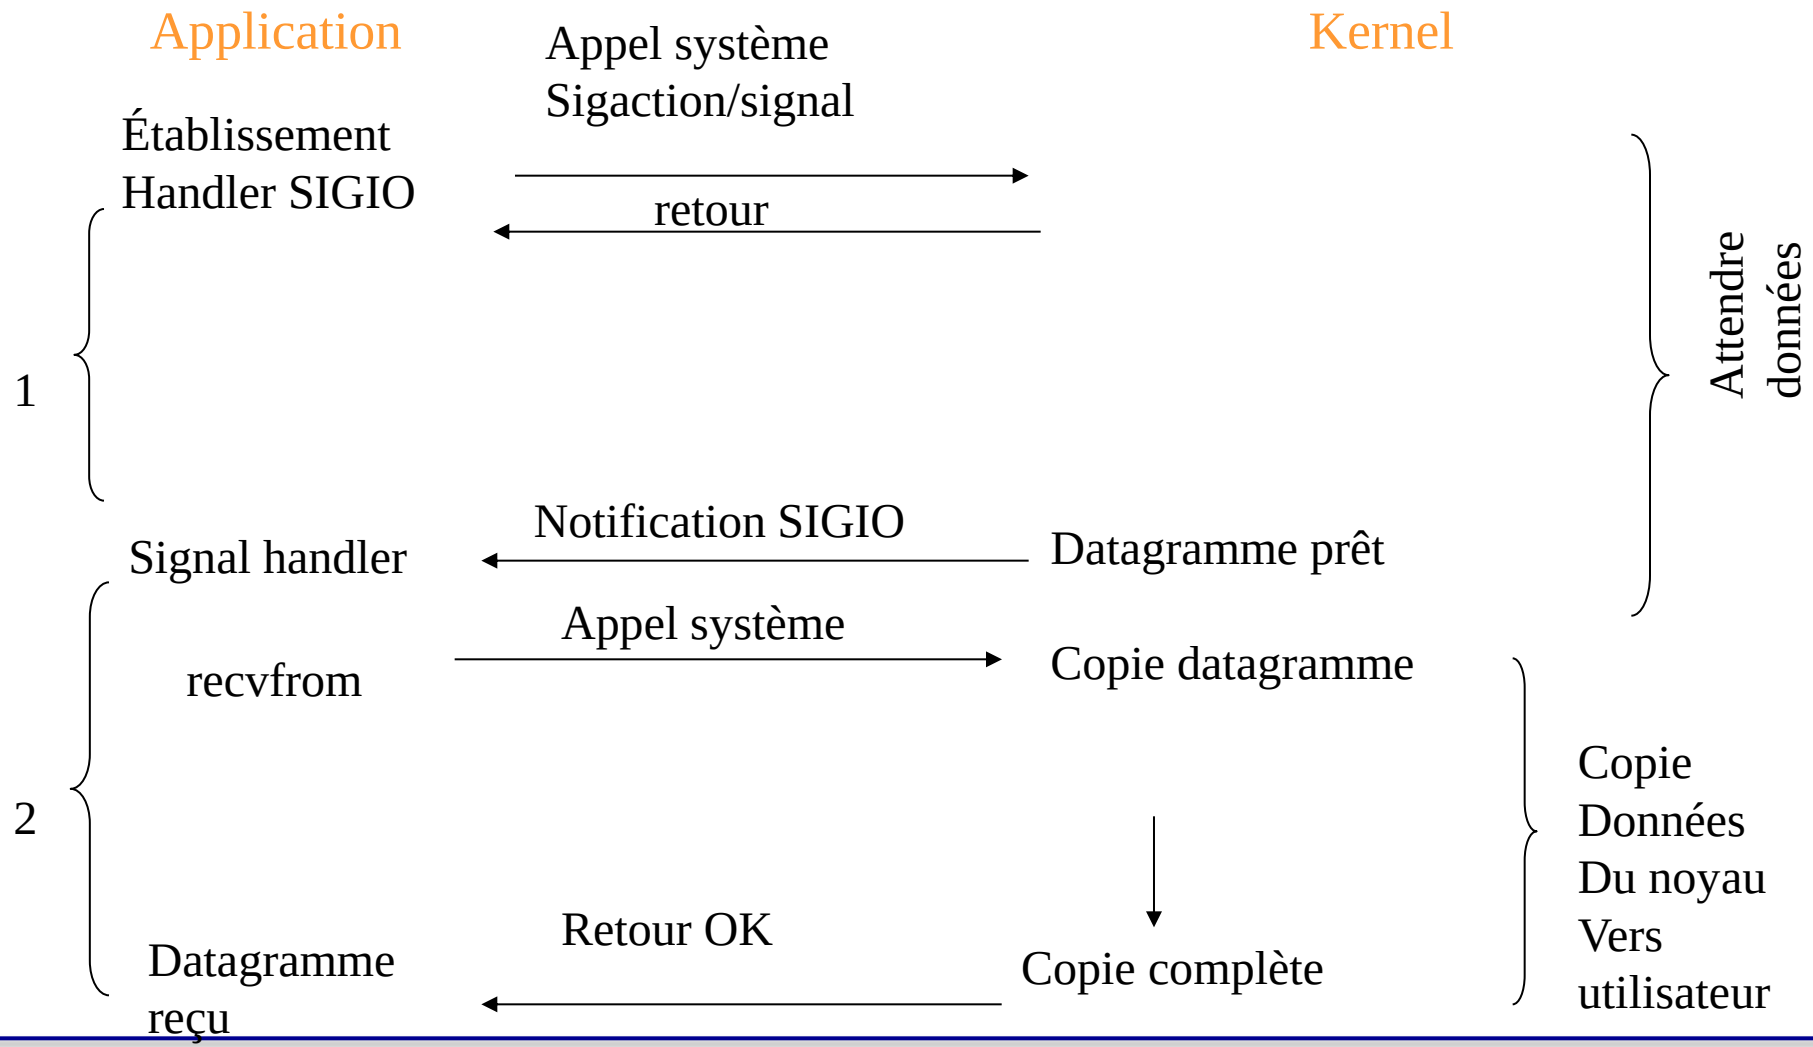

Socket et signaux

- 3 signaux peuvent être générés pour les sockets
  - SIGIO
    - Indique que la socket est prête pour une entrée ou une sortie asynchrone
  - SIGURG
    - Indique que des données urgentes sont disponibles en lecture
  - SIGPIPE
    - Indique l'écriture n'est plus possible sur le socket concerné

Socket et signaux

- Permet à un processus d'être interrompu quand un processus est disponible en lecture/écriture
  - Le noyau prévient le processus par le signal SIGIO
  - Le processus doit tout d'abord armer un « handler » pour le signal SIGIO (fonction signal/sigaction)
  - Le processus doit ensuite indiquer au noyau qu'il désire recevoir le signal SIGIO
    - fonction fcntl,commande F_SETOWN et argument pid du processus
  - Enfin le processus doit activer les entrées/sorties asynchrones sur le descripteur désiré
    - fonction fcntl,commande F_SETFL et argument O_ASYNC
- Applicable uniquement pour les terminaux et les descripteurs de sockets
- Problème ?

```
#include <signal.h>
#include <fcntl.h>
#define BUFSIZE 4096
int sigflag;
void sigio_func ()
{ sigflag = 1;}

main()
{
int n ;
char buff[BUFSIZE];
signal (SIGIO, sigio_func);
fcntl(0, F_SETOWN, getpid() );
fcntl(0, F_SETFL, O_ASYNC) ;

for (;;) {
    sigblock(sigmask(SIGIO));
        while (sigflag == 0) sigpause (0);  /* wait for a signal */

    if ((n = read (0, buff, BUFSIZE)) > 0) {
          write (1, buff, n) ;
    else if (n < 0) perror ("read error");
    else if (n == 0)  exit (0);       /* EOF */
    sigflag = 0;
    sigsetmask(0);
}}
```

② Programmation réseaux

- Modèle client serveur
- Introduction socket
- Client-Serveur TCP
- Client-Serveur UDP
- Entrée/sorties multiplexée : select
- Entrés/sortie asynchrone
- Options de socket
- Socket raw

Options sur les sockets

- Plusieurs fonctions disponibles pour positionner et obtenir les valeurs des options sur les sockets
  - **getsockopt()**, **setsockopt**(), fcntl(), ioctl ()

```
#include <sys/types.h>
#include <sys/socket.h>
int getsockopt (int fd, int level, int optname, void *optval, socklen_t *optlen)
int setsockopt (int fd, int level, int optname, const void  *optval,
                socklen_t optlen)
```

level ➔ permet d'indiquer la couche logicielle en charge de l'option (socket, TCP, IP) : SOL_SOCKET, IPPROTO_IP, IPPROTO_TCP

optname ➔ nom de l'option

optval ➔ pointeur générique contenant la valeur de l'option

optlen ➔ contient la taille de la valeur

(level) SOL_SOCKET

- Optname **SO_BROADCAST**
  - permet d'envoyer des datagrammes en broadcast au niveau des réseaux locaux

```
int on=1;
setsockopt (sockfd, SOL_SOCKET,
SO_BROADCAST,&on, sizeof(on));
```

- Optname **SO_RCVBUF** ou **SO_SNDBUF**
  - permet de préciser la taille du buffer de réception ou émission des sockets TCP/UDP
    - Appel avant ou après connect(côté client) ?
    - Appel avant ou après listen(côté serveur) ?

```
int size = 4096;
setsockopt (sockfd, SOL_SOCKET,
SO_RCVBUF, &size,sizeof(size));
```

(level) SOL_SOCKET

- Optname **SO_REUSEADDR / SO_REUSEPORT**
  - permet d'indiquer qu'une même adresse locale peut être réutilisée
- Optname **SO_LINGER**
  - spécifie comment la fonction close se comporte

```
struct linger{
    int         l_onoff;  /* 0 ➔  off  */
    int         l_linger;  /* temps en sec */
}
```

Comportement par défaut (l_onoff == 0) : la fonction close retourne immédiatement

(level) IPPROTO_IP

- Optname **IP_OPTIONS**
  - permet d'utiliser les options de l'entête IP
- Optname **IP_TTL**
  - permet de préciser TTL qui va être utilisé par le système
  - dans le cas du multicast ➔ IP_MULTICAST_TTL
- Optname **IP_HDRINCL**
  - permet d'utiliser les sockets RAW

(level) IPPROTO_TCP

- Optname **TCP_MAXSEG**
  - spécifie la taille de segment maximum
- Optname **TCP_NODELAY**
  - désactive l'algorithme de Nagle

```
#include <sys/types.h>
#include <sys/socket.h>
#include <netinet/in.h>
#include <netinet/tcp.h>

main()
{
int sockfd, maxseg, sendbuf ;
socklen_t optlen ;
if ( (sockfd=socket(AF_INET, SOCK_STREAM,0)) <0){
                perror("probleme socket"); exit(1) ;
}
optlen =  sizeof(maxseg);
if (getsockopt(sockfd, IPPROTO_TCP, TCP_MAXSEG, &maxseg, &optlen) <0){
                perror("probleme getsockopt"); exit(1) ;
}
printf ("TCP maxseg = %d\n",maxseg);
sendbuf =  16384;
if (setsockopt(sockfd, SOL_SOCKET, SO_SNDBUF, &sendbuf, sizeof(sendbuf))<0){
        perror("probleme setsockopt"); exit(1) ;
}
optlen = sizeof(sendbuf);
if (getsockopt(sockfd, SOL_SOCKET, SO_SNDBUF, &sendbuf, &optlen)) <0){
        perror("probleme getsockopt"); exit(1) ;
}
printf ("send buffer size = %d\n",sendbuf);
}
```

② Programmation réseaux

- Modèle client serveur
- Introduction socket
- Client-Serveur TCP
- Client-Serveur UDP
- Entrée/sorties multiplexée : select
- Entrés/sortie asynchrone
- Options de socket
- Socket raw

Caractéristiques d'une socket raw

- Permet à un processus de lire et d'envoyer des paquets de contrôle (ICMP, IGMP)
- Permet à un processus de lire et d'envoyer des datagrammes IP avec un champ *protocol* non traité par le noyau
- Permet à un processus de construire sa propre entête IPv4 (options socket IP_HDRINCL)

Création

```
int sockfd;

if ( (sockfd=socket(AF_INET, SOCK_RAW, protocol)) <0){
        perror("probleme socket");
        exit(1) ;
}
```

- protocol ➔ constante définie dans <netinet/in.h> comme IPPROTO_ICMP

- Création uniquement en mode super utilisateur

Création

```
const int on =1:

if ( setsockopt(sockfd, IPPROTO_IP, IP_HDRINCL, &on, sizeof(on)) <0){
            perror(¨probleme setsockopt¨);
      exit(1) ;
}
```

- Positionnement de l'option IP_HDRINCL si en-tête IP est inclus dans la donnée
- Fonction bind peut être appelée mais rare
  - Pas de concept de numéro de port, uniquement adresse locale
- Fonction connect peut être appelée mais rare

Emission

- Utilisation de **sendto** en spécifiant l'adresse IP destination
- Si l'option IP_HDRINCL n'est pas positionnée
  - L'adresse de début de la donnée = le 1er octet suivant l'en-tête IP
- Le noyau fragmente les paquets raw qui excèdent la taille du MTU de l'interface sortante

Réception

- Utilisation de **recvfrom**
- Les paquets TCP et UDP reçus ne sont jamais passés à une socket RAW
- La plupart des paquets ICMP sont passés à une socket RAW une fois que le noyau a fini de traiter le message ICMP
  - Les implémentations dérivées de BSD passent tous les paquets ICMP sauf echo request, timestamp request et address mask request.
- Tous les paquets IGMP sont passés à une socket RAW une fois que le noyau a fini de traiter le message IGMP
- Tous les datagrammes IP avec un champ *protocol* non reconnu par le noyau sont passés à une socket RAW

Réception

- Si un datagramme arrive en fragments :
  - Attente de tous les fragments
- Tests à vérifier pour obtenir un datagramme IP
  - Si *protocol* ≠ 0 spécifié à la création du socket RAW alors
    - Champ *protocol* du datagramme reçu == champ *protocol* spécifié
  - Si une adresse IP locale est liée au socket RAW par *bind* alors
    - Adresse destination du datagramme reçu == adresse locale
  - Si une adresse distante est spécifiée par *connect* alors
    - Adresse source du datagramme reçu == adresse distante

Plan

① Contrôle de congestion et TCP

② Programmation réseaux

- socket, select(), options de socket, socket raw

③ Communication de groupe (multicast)

④ Introduction IPv6

Unicast, Broadcast et Multicast

- IP Unicast (diffusion point à point)
  Liaison point à point entre 2 machines : source - destination

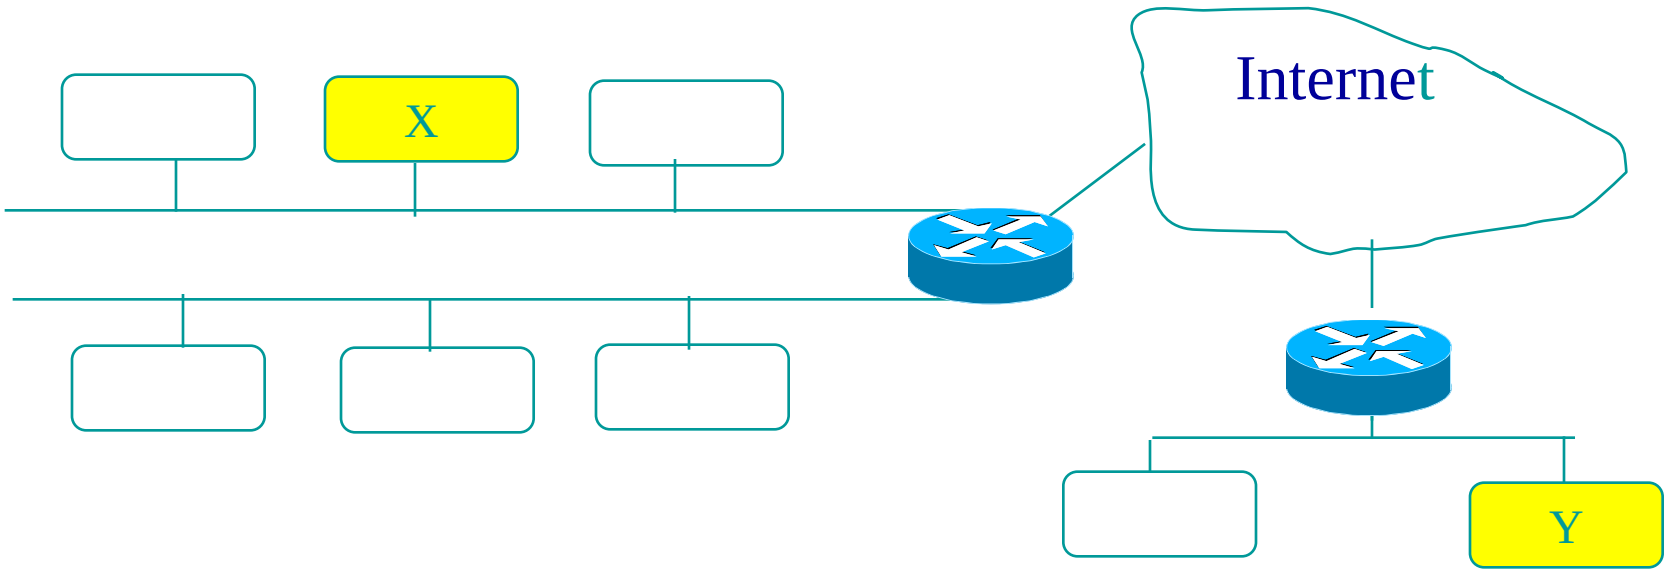

Unicast, Broadcast et Multicast

- IP Broadcast (diffusion générale)
  Diffusion de paquets limitée au réseau local

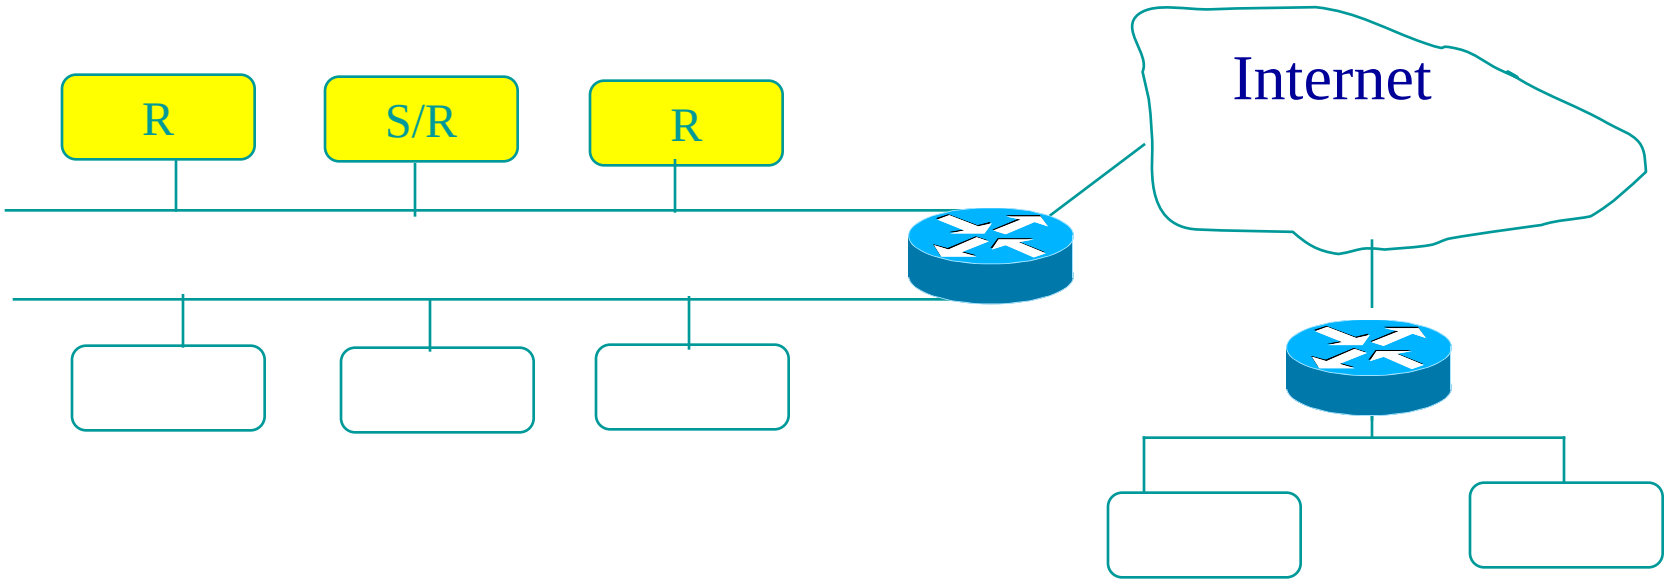

Unicast, Broadcast et Multicast

- IP Multicast (diffusion de groupes/multipoint)
  Le multicast atteint un groupe de machines qui peuvent être réparties sur des réseaux distincts

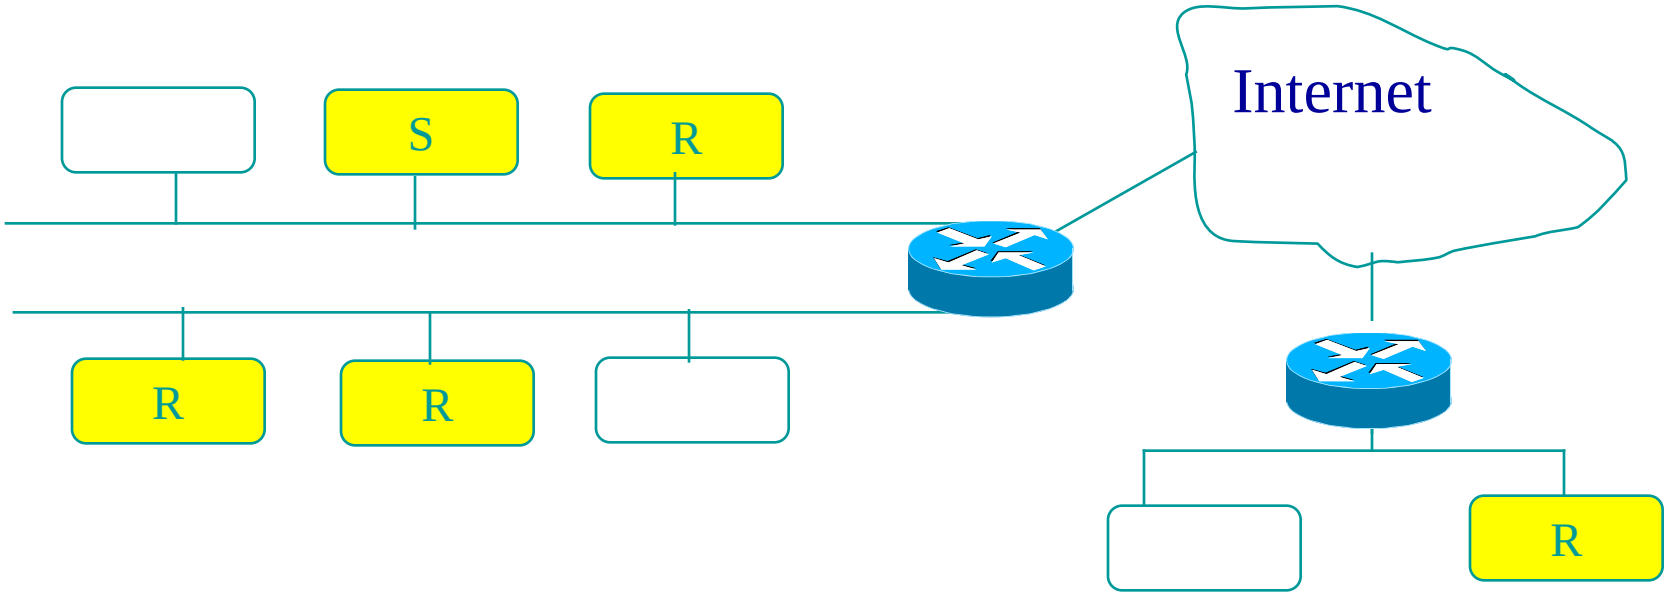

Applications du Multicast

- Téléconférence
- Jeux distribués
- Distribution de logiciels
- Vidéo à la demande
- Mise à jour des bases de données répliquées

Le modèle IP multicast

- Défini par Steve Deering
  - [Multicast Routing in a datagram internetwork, Ph.D Thesis, Stanford University, 1991]
- Présente
  - la notion de groupe,
  - le type d'adressage,
  - Extension de l'interface de service IP du module IP pour envoyer et recevoir des données
  - Le protocole d'adhésion au groupe sur un réseau local

La notion de groupe/multicast

- Un groupe est un ensemble de 0 ou n machines
- Un groupe est entièrement dynamique
  - Une station peut rejoindre ou quitter le groupe à tout moment
- Un groupe est ouvert
  - Une station peut émettre un paquet dans un groupe sans en faire partie
- Un groupe est temporaire ou non
  - Adresses allouées dynamiquement ou non
- Un groupe est désigné par une adresse IP

Adressage de groupe/multicast

- Adresse Internet de Classe D :
  - 224.0.0.0 -> 239.255.255.255

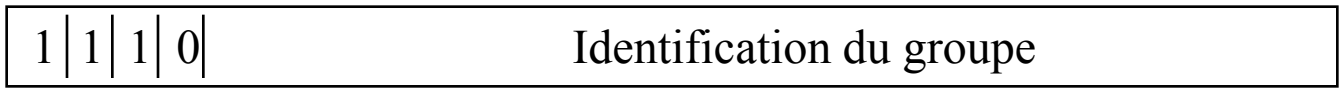

- Adresse utilisée uniquement en destination
- Réservation de plages d'adresses spécifiques
  - http://www.iana.org/numbers.html
  - 224.0.0.0 –> 224.0.0.255 (224.0.0.0/24)
    - Réservées pour la diffusion sur le LAN
    - 224.0.0.1 tous les hosts multicast sur un LAN
    - 224.0.0.2 tous les routeurs multicast sur un LAN

Adressage de groupe/multicast

- Correspondance adresse IP multicast et adresse Ethernet multicast
  - Pour mettre en correspondance les adresses de diffusion Ethernet, placer les 23 bits de poids faibles des adresses de diffusion au niveau IP dans les 23 bits de l'adresse de diffusion de groupe au niveau Ethernet spécifique suivante :
    - 01:00:5E:00:00:00
  - Adresse IP : 224.255.26.9 Adresse MAC = ?????
  - Remarque ?

Extension Interface de service IP et Module IP

- Émission de données
  - Emission d'un paquet multicast est identique à l'émission en point-à-point
  - Pour autoriser les transmissions multicast, la logique de routage doit être changée :
    - if IP-destination is on the same local network **or IP-destination is a host group,**
      send datagram locally to IP-destination
      else send datagram locally to Gateway
- Réception de données
  - Nécessite un abonnement préalable au groupe pour laisser passer vers le niveau supérieur les données relatives à une adresse de diffusion :
    - Ajout des nouvelles primitives à l'interface comme Join et Leave (=> IGMP)

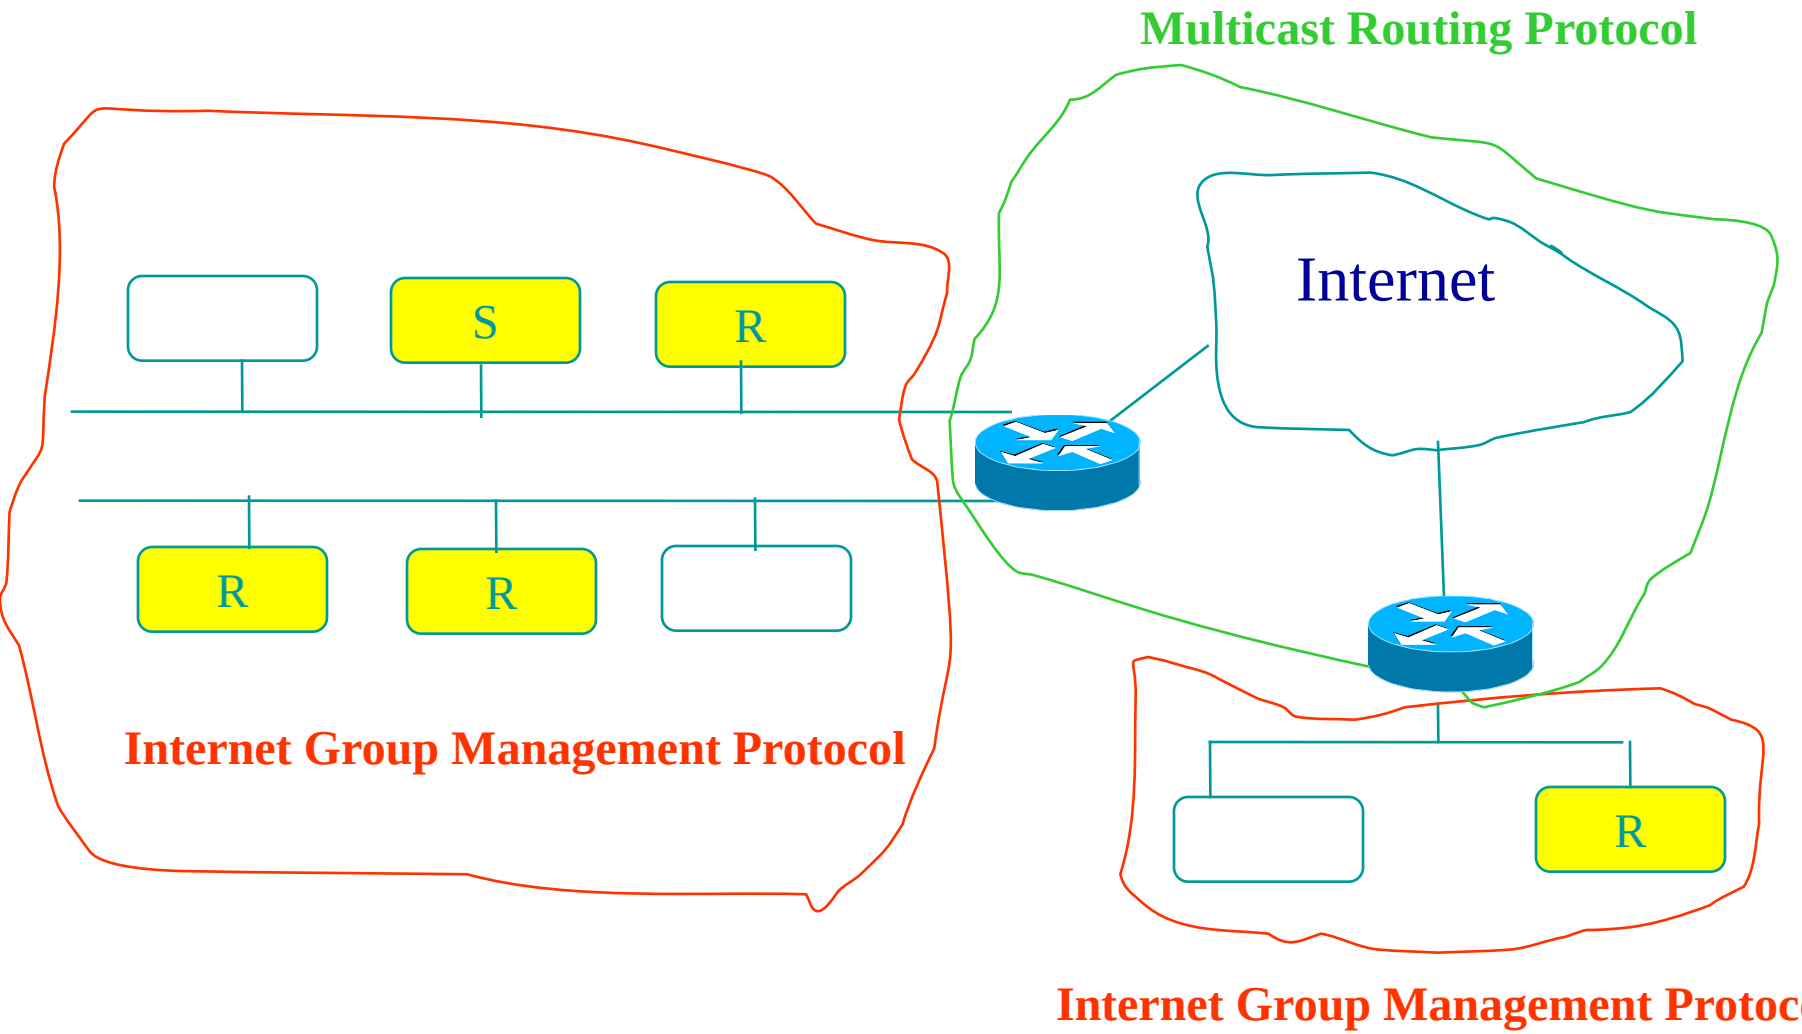
Multicast Routing Protocol
Internet
S
R
R
R
R
Internet Group Management Protocol
Internet Group Management Protocol

148

Le protocole IGMP

- Protocole d'interaction entre :
  - Les routeurs multicast du réseau local
  - Les machines hôtes multicast du réseau local
- Les hôtes informent les routeurs de leur appartenance au groupe (abonnement/désabonnement)
- Les routeurs sollicitent directement les hôtes connectés

Le protocole IGMP

- Comme ICMP, les messages IGMP sont encapsulés dans des datagrammes IP
  - numéro de protocole 2
  - TTL à 1
  - l'option IP Router Alert dans l'entête IP
- Trois versions de IGMP :
  - v1 (rfc 1112)
  - v2 (rfc 2236)
  - v3 (rfc 3376)

Le protocole IGMP

- Le routeur envoie de manière périodique (60s) un *IGMP Query* à l'adresse 224.0.0.1
  - Sollicitation des hôtes pour savoir à quel groupe ils sont abonnés
- Les hôtes répondent par un *IGMP Report*
  - Précisant l'adresse du ou des groupes auxquels ils appartiennent
- Si le routeur ne reçoit plus de réponses pour un groupe spécifique
  - Les paquets multicast pour ce groupe ne seront plus retransmis dans le réseau local
  - Le routeur prévient les autres routeurs multicast en amont via un protocole de routage multicast

Le protocole IGMP

- Sur réception d'un *Query* :
  - L'hôte fixe un délai aléatoire avant de répondre
  - Si un autre hôte répond avant lui, il arrête le temporisateur et n'émet plus le *Report*
  - Diminution de la surcharge du réseau : une réponse par groupe multicast sur un réseau local
- Quand un hôte joint un nouveau groupe, il transmet un *Report* pour ce groupe

Abonnement

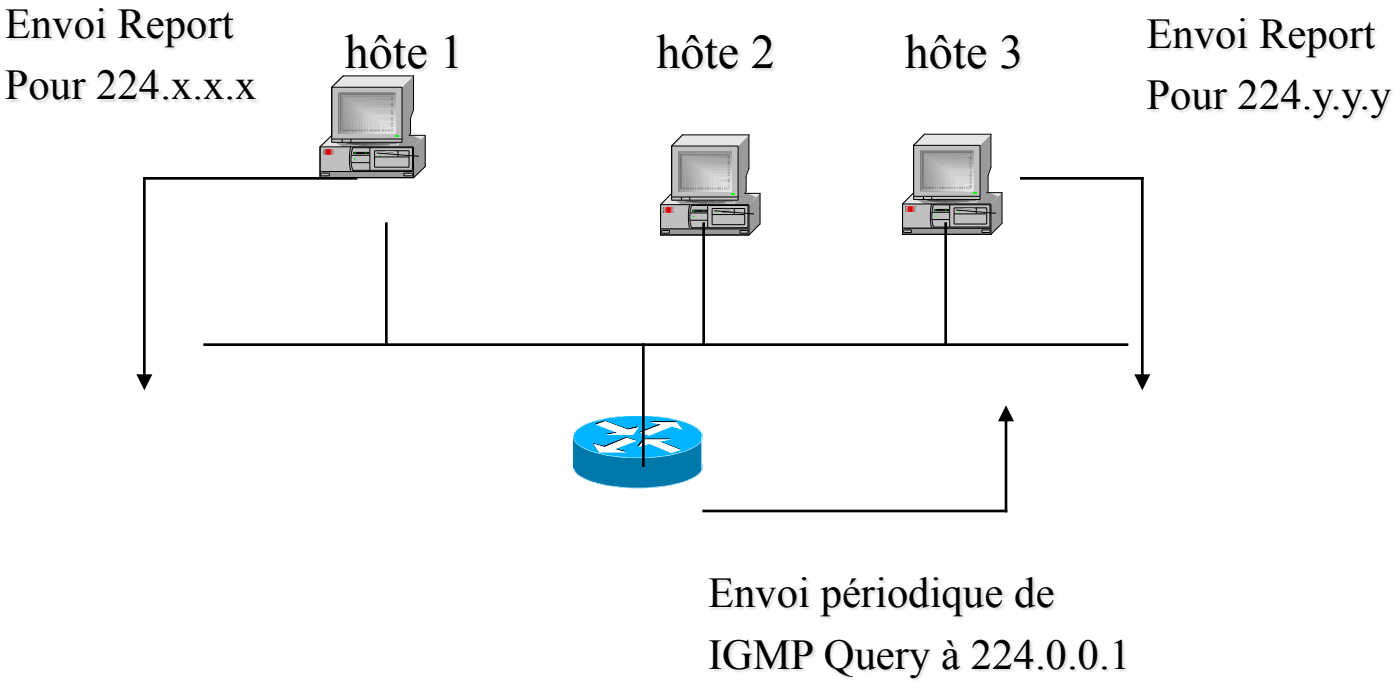
Envoi Report
Pour 224.x.x.x
hôte 1
hôte 2
hôte 3
Envoi Report
Pour 224.y.y.y
Envoi périodique de
IGMP Query à 224.0.0.1

Evolutions vers IGMPv2

- Si plusieurs routeurs sur le même réseau local :
  - Un seul routeur est élu pour émettre des *Queries* : Designated Router (DR)
  - En IGMPv1, le mécanisme d'élection devait être réalisé par le routage multicast et non par IGMP
  - En IGMPv2, le DR sera celui avec l'adresse IP la plus petite
- Désabonnement:
  - Introduction d'un message *Leave Group*
    - Message envoyé à l'adresse 224.0.0.2 (all-routers multicast group) si le hôte est le dernier membre (pas obligatoire sinon)

Désabonnement

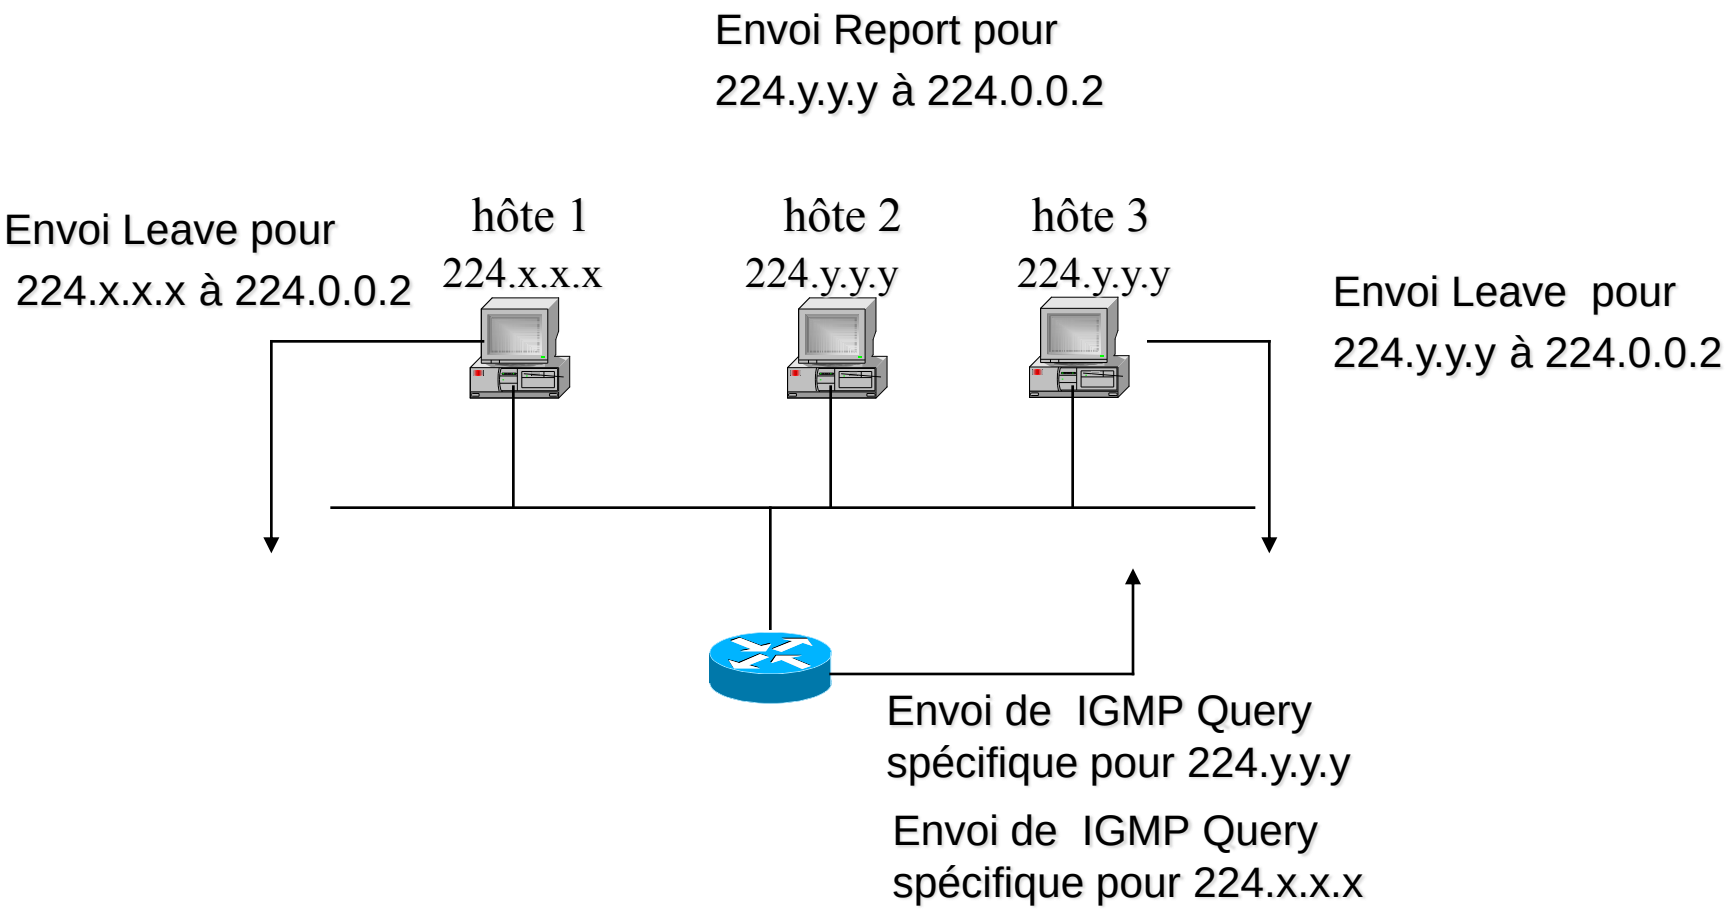

Diagramme état : IGMP hôte

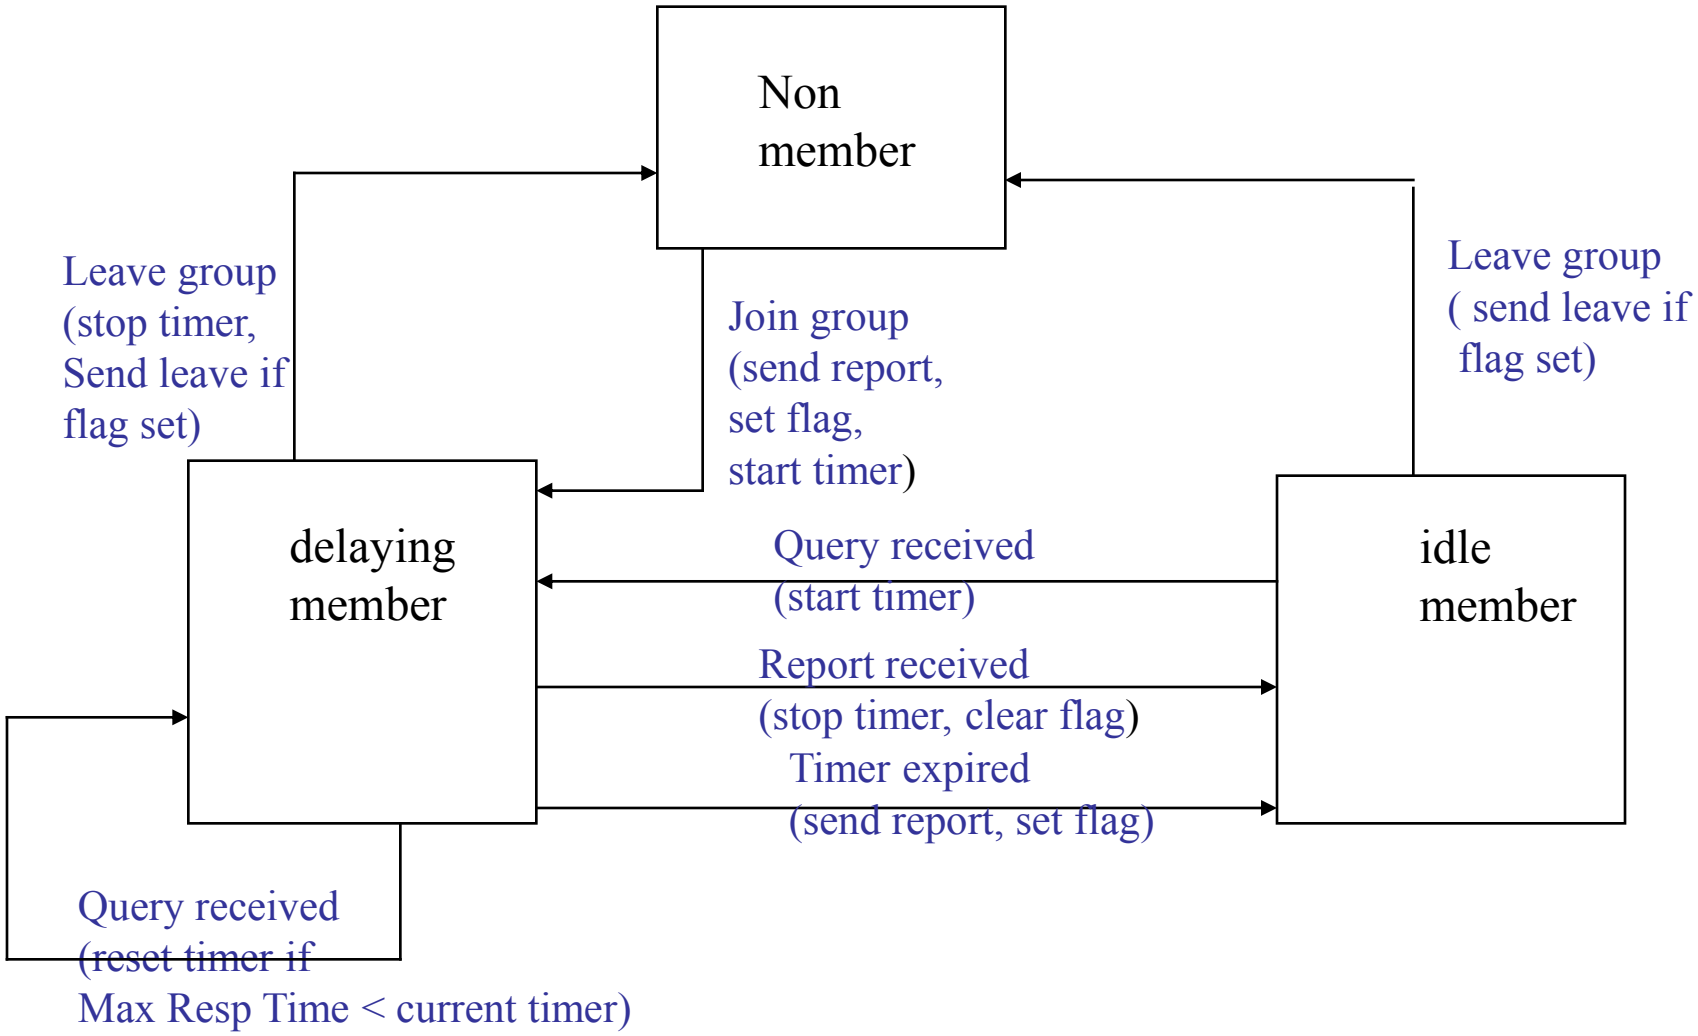

Diagramme état : IGMP routeur

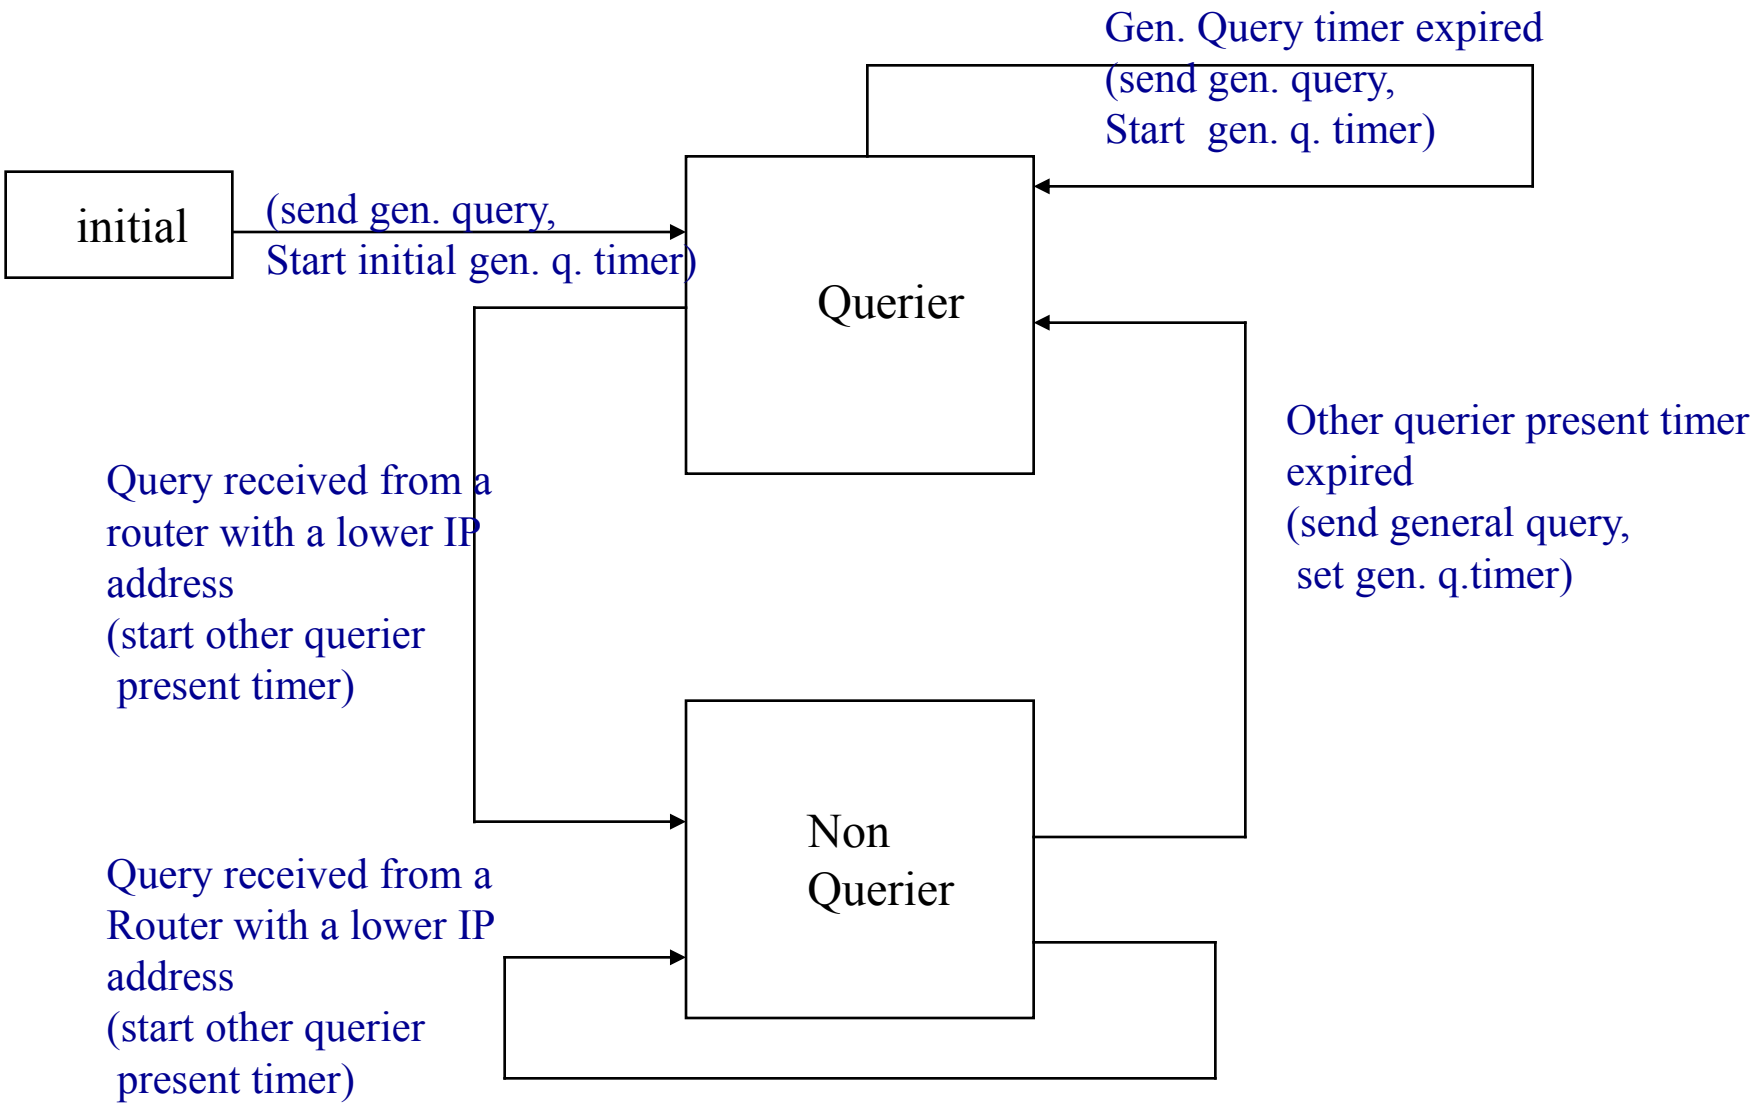

Diagramme état : IGMP routeur

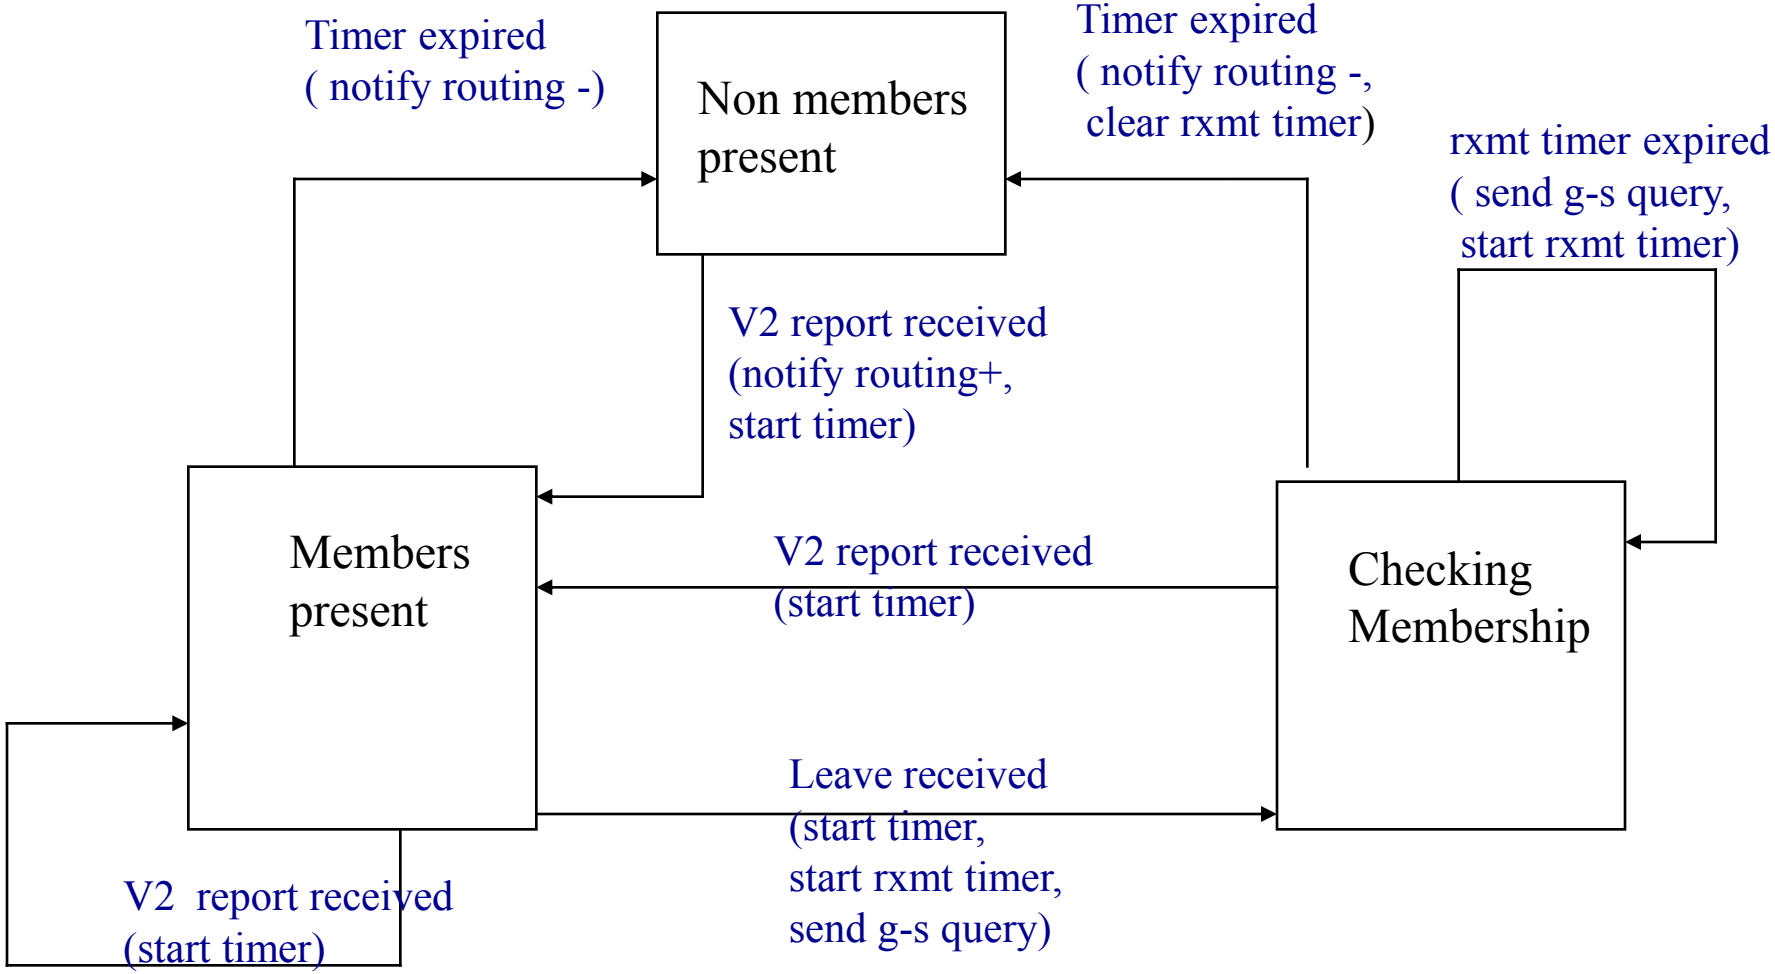

IP Multicast et le Mbone

- Mbone = Virtual Internet Backbone for Multicast IP
- Relier des¨îlots multipoints¨ (zone où le routage multipoint est supporté) par des tunnels.

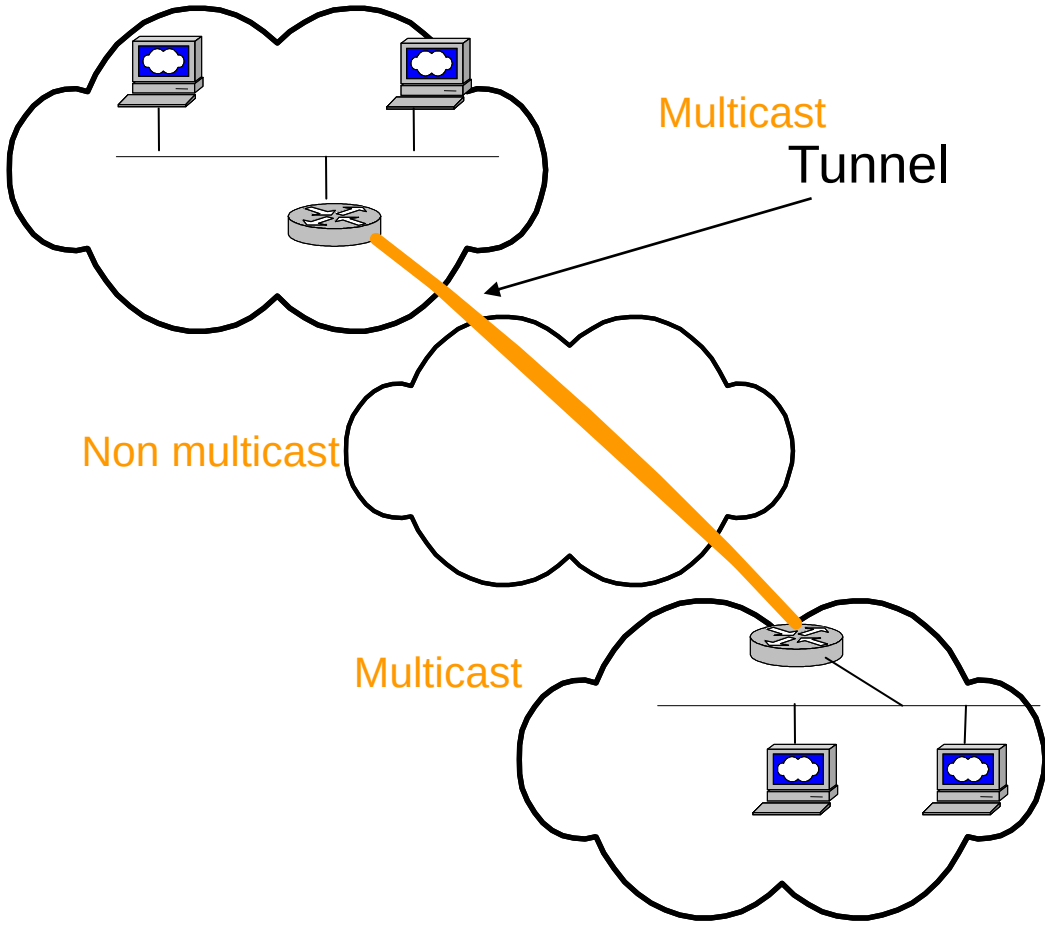

Initialisation d'un socket Multicast récepteur (R)

```
#define GROUP "239.137.194.111"
#define PORT 55555

int sdr;

/* création socket * /
sdr = socket(AF_INET, SOCK_DGRAM, 0);
if (sdr < 0) {perror("problème création socket"); exit(1);}

struct sockaddr_in addr_r;
/* Initialisation structure adresse réception * /
memset (&addr_r, 0, sizeof(addr_r));
addr_r.sin_family = AF_INET;
addr_r.sin_port = htons(PORT);
addr_r.sin_addr.s_addr = htonl(INADDR_ANY);
```

Rejoindre un groupe Multicast (R)

```
struct ip_mreq imr;

/* Initialisation structure imr */
imr.imr_multiaddr.s_addr = inet_addr(GROUP);
imr.imr_interface.s_addr = INADDR_ANY

/* Demande de participation à un groupe */
if (setsockopt (sdr,IPPROTO_IP,IP_ADD_MEMBERSHIP, &imr, sizeof(imr))<0){
            perror("probleme setsockopt");
        exit(1);
}
unsigned int on = 1;
/* En cas de réutilisation d'un port */
if (setsockopt (sdr,SOL_SOCKET, SO_REUSEADDR, &on,sizeof(on)) < 0)
            {perror("probleme setsockopt " );
            exit(1);
}
/* Nommer et lier le socket en reception */
if (bind (sdr, (struct sockaddr *)&addr_r,  sizeof(addr_r)) < 0) {
            perror("probleme setsockopt " );
      exit(1);
}
```

Réception d'un message Multicast (R)

```
int cnt, len_r=sizeof(addr_r);
char buf[100];

/* Réception de paquets */
/* Utilisation de la primitive  recvfrom */

cnt = recvfrom (sdr, buf, sizeof(buf), 0,
                                    (struct sockaddr *)&addr_r, &len_r)
if (cnt < 0) {
            perror("probleme recvfrom" );
            exit(1);
}
```

Quitter un groupe Multicast (R)

```
/* Demande pour abandonner un groupe */

if (setsockopt (sdr, IPPROTO_IP, IP_DROP_MEMBERSHIP,
       &imr, sizeof(imr)) < 0) {
              perror("probleme setsockopt " );
        exit(1);
}
```

Initialisation d'un socket Multicast émetteur (E)

```
#define GROUP "239.137.194.111"
#define PORT 55555

int sds;

sds = socket(AF_INET, SOCK_DGRAM, 0);
if (sds < 0) {perror("problème création socket"); exit(1);}


struct sockaddr_in addr_s;
/* Initialisation structure adresse émission * /
memset (&addr_s, 0, sizeof(addr_s));
addr_s.sin_family = AF_INET;
addr_s.sin_port =htons(PORT);
addr_s.sin_addr.s_addr = inet_addr(GROUP);
```

Portée d'un message Multicast (E)

```
unsigned char ttl = 1;

/* Fixer la portée du message */
/* Fixer la valeur du TTL */

if (setsockopt (sds, IPPROTO_IP,
IP_MULTICAST_TTL,
&ttl, sizeof(ttl)) < 0) {
    perror("probleme setsockopt" );
    exit(1);
}
```

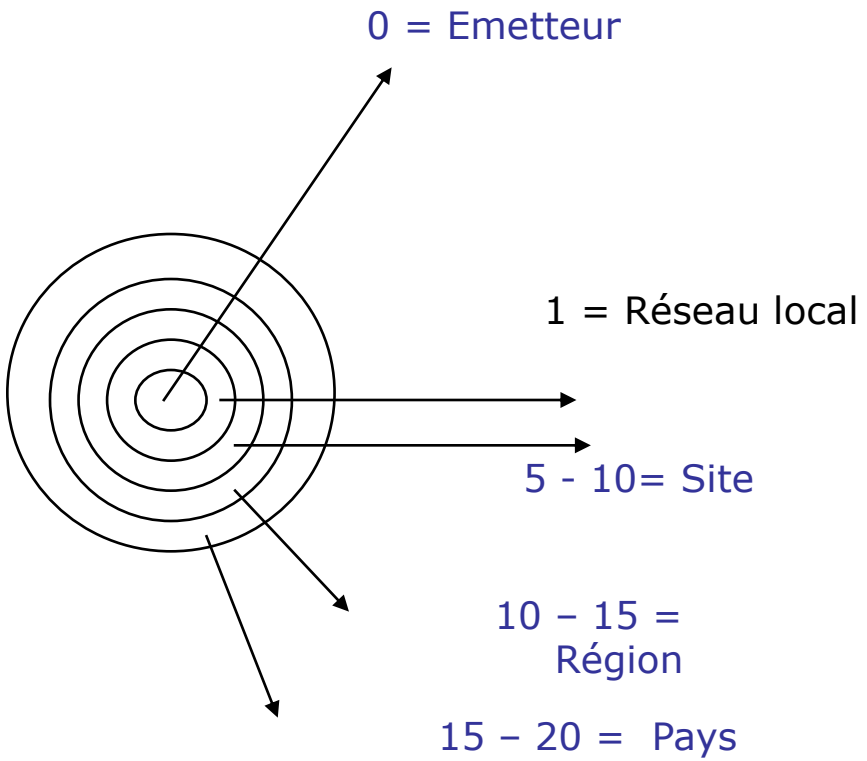

Emission d'un message Multicast (E)

```
int cnt, len_s=sizeof(addr_s);
char buf[100];
/* Emission de paquets */
/* Utilisation de la primitive  sendto */

cnt = sendto (sds, buf, strlen(buf)+1, 0,
                                        (struct sockaddr *)&addr_s, len_s)
if (cnt < 0) {
        perror("problème sendto" );
          exit(1);
}
```

Plan

① Contrôle de congestion et TCP

② Programmation réseaux

- socket, select(), options de socket, socket raw

③ Communication de groupe (multicast)

④ Introduction IPv6